

University of Oviedo

UNIVERSIDAD DE OVIEDO
ESCUELA POLITÉCNICA DE INGENIERÍA DE GIJÓN

Análisis de ECG como imagen con modelos supervisados y de visión y lenguaje: estudio de caso en síndrome de Brugada

Trabajo de Fin de Grado

Autor: Alejandro Moris Lara

Tutor: Nahuel Costa Cortez

18 de agosto de 2026

Resumen

Este Trabajo de Fin de Grado estudia el análisis automático de electrocardiogramas (ECG) representados como imágenes. El trabajo se centra en la sospecha de síndrome de Brugada, una enfermedad rara para la que resulta difícil reunir conjuntos amplios de pacientes etiquetados. Su objetivo es analizar cómo pueden aprovecharse unos pocos ejemplos para identificar patrones relevantes en el trazado electrocardiográfico.

Se comparan dos estrategias. La primera emplea una red neuronal convolucional (CNN) ResNet18 entrenada de forma supervisada. La segunda utiliza el modelo de visión y lenguaje Gemma 4 mediante aprendizaje en contexto (ICL), incorporando ejemplos etiquetados a la consulta sin modificar sus pesos. Ambos métodos analizan la imagen de un latido de la derivación V1, uno de los trazados que el ECG registra desde el tórax. Se utilizan entre 2 y 32 ejemplos, con 100 casos generados por un simulador QRS/ST y ECG de 317 pacientes del Hospital Universitario Central de Asturias (HUCA).

Primero se comprueba si los modelos reconocen la combinación de tres rasgos morfológicos definida en el simulador, utilizando ejemplos y pruebas del propio generador. Con 32 ejemplos, ResNet18 alcanza una exactitud balanceada (BA) de 0,885 y Gemma 4 obtiene 0,904 con igual número de demostraciones de ambas clases. Estos resultados no se mantienen al evaluar ECG clínicos con lo aprendido del simulador. La CNN alcanza un máximo de 0,551 sobre el HUCA y Gemma 4 obtiene 0,514 con demostraciones del generador, tendiendo a clasificar los casos como negativos.

Por último, se compara el aprendizaje con ejemplos del HUCA al clasificar otros pacientes del mismo conjunto. Una segunda CNN se entrena directamente con estos datos y llega a una BA de 0,546 con 16 ejemplos. Su rendimiento queda cerca del azar y supera ligeramente a Gemma 4 con 2 y 4 ejemplos. Gemma 4 obtiene mejores resultados desde 8 y alcanza una BA de 0,761 con 32 demostraciones del HUCA equilibradas, una sensibilidad de 0,741 y una especificidad de 0,781.

Sin ejemplos, Gemma 4 no identifica positivos en ninguno de los dos conjuntos. Con demostraciones del HUCA sí logra clasificar otros pacientes del mismo conjunto, mientras que los ejemplos del simulador no bastan para trasladar ese aprendizaje a ECG reales. Estos resultados justifican investigar su uso como apoyo al triaje para priorizar la revisión y facilitar la recogida de datos con los que desarrollar modelos de mayor rendimiento o explicabilidad. Esta ayuda requeriría validación clínica y no sustituiría una evaluación médica completa.

Palabras clave: electrocardiograma como imagen, síndrome de Brugada, aprendizaje con pocos datos, redes neuronales convolucionales, modelos de visión y lenguaje, aprendizaje en contexto, adaptación de dominio.

Abstract

This Bachelor's Thesis studies the automatic analysis of electrocardiograms (ECGs) represented as images. It focuses on suspected Brugada syndrome, a rare disease for which large labelled patient datasets are difficult to assemble. The aim is to examine how a few examples can help identify relevant ECG patterns.

The two strategies compared are supervised training of a ResNet18 convolutional neural network (CNN) and in-context learning (ICL) with the Gemma 4 vision-language model, which receives labelled examples in the query without weight updates. Both analyse an image of one heartbeat from lead V1, one of the ECG traces recorded from the chest. Experiments use between 2 and 32 examples, with 100 QRS/ST simulator cases and ECGs from 317 patients at Hospital Universitario Central de Asturias (HUCA).

First, examples and test images from the simulator assess recognition of three predefined waveform features. With 32 examples, ResNet18 reaches a balanced accuracy (BA) of 0.885 and Gemma 4 reaches 0.904 with equally represented classes. Performance falls when simulator-based learning is applied to clinical ECGs. The CNN achieves a maximum BA of 0.551 on HUCA, while Gemma 4 reaches 0.514 with simulator demonstrations and tends to predict the negative class.

Finally, HUCA examples are used to classify other patients from the same dataset. A second CNN trained directly on these data reaches a BA of 0.546 with 16 examples. It remains near chance and slightly outperforms Gemma 4 with 2 and 4 examples. Gemma 4 performs better from 8 onwards, reaching a BA of 0.761 with 32 balanced HUCA demonstrations, 0.741 sensitivity and 0.781 specificity.

Without examples, Gemma 4 identifies no positives in either dataset. HUCA demonstrations help it classify other patients from the same dataset, whereas simulator examples do not adequately transfer this learning to real ECGs. These results support investigating triage assistance to prioritise review and collect data for models with better performance or explainability. Such assistance would require clinical validation and would not replace a full medical assessment.

Keywords: electrocardiogram as image, Brugada syndrome, few-shot learning, convolutional neural networks, vision-language models, in-context learning, domain adaptation.

Glosario de siglas

Tabla 1.- Siglas y abreviaturas utilizadas en la memoria.

Sigla	Significado	Uso en este trabajo
Acc.	Exactitud	Proporción global de predicciones correctas. Se informa como métrica complementaria en los apéndices.
ACCF	American College of Cardiology Foundation	Sociedad científica citada en recomendaciones de estandarización electrocardiográfica.
AHA	American Heart Association	Sociedad científica citada en guías y recomendaciones clínicas sobre electrocardiografía.
AP	Precisión media	Área bajo la curva precisión-recall. Se usa como métrica complementaria en las tablas completas.
API	Interfaz de programación de aplicaciones	Se menciona al discutir modelos servidos por proveedores externos.
AUC	Área bajo la curva	Resumen escalar de una curva de rendimiento, usado junto a ROC.
aVR, aVL, aVF	Derivaciones aumentadas de miembros	Derivaciones del electrocardiograma convencional citadas al describir el registro de doce derivaciones.
BA	Exactitud balanceada	Métrica principal. Promedia sensibilidad y especificidad para no favorecer a la clase mayoritaria.
BCE	Entropía cruzada binaria	Función de pérdida para clasificación binaria o multietiqueta.
CAM	Mapa de activación de clase	En Grad-CAM relaciona regiones de la imagen con una predicción.
CC BY	Creative Commons Attribution	Licencia de reutilización asociada a una de las imágenes clínicas citadas.
CC BY-SA	Creative Commons Attribution ShareAlike	Licencia de reutilización con atribución y obligación de compartir bajo condiciones equivalentes.
CLIP	Contrastive Language-Image Pre-training	Modelo que relaciona imágenes y textos mediante preentrenamiento contrastivo, revisado en antecedentes.

Sigla	Significado	Uso en este trabajo
CNN	Red neuronal convolucional	Modelo supervisado que ajusta pesos a partir de ejemplos etiquetados. En la memoria se concreta en ResNet18.
CoCoOp	Conditional Context Optimization	Ajuste de prompts condicionados por la imagen, revisado en antecedentes.
CoOp	Context Optimization	Ajuste de vectores de contexto para adaptar modelos de visión y lenguaje, revisado en antecedentes.
CORAL	Correlation Alignment	Método de adaptación de dominio incluido como resultado complementario.
DANN	Domain-Adversarial Neural Network	Método de adaptación de dominio incluido como resultado complementario.
DAPL	Domain Adaptation via Prompt Learning	Adaptación de dominio mediante prompts aprendidos, revisada en antecedentes.
ECG	Electrocardiograma	Trazado cardíaco utilizado en forma de imagen.
ECGBench	ECG Benchmark	Banco de evaluación multimodal citado en trabajos relacionados.
ECGInstruct	ECG Instruction Dataset	Conjunto de instrucciones con imagen y texto citado en trabajos relacionados.
Esp.	Especificidad	Proporción de casos negativos identificados correctamente.
F1	Medida F1	Media armónica entre precisión y sensibilidad.
FN	Falso negativo	Caso positivo clasificado como negativo.
FP	Falso positivo	Caso negativo clasificado como positivo.
HRS	Heart Rhythm Society	Sociedad científica citada en recomendaciones clínicas.
HUCA	Hospital Universitario Central de Asturias	Origen de la muestra de ECG clínicos utilizada en la evaluación.
ICL	Aprendizaje en contexto	Uso de ejemplos etiquetados dentro del prompt sin modificar los pesos del modelo.
ImageNet	ImageNet	Colección de imágenes usada como origen habitual de pesos preentrenados en modelos visuales.
JSON	JavaScript Object Notation	Formato estructurado exigido en las respuestas del modelo multimodal.
K	Número de ejemplos	Tamaño del conjunto usado en cada pliegue. En la CNN indica pacientes de entrenamiento y en el VLM indica demostraciones de contexto.

Sigla	Significado	Uso en este trabajo
LOOCV	Validación leave-one-out	Evaluación por paciente reservado. En cada pliegue se deja un paciente fuera.
MaPLe	Multi-modal Prompt Learning	Ajuste conjunto de prompts visuales y textuales, revisado en antecedentes.
MEETI	MIMIC ECG Event-based Text-image	Recurso multimodal de electrocardiografía revisado en el estado del arte.
MIMIC	Medical Information Mart for Intensive Care	Familia de recursos clínicos abiertos citada en trabajos relacionados.
MMD	Maximum Mean Discrepancy	Medida usada como método complementario de adaptación de dominio.
PDF	Portable Document Format	Formato habitual de documento clínico o de intercambio del electrocardiograma renderizado.
PR	Intervalo PR	Intervalo electrocardiográfico entre la activación auricular y ventricular.
Prec.	Precisión	Proporción de predicciones positivas que corresponden a positivos reales.
PTB XL	Physikalisch-Technische Bundesanstalt XL	Conjunto abierto de electrocardiogramas de doce derivaciones citado en trabajos relacionados.
PULSE	PULSE	Modelo multimodal especializado en ECG citado en el estado del arte.
QRS	Complejo QRS	Región asociada a la despolarización ventricular.
QRS/ST	Complejo QRS y segmento ST	Nombre abreviado del simulador utilizado en la memoria.
QT	Intervalo QT	Intervalo electrocardiográfico relacionado con despolarización y repolarización ventricular.
QTc	Intervalo QT corregido	Intervalo QT ajustado por frecuencia cardíaca, mencionado en el contexto clínico.
RBBB	Bloqueo de rama derecha	Etiqueta morfológica compatible empleada en el simulador.
RBF	Radial Basis Function	Tipo de kernel utilizado para comparar características con MMD.
ResNet18	Residual Network 18	Arquitectura de la CNN evaluada.
RGB	Red, green, blue	Representación de imagen con tres canales de color.
ROC	Receiver Operating Characteristic	Curva que relaciona sensibilidad y tasa de falsos positivos.
RSR	Morfología RSR prima	Patrón visual con segunda deflexión positiva terminal en el complejo QRS.

Sigla	Significado	Uso en este trabajo
Sens.	Sensibilidad	Proporción de positivos identificados correctamente.
SimCLR	Simple Framework for Contrastive Learning of Visual Representations	Método autosupervisado citado en la configuración complementaria.
SSL	Aprendizaje autosupervisado	Estrategia complementaria de adaptación de dominio incluida en resultados completos.
ST	Segmento ST	Región posterior al QRS cuya elevación participa en la formulación morfológica del estudio.
TFG	Trabajo de Fin de Grado	Documento académico en el que se enmarca el proyecto.
TN	Verdadero negativo	Caso negativo clasificado correctamente como negativo.
TP	Verdadero positivo	Caso positivo clasificado correctamente como positivo.
TPT	Test-Time Prompt Tuning	Ajuste del prompt al evaluar cada imagen, revisado en antecedentes.
TWI	Inversión de onda T	Deflexión tardía negativa utilizada como rasgo visible en el simulador.
V1–V6	Derivaciones precordiales	Derivaciones torácicas del electrocardiograma. En los experimentos se usa exclusivamente V1.
VLM	Modelo de visión y lenguaje	Modelo multimodal que recibe imágenes y texto en un mismo prompt.
XAI	Inteligencia artificial explicable	Métodos para examinar qué información se relaciona con las decisiones de un modelo.

Índice general

Resumen I

Abstract II

Glosario de siglas III

1. Introducción **1**
1.1. Motivación y alcance 1
1.2. Objetivos 2
1.3. Estructura de la memoria 2

2. Antecedentes y estado del arte **3**
2.1. Aprendizaje sobre señales e imágenes de ECG 3
2.2. Generación de ECG 4
2.3. Datos multimodales y modelos especializados 4
2.4. Estudios sobre aprendizaje en contexto 5
2.5. Adaptación de dominio en modelos visuales y multimodales 6
2.5.1. Adaptación de redes convolucionales 6
2.5.2. Adaptación de modelos de visión y lenguaje 8
2.6. Elección del modelo y entorno 8
2.7. Comparación con escasez de datos 9

3. Fundamentos clínicos y técnicos **10**
3.1. El electrocardiograma y sus componentes 10
3.2. Síndrome de Brugada y rasgos estudiados 11
3.2.1. Evaluación clínica 11
3.2.2. Morfología compatible con bloqueo de rama derecha 13
3.2.3. Elevación del ST e inversión de T 13
3.3. Señal digital e imagen 14
3.4. Clasificación y salida de los modelos 14
3.5. Redes neuronales convolucionales 15
3.6. Explicabilidad y adaptación de dominio 16
3.7. Modelos de visión y lenguaje y aprendizaje en contexto 16

4. Diseño experimental **18**
4.1. Datos y tareas 18
4.1.1. Características de la muestra del HUCA 19
4.2. Escenarios de comparación 19
4.3. Selección de ejemplos y validación 20

4.3.1. Secuencia de un pliegue clínico . . . 20
4.3.2. Distribución de los ejemplos por clase . . . 21
4.4. Métricas y agregación . . . 22

5. El simulador QRS/ST **23**
5.1. Objetivo del simulador . . . 23
5.2. Representación matemática . . . 23
5.3. Muestreo temporal . . . 25
5.4. Familias generadoras . . . 25
5.4.1. Familia normal . . . 25
5.4.2. Morfología RBBB . . . 26
5.4.3. Elevación de ST . . . 26
5.4.4. Inversión de T . . . 26
5.4.5. Familia asociada al síndrome de Brugada . . . 26
5.5. Rangos de parámetros . . . 27
5.6. Reglas de coherencia morfológica . . . 27
5.7. Muestreo con rechazo . . . 28
5.8. Validadores y asignación de etiquetas . . . 29
5.9. Renderizado y controles visuales . . . 29
5.10. Limitaciones del simulador . . . 30

6. Dos enfoques de modelado **32**
6.1. CNN ResNet18 . . . 32
6.1.1. Arquitectura y entrenamiento . . . 32
6.1.2. Predicción y selección del umbral . . . 33
6.1.3. Adaptación de dominio . . . 34
6.1.4. Inspección con Grad-CAM . . . 34
6.2. Gemma con aprendizaje en contexto . . . 35
6.2.1. Modelo y servicio . . . 35
6.2.2. Prompt y respuesta . . . 36

7. Resultados **37**
7.1. Resultados con los datos del simulador . . . 37
7.2. Resultados con los datos del HUCA . . . 39
7.2.1. Transferencia desde el simulador . . . 39
7.2.2. Aprendizaje con ejemplos clínicos . . . 41
7.2.3. Comparación entre el simulador y el HUCA . . . 43

8. Discusión y conclusiones **46**
8.1. Interpretación de los resultados . . . 46
8.1.1. Aprendizaje con datos del simulador . . . 46
8.1.2. Adaptación al dominio de los datos clínicos . . . 47
8.1.3. Aprendizaje con datos clínicos . . . 47
8.2. Aportaciones y limitaciones . . . 48

8.3. Continuación del trabajo 48
8.4. Conclusiones 49

9. Aspectos éticos y protección de datos **51**
9.1. Responsabilidad clínica 51
9.2. Protección de datos 51

A. Configuración experimental **52**
A.1. Conjunto generado por el simulador QRS/ST 52
A.2. Muestra del HUCA 53
A.3. Configuración de las CNN 54
A.4. Configuración de adaptación de dominio 55
A.5. Configuración de Gemma 4 55

B. Resultados completos **56**
B.1. CNN entrenada con el simulador 56
B.2. CNN entrenada con el HUCA 57
B.3. Adaptación de dominio de la CNN 57
B.4. Gemma 4 con aprendizaje en contexto 58
B.4.1. Resultados con datos del simulador 58
B.4.2. Pacientes del HUCA con demostraciones del mismo conjunto . . . 59
B.4.3. Pacientes del HUCA con demostraciones del simulador 59

C. Prompts y respuestas estructuradas **60**
C.1. Criterio de conservación 60
C.2. Sistema para tarea morfológica 60
C.3. Tarea morfológica 60
C.4. Sistema para tarea clínica 61
C.5. Tarea clínica directa 61
C.6. Validación de las respuestas 62

Bibliografía **63**

Índice de figuras **69**

Índice de tablas **71**

Capítulo 1. Introducción

El electrocardiograma (ECG) registra la actividad eléctrica del corazón mediante electrodos colocados sobre el cuerpo. El trazado permite estudiar el ritmo cardíaco y cambios en la forma de sus ondas. Este Trabajo de Fin de Grado analiza imágenes de ECG con pocos ejemplos etiquetados y toma como caso de estudio la sospecha de síndrome de Brugada, una enfermedad poco frecuente asociada a arritmias ventriculares y muerte súbita [1, 6].

Se comparan dos formas de aprovechar esos ejemplos. En el aprendizaje supervisado, el modelo recibe imágenes junto con sus etiquetas, las respuestas asignadas a cada caso, y aprende ajustando sus parámetros internos o pesos. Se utiliza una red neuronal convolucional (CNN) con la arquitectura ResNet18.

La alternativa es Gemma 4, un modelo de visión y lenguaje (VLM) que procesa imágenes e instrucciones escritas. Mediante aprendizaje en contexto (ICL), recibe ejemplos resueltos junto con la imagen que debe clasificar. Esos ejemplos, llamados demostraciones, forman parte de la información de la consulta o contexto y orientan la respuesta sin cambiar los pesos del modelo. Los mecanismos de ambos métodos se desarrollan en las secciones 3.5 y 3.7.

1.1.- MOTIVACIÓN Y ALCANCE

La escasez de pacientes etiquetados dificulta aplicar los métodos de aprendizaje profundo, que aprenden mediante redes de varias capas y suelen entrenarse con grandes colecciones de ECG [11, 15]. Además, confirmar un caso de Brugada exige revisión especializada y, en ocasiones, pruebas complementarias. El patrón puede ser intermitente y no aparecer en un registro aislado, por lo que un ECG normal no descarta el síndrome. Sus criterios clínicos se describen en la sección 3.2.

El análisis de imágenes permite trabajar con trazados disponibles como documentos, sin exigir la señal digital original, es decir, la secuencia numérica de medidas del ECG. El recorte y el redimensionado de la imagen pueden, sin embargo, alterar su escala. En este estudio interesa comprobar a partir de cuántos ejemplos puede resultar más útil ajustar una CNN frente a proporcionar casos resueltos a Gemma 4.

Para disponer de ejemplos de forma controlada, el estudio utiliza un simulador de latidos artificiales denominado QRS/ST por las regiones del trazado que modela, descritas en la sección 3.1. Se cuenta además con ECG de 317 pacientes del Hospital Universitario Central

de Asturias (HUCA).

Los ejemplos del simulador se utilizan primero para clasificar otros latidos generados y después para estudiar la transferencia a ECG del HUCA, es decir, cuánto de lo aprendido permite reconocer casos reales. También se entrena una segunda CNN con pacientes del HUCA y se compara con Gemma 4 cuando ambos aprenden de ejemplos clínicos.

La aplicación que motiva el trabajo es el apoyo al triaje mediante la identificación de ECG sospechosos para priorizar su revisión y facilitar la recogida de más casos etiquetados. Esta ayuda no sustituiría la evaluación clínica de la sección 3.2.1, ni la confirmación diagnóstica, las pruebas o el tratamiento, que corresponden al personal sanitario.

1.2.- OBJETIVOS

El objetivo general es comparar ambos métodos cuando solo se dispone de unos pocos pacientes etiquetados. Se denomina K al número de ejemplos de entrenamiento de la CNN o de demostraciones incluidas en el contexto de Gemma 4. Se plantean las siguientes tres preguntas.

1. ¿Cómo cambia el rendimiento de ResNet18 y Gemma 4 al aumentar el número de ejemplos del simulador?
2. ¿Cómo se compara el ICL con una CNN entrenada directamente con ECG clínicos usando los mismos valores de K?
3. ¿Qué rendimiento se conserva al pasar del simulador al HUCA y cómo influye el origen de los datos de entrenamiento de la CNN y de las demostraciones de Gemma 4?

El capítulo 4 precisa la selección de esos ejemplos y las diferencias de validación entre ambos métodos.

1.3.- ESTRUCTURA DE LA MEMORIA

Los capítulos 2 y 3 presentan los antecedentes y los fundamentos clínicos y técnicos. Los capítulos 4, 5 y 6 describen el diseño experimental, el generador y la ejecución de los modelos. Los resultados se presentan en el capítulo 7, su discusión y conclusiones en el capítulo 8, y los aspectos éticos y de privacidad en el capítulo 9.

Capítulo 2. Antecedentes y estado del arte

La revisión compara estudios según la entrada, el tamaño y origen de los datos, las etiquetas y la validación. En clasificación multietiqueta, un ECG puede recibir varias etiquetas, frente a una tarea positiva o negativa. Una imagen renderizada se dibuja desde la señal digital y puede diferir de una fotografía del documento. La interpretación de los resultados debe tener en cuenta estas diferencias.

2.1.- APRENDIZAJE SOBRE SEÑALES E IMÁGENES DE ECG

Ribeiro y colaboradores entrenaron una red con más de dos millones de ECG de doce derivaciones de una red brasileña de telemedicina [11]. Reconocía seis alteraciones y se comparó con médicos en un subconjunto anotado. Este volumen de registros contrasta con la dificultad de reunir etiquetas fiables para enfermedades poco frecuentes. Las etiquetas asignadas durante la atención médica también pueden variar según los criterios de cada centro, las versiones del software y los profesionales que revisan el ECG.

PTB-XL reúne 21 837 ECG de doce derivaciones con 71 etiquetas que pueden coexistir en un registro. Propone divisiones para entrenamiento y evaluación, llamadas particiones [12]. MIMIC-IV-ECG amplió la escala hasta aproximadamente 800 000 registros vinculados a información clínica [13]. Ambos permiten preentrenar modelos, es decir, ajustarlos con un conjunto amplio antes de usarlos en una tarea concreta, y validar su rendimiento. Sin embargo, reunir muchos ECG no garantiza disponer de suficientes ejemplos de enfermedades poco frecuentes como el síndrome de Brugada.

Gliner y colaboradores compararon señales digitales e imágenes de doce derivaciones [14]. Incluyeron ocho condiciones para el modelo temporal, una evaluación visual de fibrilación auricular y transformaciones que imitaban fotografías con teléfono. Sangha y colaboradores entrenaron una CNN multietiqueta con 2 228 236 registros brasileños convertidos en imágenes [15]. Predijo seis etiquetas clínicas y se evaluó con datos alemanes y ECG impresos. Estos trabajos demuestran la utilidad de la imagen con grandes colecciones, pero no resuelven el entrenamiento con unas pocas decenas de pacientes.

Wu y colaboradores reconstruyeron señales a partir de trazados impresos [16]. La correlación con el original fue alta en formatos favorables y disminuyó cuando las derivaciones se

solapaban. Gliner y colaboradores abordaron después la transferencia de imágenes limpias a fotografías y formatos no observados mediante adaptación adversarial con imágenes objetivo sin etiqueta [17]. Ambos estudios muestran que el formato de adquisición condiciona la evaluación.

2.2.- GENERACIÓN DE ECG

La generación de ECG permite construir ejemplos cuando los registros disponibles son escasos y estudiar por separado qué cambios del trazado aprende un modelo. Una opción es representar las ondas mediante curvas gaussianas, cuya amplitud, posición y anchura pueden modificarse para controlar la forma del latido. Sayadi y colaboradores emplearon esta representación en un sistema dinámico de generación y filtrado bayesiano [18], manteniendo una relación explícita entre los parámetros y las ondas resultantes.

Los modelos electrofisiológicos, en cambio, simulan cómo se propaga la actividad eléctrica sobre una geometría cardíaca y permiten obtener varias derivaciones de un mismo caso. MedalCare XL sigue este enfoque y contiene 16 900 ECG de doce derivaciones, correspondientes a un grupo sano y siete patologías [19]. Esta descripción más próxima al proceso fisiológico requiere más cómputo que la construcción directa de las ondas.

Otra alternativa son los modelos de difusión, que aprenden a generar señales condicionadas por diagnósticos [20]. Su flexibilidad permite representar variaciones que no se han definido mediante reglas individuales, aunque resulta menos directo asociar cada parámetro con una parte concreta del trazado. Por ello, la elección de un generador debe considerar tanto la diversidad y el parecido con ECG reales como su utilidad al entrenar y evaluar otros modelos.

En este TFG se utiliza un generador de un latido con tres rasgos localizados, para conocer qué combinación debe reconocer cada modelo antes de probarlo con pacientes del HUCA. El capítulo 5 desarrolla sus ecuaciones y reglas, mientras que la evaluación con ECG reales comprueba cuánto se conserva fuera del formato y de las variaciones previstas por el simulador.

2.3.- DATOS MULTIMODALES Y MODELOS ESPECIALIZADOS

Relacionar la señal, su representación como imagen y el informe de un mismo ECG permite estudiar conjuntamente la forma del trazado y su descripción escrita. MEETI, publicado en 2026 como extensión de MIMIC-IV-ECG, organiza así hasta 784 680 registros de 160 597 pacientes [22], combinando señales, imágenes con escala estándar y parámetros por latido

con interpretaciones detalladas generadas por un modelo de lenguaje a partir de informes y medidas.

Esta correspondencia puede utilizarse en el preentreno de modelos, la búsqueda de registros semejantes y la generación de informes, además de permitir comparar imagen, señal y texto sobre los mismos ECG de doce derivaciones.

Otra forma de aprovechar la relación entre imagen y texto es adaptar un modelo mediante instrucciones específicas de ECG. Liu y colaboradores siguen esta estrategia con ECGInstruct, que contiene más de un millón de pares de imagen y texto sobre características, ritmo, morfología e informes, y con PULSE, un modelo de siete mil millones de parámetros [21]. Para evaluarlo presentan ECGBench, con cuatro tareas distribuidas en nueve conjuntos de imágenes generadas y reales, donde informan de mejores resultados de PULSE frente a varios modelos generalistas.

Estos trabajos utilizan los datos multimodales para preparar representaciones comunes y especializar un modelo para responder sobre ECG. Ambos usos dependen de conjuntos amplios, que todavía pueden contener pocos ejemplos de una enfermedad rara. Frente a ese requisito, este TFG estudia qué puede aprenderse al consultar un modelo generalista con unos pocos casos resueltos, sin ajustar sus pesos.

2.4.- ESTUDIOS SOBRE APRENDIZAJE EN CONTEXTO

Flamingo mostró que un modelo multimodal preentrenado podía responder a tareas nuevas al recibir secuencias intercaladas de imágenes y texto [24]. Este resultado extendió el uso de ejemplos dentro de una consulta a tareas visuales, sin exigir un ajuste de pesos para cada una. El mecanismo se formaliza en la sección 3.7.

Entre los antecedentes médicos del trabajo de Camba y colaboradores se encuentra el estudio de Ferber y colaboradores sobre imágenes de anatomía patológica [28, 27]. Evaluaron GPT-4V en tres tareas de clasificación y observaron que unas pocas imágenes por clase podían mejorar la respuesta sin ejemplos y alcanzar resultados comparables a clasificadores especializados en algunas de ellas. También estudiaron la selección de demostraciones por similitud visual, de modo que el número de ejemplos no fue el único factor que condicionó el resultado. Esta experiencia apoya estudiar el mismo procedimiento en otras imágenes médicas.

Camba, Otero, García, Sánchez y Costa aplicaron esta idea a la detección de bloqueo de rama izquierda y síndrome de Brugada en imágenes de ECG [27]. Además de incorporar demostraciones, solicitaron al modelo identificar primero conceptos clínicos intermedios y utilizarlos después para clasificar el caso. La propuesta se inspira en los modelos basados en conceptos de Koh y colaboradores, donde la predicción final se construye a partir de caracte-

rísticas comprensibles para una persona [29]. En un prompt, ese orden permite inspeccionar las respuestas intermedias, aunque no impone por sí mismo que el diagnóstico dependa únicamente de ellas como ocurriría en una arquitectura diseñada con esa restricción.

Costa y colaboradores desarrollaron después una comparación de modelos de visión y lenguaje preentrenados con métodos de aprendizaje automático especializados en ECG, utilizando Brugada como caso de estudio con pocos datos [30]. Analizaron también el efecto de las instrucciones y de la representación de entrada, e informaron de resultados competitivos sin actualizar los pesos del modelo. Este trabajo es un antecedente directo del TFG y del estudio de los modelos generalistas de cara al triaje de enfermedades raras.

Por otro lado, Chen y colaboradores estudiaron la composición de las demostraciones y observaron que, en los modelos y tareas estudiados, el texto tenía más influencia que las imágenes sobre la respuesta, aunque la información visual seguía siendo útil para elegir ejemplos [25]. Qin y colaboradores, al comparar seis modelos y veinte estrategias, encontraron efectos de la selección multimodal, del orden de imagen y texto dentro de cada demostración y de la posición de las instrucciones [26]. Estas observaciones aconsejan comprobar tanto qué casos se muestran como la forma de presentarlos.

En conjunto, estos antecedentes justifican estudiar el aprendizaje en contexto con ECG cuando faltan datos.

2.5.- ADAPTACIÓN DE DOMINIO EN MODELOS VISUALES Y MULTIMODALES

Un modelo puede perder rendimiento cuando las imágenes utilizadas para aprender difieren de aquellas sobre las que debe predecir. La adaptación de dominio estudia cómo aprovechar el conjunto de origen para trabajar sobre otro conjunto, denominado objetivo, cuya distribución cambia. En ECG, este problema puede aparecer al pasar de trazados generados a registros de pacientes o entre formatos de adquisición. El acceso a imágenes objetivo y a sus etiquetas determina qué métodos pueden aplicarse.

2.5.1.- Adaptación de redes convolucionales

Cuando el conjunto objetivo carece de etiquetas, una posibilidad consiste en preparar el extractor para reconocer regularidades de sus imágenes antes de entrenar un clasificador. SimCLR, propuesto por Chen y colaboradores, utiliza aprendizaje autosupervisado, o SSL, para acercar las representaciones de dos versiones aumentadas de una misma imagen y separarlas de las correspondientes a otras imágenes [42]. Una red de proyección transforma las características antes de calcular la pérdida contrastiva. Las transformaciones utilizadas son

parte del problema de aprendizaje, pues definen qué variaciones debe tolerar la representación. Este procedimiento prepara las características sin necesitar respuestas clínicas para cada imagen.

Otra línea mantiene el aprendizaje con etiquetas del origen y añade un objetivo para aproximar sus representaciones a las del conjunto objetivo. Deep CORAL, el alineamiento de correlaciones de Sun y Saenko para redes profundas, reduce la diferencia entre las covarianzas de ambos grupos [43]. Estas matrices describen cómo varían conjuntamente las características y permiten actuar sobre sus relaciones, además de conservar la pérdida de clasificación del origen. La Figura 2.1 resume este mecanismo en el contexto del simulador y el HUCA.

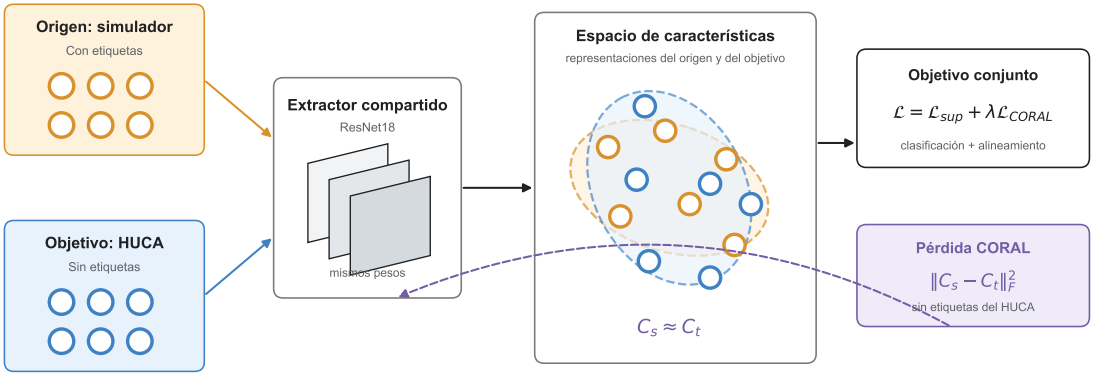


Figura 2.1.- Esquema de Deep CORAL. El extractor compartido aprende la tarea con las etiquetas del simulador y recibe además una penalización que aproxima las covarianzas de las representaciones del simulador y del HUCA, sin utilizar etiquetas clínicas.

Long y colaboradores emplean en las redes de adaptación profunda la discrepancia máxima de medias, o MMD, para comparar distribuciones de características [44]. La comparación se realiza en un espacio definido por kernels, funciones que miden semejanza entre representaciones, y permite recoger diferencias que no quedarían descritas por la media de los vectores originales. Los kernels de base radial, o RBF, expresan esa semejanza en función de la distancia, mientras que combinar escalas permite considerar proximidades distintas.

La red adversarial de dominio, o DANN, de Ganin y colaboradores plantea el problema mediante un clasificador adicional que intenta identificar el origen de cada imagen [41]. El extractor aprende a resolver la tarea etiquetada y, al mismo tiempo, a dificultar esa identificación. Una capa de inversión de gradiente transmite al extractor la dirección opuesta a la que mejora el clasificador de dominio, permitiendo entrenar ambas ramas conjuntamente. En imágenes de ECG, el trabajo de Gliner y colaboradores utiliza adaptación adversarial para abordar diferencias entre imágenes limpias y fotografías o formatos no observados [17].

SimCLR prepara el extractor antes del ajuste supervisado. CORAL, MMD y DANN relacionan los conjuntos durante el entrenamiento.

2.5.2.- Adaptación de modelos de visión y lenguaje

En los modelos de visión y lenguaje, la información textual ofrece otra vía para adaptar la clasificación. CLIP, cuyo nombre alude al preentrenamiento contrastivo de lenguaje e imagen, aprende a relacionar imágenes y descripciones en un espacio de representación común [31]. Después puede comparar una imagen con textos que describen las clases de interés. La elección de esas descripciones influye en la correspondencia entre la tarea y las representaciones aprendidas, lo que ha motivado métodos para ajustar los prompts con pocos ejemplos.

CoOp, de Zhou y colaboradores, sustituye las palabras de contexto del prompt por vectores entrenables, manteniendo fijos los parámetros del modelo preentrenado [32]. Su extensión CoCoOp genera además un contexto condicionado por cada imagen para reducir la dependencia de las clases observadas durante el ajuste [33]. MaPLe amplía este planteamiento con prompts aprendidos y acoplados en las ramas visual y textual [34]. Estas propuestas estudian cómo aprovechar la relación entre ambas modalidades sin tener que ajustar todo el modelo para cada tarea.

La adaptación a un conjunto objetivo sin etiquetas aparece de forma explícita en DAPL, de Ge y colaboradores. El método incorpora información del dominio a prompts aprendidos para adaptar la clasificación a cada origen de las imágenes [35]. TPT, de Shu y colaboradores, desplaza el ajuste al momento de la prueba y optimiza el prompt a partir de versiones aumentadas de cada imagen [36]. Para ello selecciona las predicciones de mayor confianza y minimiza su entropía, favoreciendo una respuesta concentrada en una clase. En ambos casos existe una optimización de parámetros del prompt, aunque no se disponga de etiquetas objetivo.

Los modelos generativos admiten además la adaptación mediante instrucciones y demostraciones incluidas en la consulta, como muestran los antecedentes de Flamingo y los estudios sobre ECG ya revisados [24, 30]. Estos ejemplos se procesan como parte de la entrada, sin entrenar vectores de contexto ni actualizar los pesos del modelo.

2.6.- ELECCIÓN DEL MODELO Y ENTORNO

Además del rendimiento, trabajar con imágenes de pacientes exige decidir dónde se ejecuta el modelo y quién recibe los datos. Los modelos de pesos abiertos permiten realizar las consultas en equipos del propio centro o en un pequeño clúster de cómputo, sin depender de una API comercial externa. La interfaz de programación o API sigue siendo una forma de acceder al modelo desde otro programa, pero puede prestarse dentro del entorno autorizado, manteniendo allí las imágenes y el control de las versiones.

MedGemma 1.5 ofrece una variante médica de cuatro mil millones de parámetros que

puede ejecutarse localmente con GPU y está adaptada a radiología, histopatología, dermatología, fondo de ojo, documentos y registros clínicos. Las imágenes de ECG no figuran entre los datos de entrenamiento médico descritos en su documentación [38].

Gemma 4 E4B pertenece a las variantes compactas de la familia, orientadas a la ejecución en dispositivos locales [37]. Admite texto e imagen, un contexto extenso y resolución visual variable mediante tokens visuales, que son las unidades con las que representa la imagen. Conservar más detalle o incluir más demostraciones aumenta el cómputo y la memoria necesarios, por lo que la capacidad del equipo sigue siendo relevante. La sección 6.2 describe el clúster utilizado para los experimentos.

2.7.- COMPARACIÓN CON ESCASEZ DE DATOS

Los trabajos de Camba y de Costa y colaboradores ya plantean el uso de demostraciones para analizar ECG con pocos datos [27, 30]. Este TFG continúa esa línea al comparar ResNet18 con un modelo de visión y lenguaje de pesos abiertos usando entre 2 y 32 ejemplos etiquetados. Se estudia su capacidad de generalizar ante una enfermedad poco frecuente, tanto con ejemplos del simulador como del HUCA, manteniendo las imágenes en un entorno propio para proteger la privacidad de los pacientes. El objetivo es investigar una ayuda al triaje y a la priorización médica que acompañe la evaluación clínica completa y cuya utilidad deberá validarse antes de aplicarla a la asistencia.

Capítulo 3. Fundamentos clínicos y técnicos

3.1.- EL ELECTROCARDIOGRAMA Y SUS COMPONENTES

El electrocardiograma registra las diferencias de potencial producidas por la actividad eléctrica del corazón mediante derivaciones que observan distintas proyecciones de esa actividad tridimensional. En el ECG convencional, diez electrodos permiten obtener doce derivaciones, de las cuales I, II, III, aVR, aVL y aVF describen el plano frontal, mientras que V1 a V6 corresponden al horizontal.

Para interpretar sus amplitudes y duraciones es necesario conocer la colocación de los electrodos, la ganancia, la velocidad de registro y el filtrado [2]. La representación habitual utiliza 25 mm por segundo y 10 mm por mV, de modo que un milímetro equivale a 40 ms en horizontal y 0,1 mV en vertical. Esta escala, visible en el formato clínico de la Figura 3.1, puede perderse al recortar o redimensionar la imagen.

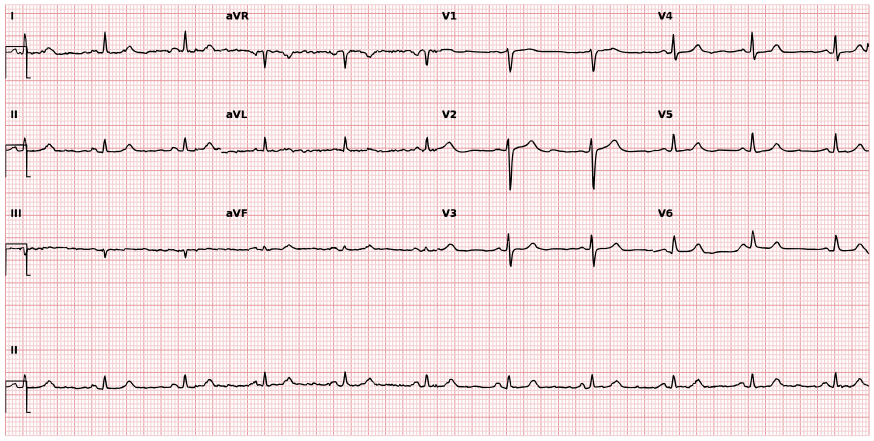


Figura 3.1.- Representación clínica de un ECG real de doce derivaciones a partir del renderizado de un registro de PTB-XL/PhysioNet [12].

La despolarización es la activación eléctrica de las células cardíacas y la repolarización, la recuperación de su estado eléctrico tras esa activación. La onda P representa la despolarización auricular y el intervalo PR, la propagación hacia los ventrículos. El complejo QRS corresponde a la despolarización ventricular. El punto J marca su final y el inicio del segmento ST. La onda T representa la repolarización ventricular. La Figura 3.2 sitúa estos componentes.

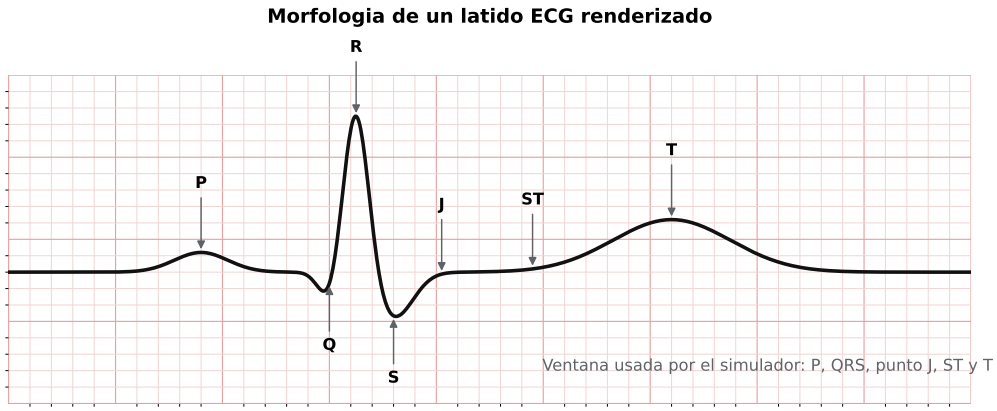


Figura 3.2.- Componentes morfológicos de un latido ECG. La figura identifica las ondas P, Q, R, S y T, el punto J y el segmento ST.

Q es la primera deflexión negativa anterior a una positiva, R la primera positiva y S la negativa posterior a R. Una segunda deflexión positiva se denomina R prima. Estas letras describen la forma del trazado.

3.2.- SÍNDROME DE BRUGADA Y RASGOS ESTUDIADOS

El síndrome de Brugada es una canalopatía hereditaria, una alteración de los canales que regulan el paso de iones en las células cardíacas. Se relaciona con los canales de sodio y con variantes en el gen *SCN5A*. Predispone a fibrilación ventricular y muerte súbita, especialmente durante el reposo o el sueño en varones jóvenes, aunque puede manifestarse a cualquier edad [1, 6]. Las estimaciones citadas sitúan su prevalencia entre 1 y 5 casos por cada 10 000 personas [5], con intervalos también descritos de una persona por cada 2 000 a 5 000. Puede estar infradiagnosticado porque muchos afectados permanecen asintomáticos.

El patrón tipo 1, o *coved*, presenta elevación del ST de al menos 2 mm en V1 o V2, de forma convexa y descendente, seguida de T negativa. Los patrones tipo 2 y tipo 3 no bastan para establecer el diagnóstico [1]. El patrón puede ser intermitente, por lo que un ECG basal normal no descarta el síndrome.

3.2.1.- Evaluación clínica

La interpretación combina el ECG con síntomas, antecedentes familiares y la exclusión de otras causas. El síncope inexplicado, la respiración agónica nocturna, la muerte súbita familiar y las arritmias ventriculares documentadas orientan la valoración del riesgo. El circuito comprende los siguientes pasos.

1. **ECG basal de doce derivaciones.** Un patrón tipo 1 espontáneo permite establecer el

diagnóstico tras descartar otras causas de elevación del ST.

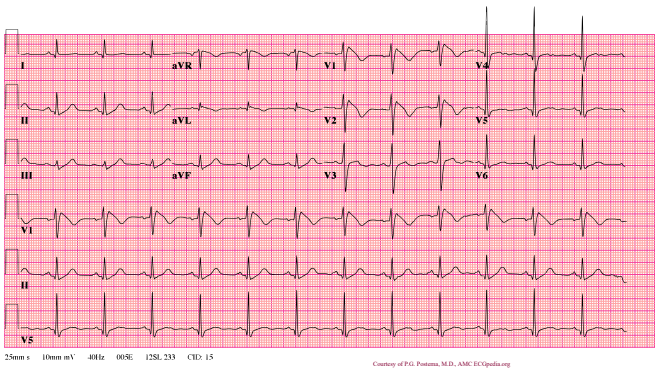
2. **Registro precordial alto.** Si el ECG es sospechoso, se registran V1 y V2 en el segundo o tercer espacio intercostal, en lugar del cuarto. La proximidad al tracto de salida del ventrículo derecho aumenta la sensibilidad [7].

3. **Revisión clínica.** Se revisan síntomas, antecedentes, comorbilidades y fármacos, ya que los trastornos electrolíticos, la isquemia y algunos medicamentos pueden producir patrones similares. Durante un episodio de fiebre puede aparecer un patrón de Brugada que no se observa a temperatura normal [1].

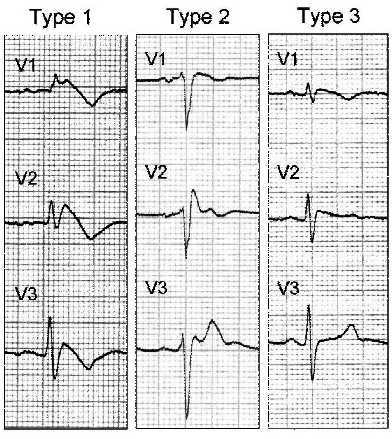
4. **Prueba farmacológica.** En pacientes seleccionados con sospecha persistente y ECG no diagnóstico se utilizan bloqueantes del canal de sodio, como ajmalina, flecainida, procainamida o pilsicainida. Se realiza con monitorización, personal entrenado y desfibrilador, y se considera positiva si aparece un patrón tipo 1 durante o después de administrar el fármaco [6].

5. **Estudio genético y decisión especializada.** En pacientes índice con patrón tipo 1 puede recomendarse estudiar *SCN5A* para la caracterización molecular y el cribado familiar. La estratificación del riesgo y el tratamiento dependen de la valoración conjunta de especialistas.

La Figura 3.3 muestra ejemplos clínicos de estos patrones.



(a) ECG con morfología tipo 1 en V1 y V2.



(b) Patrones tipo 1–3.

Figura 3.3.- Ejemplos clínicos de morfología asociada al síndrome de Brugada. La imagen izquierda procede de ECGpedia, CC BY-SA 3.0 [8]. La imagen derecha procede de Napolitano y Priori, CC BY 2.0 [9].

3.2.2.- Morfología compatible con bloqueo de rama derecha

El bloqueo de rama derecha (RBBB, por sus siglas en inglés) es una alteración de la conducción eléctrica que retrasa la activación del ventrículo derecho. Como esa activación ocurre después que la del izquierdo, cambia la parte final del complejo QRS y puede aparecer una segunda deflexión positiva en las derivaciones que observan el lado derecho del corazón.

En el bloqueo completo, el ECG presenta un QRS de al menos 120 ms, patrones como rsR prima o rSR prima en V1 o V2 y una onda S ensanchada en derivaciones laterales [3]. Estos criterios describen un problema de conducción eléctrica y algunos de sus rasgos visuales también aparecen en patrones asociados al síndrome de Brugada.

Como una forma semejante en una sola derivación no basta para diagnosticar el bloqueo, también deben valorarse la duración global del QRS, las derivaciones I y V6, la posición de los electrodos y otras causas de retraso terminal. Por ello, en esta memoria RBBB identifica únicamente un rasgo visual compatible, que también puede recordar al patrón tipo 1 de Brugada. A diferencia del bloqueo, este patrón concentra su onda J en las precordiales derechas y no requiere una onda S lateral recíproca [10]. La Figura 3.4 resume los rasgos considerados.

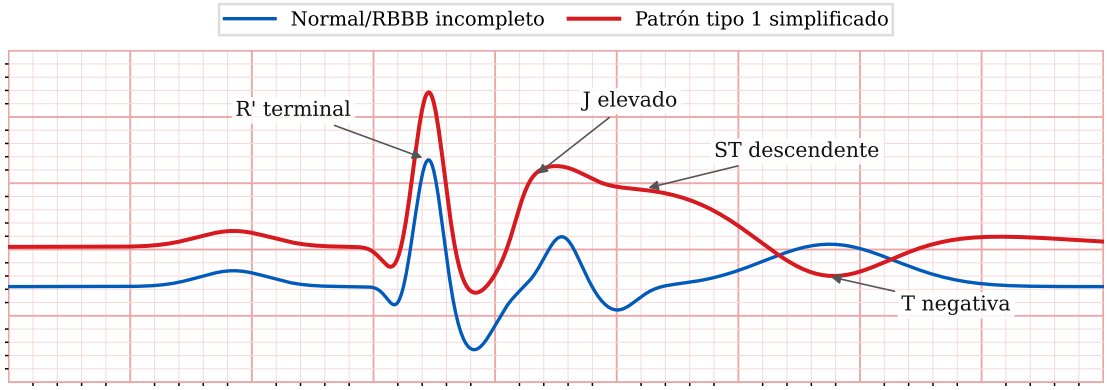


Figura 3.4.- Representación esquemática de rasgos morfológicos asociados al patrón tipo 1 del síndrome de Brugada.

3.2.3.- Elevación del ST e inversión de T

El ST se extiende desde J hasta el inicio de T. Su desplazamiento se mide respecto de la línea isoeléctrica, aproximada por TP o PR según el registro. La interpretación depende de la derivación, la magnitud y forma de la elevación, su distribución, la edad, el sexo y el cuadro clínico [4]. Puede aparecer en isquemia aguda, pericarditis, repolarización precoz, alteraciones de conducción y síndromes de onda J.

La polaridad de T varía entre derivaciones y con la edad y el sexo. También puede cambiar de forma secundaria a una despolarización anómala, con alteraciones discordantes del ST y de T. Una T negativa aislada no permite determinar si es primaria, secundaria, fisiológica o

patológica.

La elevación del ST o la inversión de T pueden deberse a distintas causas, por lo que distinguir Brugada de otras enfermedades exige valorar el ECG completo junto con la información clínica. Las etiquetas del simulador se limitan a describir esas formas visibles, sin asignarles por sí solas un diagnóstico.

3.3.- SEÑAL DIGITAL E IMAGEN

La señal digital conserva las amplitudes ordenadas en el tiempo, de modo que pueden filtrarse, medirse intervalos y compararse derivaciones con una escala conocida. Al representarla como imagen se mantiene la forma del trazado, pero se incorporan también la cuadrícula, el grosor de la línea, los márgenes y la distribución sobre el documento. Estos elementos pueden influir en la clasificación si se repiten más en una clase que en otra, aunque no correspondan a una alteración cardíaca.

Por ello, cuando solo se dispone de un documento, hay que elegir entre analizar su imagen o reconstruir primero la señal mediante digitalización. La segunda opción permite reutilizar modelos temporales, aunque puede introducir errores si los trazos se solapan o la calidad es insuficiente, mientras que el análisis directo debe distinguir las ondas de los elementos del fondo. La sección 2.1 recoge los estudios que comparan estas alternativas.

3.4.- CLASIFICACIÓN Y SALIDA DE LOS MODELOS

En clasificación multiclase las categorías son exclusivas. En clasificación multietiqueta pueden coexistir, como ocurre con los rasgos del ECG [45]. Para una imagen x y L etiquetas se define

$$\mathbf{y} = (y_1, \ldots, y_L), \qquad y_j \in \{0, 1\}. \tag{3.1}$$

La red produce un logit z_j por etiqueta, una puntuación numérica que puede tomar cualquier valor real. La función sigmoide lo transforma en una probabilidad entre cero y uno mediante la expresión

$$\hat{p}_j = \frac{1}{1 + \exp(-z_j)}. \tag{3.2}$$

La entropía cruzada binaria (BCE) es la función de pérdida que mide la discrepancia entre las probabilidades predichas y las etiquetas. Se utiliza para ajustar el modelo y se calcula como

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{L} \sum_{j=1}^{L} \left[y_j \log(\hat{p}_j) + (1 - y_j) \log(1 - \hat{p}_j) \right]. \tag{3.3}$$

Aunque la red produzca una salida por rasgo, todas se obtienen a partir de la misma imagen y pueden aprovechar asociaciones entre etiquetas. Si, por ejemplo, las T negativas apareciesen siempre junto con elevación del ST, el modelo podría predecir la primera a partir de la segunda sin examinar su región, por lo que acertar ambas etiquetas no demuestra que reconozca cada onda de forma independiente.

Para evaluar estas salidas, sus probabilidades se convierten en decisiones mediante un umbral elegido con los pacientes de validación y mantenido durante la prueba. Ajustarlo con los casos que se evalúan permitiría favorecer el resultado después de conocer sus respuestas, de ahí la separación descrita en la sección 6.1.2. En Gemma 4, la respuesta llega como texto estructurado y se transforma en las mismas etiquetas positivas o negativas para poder calcular las métricas de ambos métodos.

3.5.- REDES NEURONALES CONVOLUCIONALES

Una CNN combina capas convolucionales, que aprenden filtros para detectar formas, con funciones de activación, operaciones que reducen la resolución y una salida de clasificación. En este trabajo, esas capas procesan la imagen del ECG, donde las primeras pueden detectar bordes y cambios de dirección del trazo, mientras que las siguientes reúnen esa información para representar picos, valles y relaciones entre ondas. La convolución aplica un mismo filtro en distintas posiciones, por lo que no necesita aprender por separado una forma cada vez que aparece desplazada.

En una señal digital se utilizan filtros unidimensionales que, al apilarse las capas, abarcan intervalos temporales cada vez mayores. En la imagen, el recorrido es espacial, pero sigue siendo importante conservar la posición de las ondas, porque una deflexión negativa no significa lo mismo dentro del QRS que en T. Por ello, la tolerancia a pequeños desplazamientos debe combinarse con un preprocesamiento que alinee los latidos sin borrar sus relaciones temporales.

ResNet18 incorpora conexiones residuales que suman la entrada de un bloque a su transformación y permiten entrenar la red aprendiendo cambios sobre esa entrada [39]. El modelo parte de pesos aprendidos con ImageNet y se comprueba experimentalmente si esos filtros resultan útiles para reconocer los trazos y texturas del ECG. La adaptación de la salida a las tareas del simulador y del HUCA se describe en la sección 6.1.1.

3.6.- EXPLICABILIDAD Y ADAPTACIÓN DE DOMINIO

La inteligencia artificial explicable, o *explainable AI* (XAI), estudia cómo examinar las decisiones de un modelo para que una persona pueda valorar en qué información se apoyan. En el análisis de ECG interesa comprobar si la clasificación se relaciona con las ondas relevantes o con elementos del documento, como la cuadrícula y los márgenes, antes de atribuirle una interpretación clínica.

Para inspeccionar la CNN se utiliza Grad-CAM, que construye un mapa de regiones asociadas a una predicción ponderando las activaciones de una capa convolucional con los gradientes de la clase [40]. Así puede observarse si la respuesta se concentra alrededor del QRS, del ST o de T, aunque la resolución del mapa depende de la capa elegida y puede abarcar una zona amplia alrededor de un artefacto. Esta inspección ayuda a detectar comportamientos sospechosos, pero no permite asegurar por sí sola qué rasgo clínico determinó el resultado.

En un modelo de visión y lenguaje también puede solicitarse una explicación escrita, pero que resulte comprensible no garantiza que describa el proceso que produjo la predicción. Por eso se distinguen las etiquetas estructuradas utilizadas para evaluar el rendimiento de las justificaciones examinadas de forma cualitativa.

Esta precaución también importa al cambiar de conjunto de datos, porque la red puede aprender el estilo de representación en lugar de la forma de las ondas. La adaptación de dominio intenta reducir esa diferencia cuando se pasa de los latidos alineados y las cuadrículas uniformes del simulador a ECG con ruido, deriva de línea base, variación de frecuencia, anotaciones y trazos superpuestos. El capítulo 5 describe los controles del generador y la sección 6.1.3, los métodos empleados para estudiar ese cambio.

3.7.- MODELOS DE VISIÓN Y LENGUAJE Y APRENDIZAJE EN CONTEXTO

Un modelo de visión y lenguaje (VLM) combina un componente que procesa imágenes con un modelo generativo de texto. El componente visual transforma la imagen en vectores numéricos que representan su contenido y que el modelo relaciona con las instrucciones escritas. El entrenamiento multimodal permite aprender asociaciones entre imágenes y texto, de modo que una consulta puede pedir una descripción, una respuesta a una pregunta o una clasificación [24].

Al analizar un ECG, la imagen aporta el trazado y las instrucciones indican qué debe examinarse y cómo expresar la respuesta. Así, el mismo modelo puede recibir preguntas sobre la forma de las ondas o responder con una etiqueta, según la tarea planteada.

El aprendizaje en contexto (ICL) incorpora además ejemplos resueltos a la consulta. En su versión multimodal, cada demostración reúne una imagen y su etiqueta, con las que se muestra al modelo el criterio de clasificación y el formato esperado de la respuesta [23]. Las demostraciones, las instrucciones y la imagen que debe clasificarse forman el contexto disponible para generar esa respuesta. La Figura 3.5 ilustra el esquema general con una tarea de texto. Formalmente,

$$\mathcal{D}_K = \{(x_1, y_1), \ldots, (x_K, y_K)\}, \tag{3.4}$$

y predice la salida de x^* condicionada por esos ejemplos y la instrucción mediante

$$\hat{y}^* = f_\theta\left(x^*, \mathcal{D}_K, \text{instrucción}\right). \tag{3.5}$$

Durante la consulta, los parámetros θ permanecen fijos y la respuesta se adapta a los ejemplos presentes en el contexto. En cambio, el entrenamiento supervisado de la CNN incorpora los ejemplos mediante la actualización de sus pesos. K indica cuántas demostraciones recibe el VLM, aunque su selección, diversidad, orden y correspondencia entre imagen y etiqueta también afectan a la consulta. Los estudios sobre estos factores se recogen en la sección 2.4.

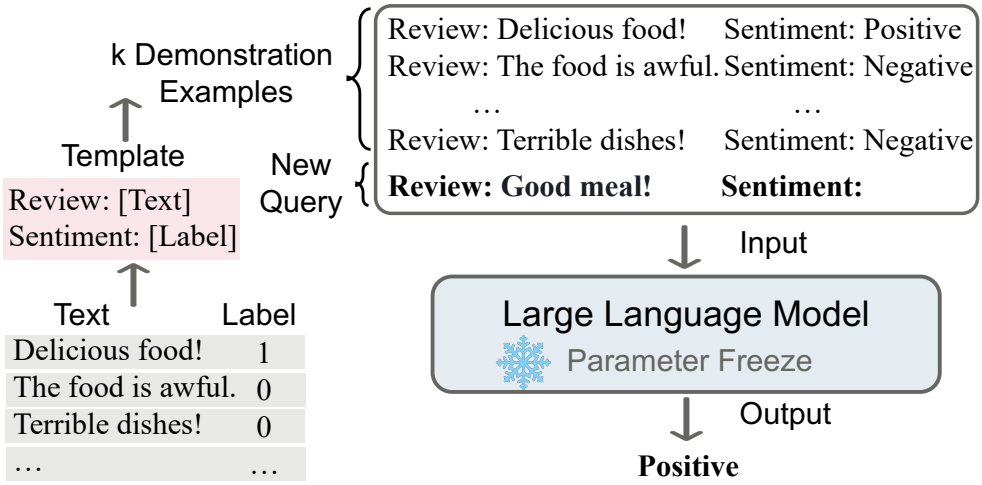


Figura 3.5.- Esquema de demostraciones y consulta en ICL, basado en Dong y colaboradores [23].

Capítulo 4. Diseño experimental

El experimento compara una CNN entrenada de forma supervisada con Gemma 4 mediante aprendizaje en contexto con la misma entrada, una imagen V1 por paciente, y las mismas métricas. La Figura 4.1 muestra el proceso.

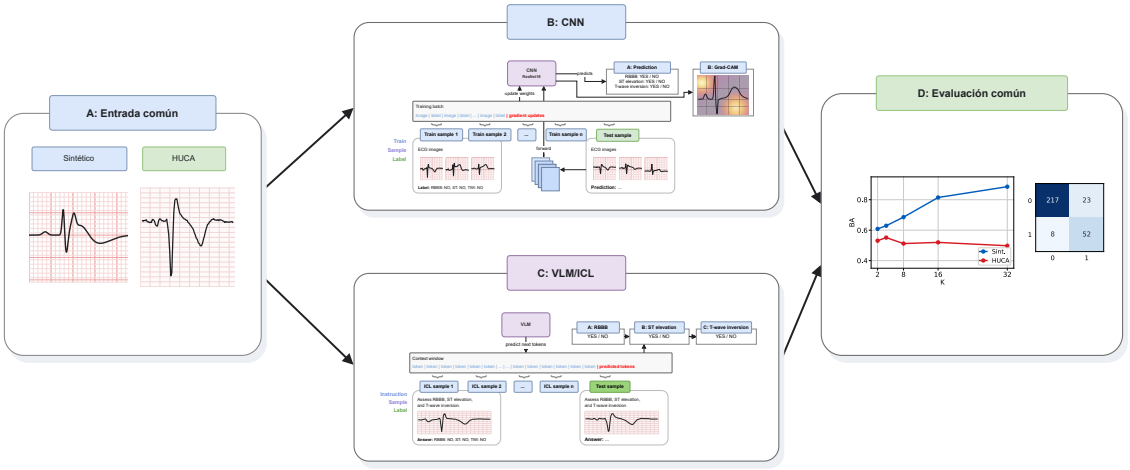


Figura 4.1.- Diseño experimental con preparación de imágenes, entrenamiento de la CNN o consulta de Gemma 4 y evaluación por paciente.

4.1.- DATOS Y TAREAS

La Tabla 4.1 recoge los dos conjuntos. En el simulador, un caso es positivo si presenta simultáneamente RBBB, elevación del ST e inversión de T. En el HUCA se utiliza una etiqueta binaria que indica la presencia o ausencia de Brugada según los datos facilitados para el estudio, sin identificar por separado los tres rasgos del trazado.

Conjunto	Pacientes	Imágenes	Positivos	Negativos	Etiqueta
Simulador QRS/ST	100	100	20	80	Presencia de los tres rasgos
Datos HUCA	317	317	116	201	Etiqueta clínica

Tabla 4.1.- Conjuntos finales. Cada paciente aporta una imagen V1.

El capítulo 5 describe el generador. Las señales clínicas proceden de Brugada-HUCA [47]. Por recomendación de los médicos colaboradores, se excluyeron 46 de los 363 pacientes iniciales cuya clasificación todavía no estaba clara al preparar el estudio, para evitar que esos casos dudosos condicionaran la comparación. En los 317 restantes se selecciona V1,

se detecta un latido central y se recorta desde 300 ms antes de R hasta 600 ms después. El apéndice A recoge los parámetros completos.

La Figura 4.2 ilustra las diferencias de forma entre un latido del simulador y un trazado clínico del HUCA.

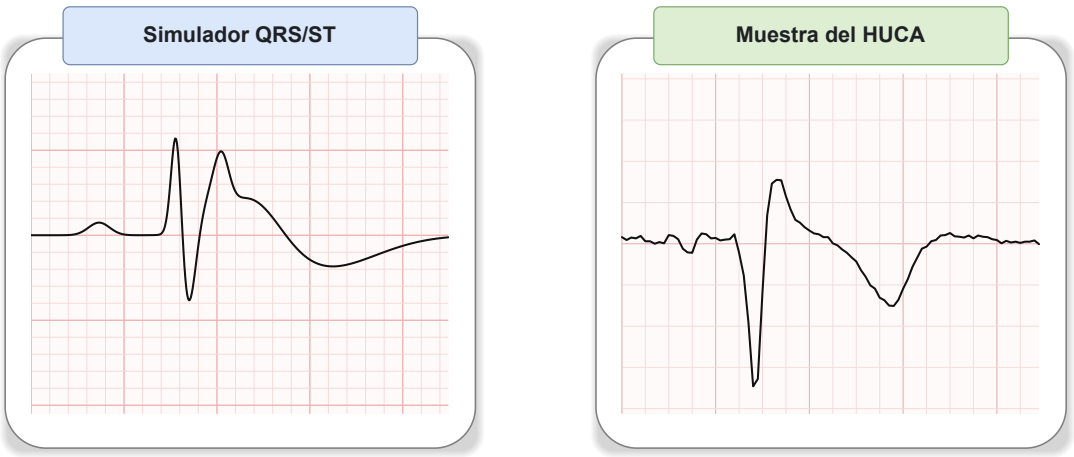


Figura 4.2.- Ejemplo del simulador y trazado clínico V1.

4.1.1.- Características de la muestra del HUCA

La muestra utilizada contiene 116 pacientes etiquetados como positivos y 201 como negativos. Esta distribución desigual hace necesario valorar por separado los aciertos en cada clase, ya que predecir siempre la más frecuente produciría una proporción de aciertos elevada sin detectar ningún positivo.

Aunque la preparación de los registros permite obtener imágenes de V1, V2 y V3, todos los experimentos de la memoria utilizan únicamente V1 y, por tanto, una imagen por paciente. Su elección se apoya en la relevancia de las precordiales derechas para estudiar Brugada, ya que V1 y V2 recogen los cambios del ST y de T con los que la literatura caracteriza el patrón tipo 1 [1]. Los ECG clínicos presentan más variación de forma, ruido y cuadrícula que los latidos generados, como ilustra la Figura 4.2.

4.2.- ESCENARIOS DE COMPARACIÓN

Se evalúan los siguientes tres escenarios.

1. **Aprendizaje con el simulador.** La CNN se entrena con las tres etiquetas morfológicas y se prueba con otros casos generados. Gemma 4 recibe ejemplos del mismo origen.

2. **Transferencia del simulador al HUCA.** La CNN entrenada con el simulador se prueba con ECG clínicos. Gemma 4 recibe ejemplos del simulador y clasifica consultas clínicas.

3. **Aprendizaje con pacientes del HUCA.** Una segunda CNN se entrena directamente con la etiqueta clínica. Gemma 4 recibe demostraciones de la misma muestra.

4.3.- SELECCIÓN DE EJEMPLOS Y VALIDACIÓN

Se utiliza validación *leave-one-out* por paciente (LOOCV), de modo que en cada repetición o pliegue se reserva un paciente para la prueba y se seleccionan los ejemplos entre los restantes, sin incluirlo en el entrenamiento, la validación ni las demostraciones de Gemma 4.

Se prueban $K = \{2, 4, 8, 16, 32\}$ pacientes de entrenamiento para la CNN y el mismo número de demostraciones para Gemma 4. Cada configuración se repite con las semillas 42, 123 y 2026, que fijan la selección aleatoria de pacientes y, en la CNN, la aleatoriedad del entrenamiento. Ambos métodos se evalúan sobre los mismos pacientes y seleccionan sus ejemplos del mismo conjunto disponible.

En las variantes de adaptación de dominio desde el simulador al HUCA, el modelo también puede utilizar imágenes del HUCA sin sus etiquetas, incluidas imágenes que después se evalúan. Este uso se detalla en la sección 6.1.3 y en la Tabla A.4.

La CNN entrenada con el HUCA reserva además ocho pacientes etiquetados, cuatro por clase y distintos de los de entrenamiento y prueba, para elegir el umbral y detener el ajuste cuando deja de mejorar, mediante *early stopping*. Gemma 4 no utiliza este grupo adicional.

4.3.1.- Secuencia de un pliegue clínico

La Figura 4.3 resume el pliegue clínico. En cada pliegue se crea una CNN nueva a partir de los pesos iniciales, sin continuar el entrenamiento del pliegue anterior. Después de ajustar y seleccionar el modelo, se predice al paciente reservado y se registra el resultado antes de pasar al siguiente.

Gemma 4 prepara una consulta nueva para ese mismo paciente. Las demostraciones llevan sus respuestas, pero la imagen final no incluye su etiqueta. La respuesta generada se compara con ella al calcular las métricas.

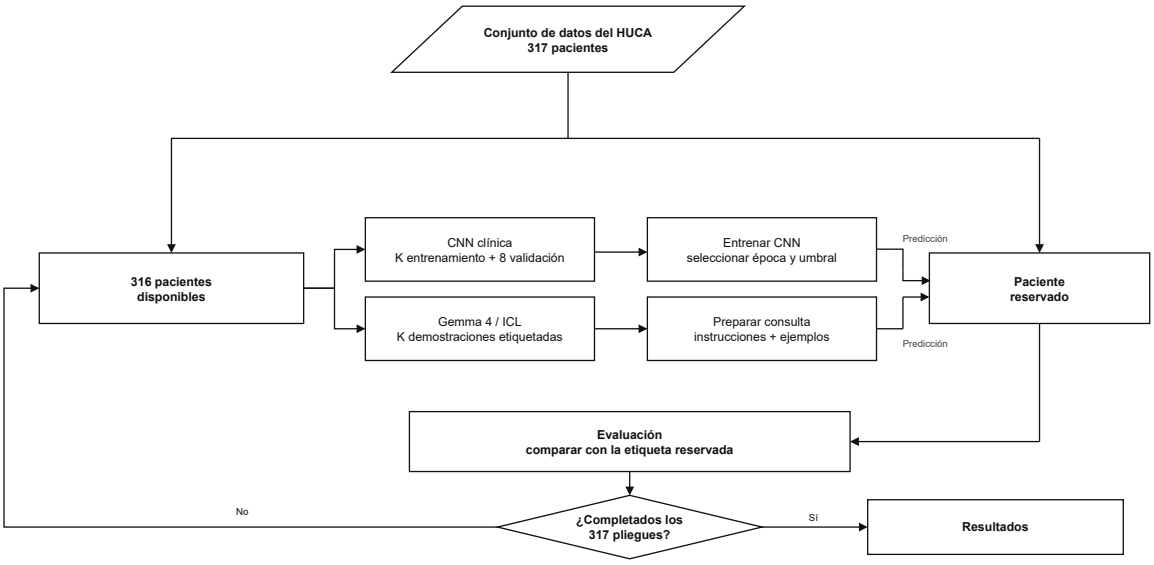


Figura 4.3.- Operaciones de un pliegue de la comparación con los datos clínicos del HUCA.

La CNN utiliza $K + 8$ pacientes etiquetados por pliegue, diez cuando $K = 2$ y cuarenta cuando $K = 32$, frente a los dos y treinta y dos que recibe Gemma 4, respectivamente. Esta diferencia procede de los ocho pacientes de validación, que intervienen en la selección de época y umbral y quedan fuera de la actualización de pesos. Al combinar las condiciones estándar y balanceada descritas a continuación con cinco valores de K y tres semillas, la evaluación de la CNN con el HUCA comprende 30 ejecuciones de 317 pliegues.

4.3.2.- Distribución de los ejemplos por clase

En ambos conjuntos predominan los casos negativos, por lo que el reparto de clases entre los pocos ejemplos disponibles puede influir en el aprendizaje. Para estudiar este efecto se comparan dos formas de selección. La estándar asegura, para $K \geq 2$, un positivo y un negativo y completa el grupo de forma seudoaleatoria entre los pacientes restantes. La balanceada busca que la mitad de los ejemplos sean positivos y la otra mitad negativos y, si faltan casos de una clase, completa el grupo con la otra.

Estas condiciones se estudian en las demostraciones de Gemma 4 y en el entrenamiento de la CNN con el HUCA. Para esta CNN, la selección estándar conserva los pacientes del plan de pliegues, mientras que la balanceada mantiene sus ocho pacientes de validación y vuelve a elegir el entrenamiento entre los restantes. Gemma 4 selecciona sus demostraciones directamente entre los pacientes disponibles para el contexto, de modo que cada método aplica el reparto por clase a su propio grupo de candidatos.

Además, se estudia el caso *zero-shot* de Gemma 4, con $K = 0$, en el que se mantienen las instrucciones y la imagen que debe clasificarse y se retiran las demostraciones. Esta condición

permite comparar el comportamiento del modelo sin ejemplos con el obtenido al incorporar las selecciones estándar y balanceada. Cuando $K > 0$, el origen de los ejemplos depende del escenario de la sección 4.2.

4.4.- MÉTRICAS Y AGREGACIÓN

La exactitud balanceada (BA) promedia sensibilidad y especificidad y da igual peso a las clases mediante la expresión

$$\text{BA} = \frac{1}{2}\left(\frac{TP}{TP+FN} + \frac{TN}{TN+FP}\right).$$

La sensibilidad y la especificidad son las proporciones de positivos y negativos bien clasificados, respectivamente. TP y TN cuentan esos aciertos. Los falsos negativos (FN) son positivos clasificados como negativos y los falsos positivos (FP), negativos clasificados como positivos.

F1 es la media armónica de precisión y sensibilidad. La precisión indica la proporción de predicciones positivas correctas. El área bajo la curva ROC (ROC-AUC) resume la separación entre clases al variar el umbral. La precisión media resume la precisión obtenida a distintos niveles de sensibilidad. Las matrices de confusión cruzan etiquetas y predicciones para separar aciertos y errores [50, 48, 49].

Para el triaje se interpretan juntas sensibilidad y especificidad, porque detectar más positivos puede aumentar falsas alertas y carga de revisión, especialmente con baja prevalencia.

Capítulo 5. El simulador QRS/ST

5.1.- OBJETIVO DEL SIMULADOR

El simulador construye latidos de apariencia precordial a partir de curvas gaussianas cuyos parámetros controlan la forma de las ondas. Su objetivo es producir ejemplos en los que puedan reconocerse RBBB, elevación del ST e inversión de T, así como combinaciones de estos rasgos. Cada señal se acompaña de las etiquetas obtenidas al comprobar su forma, lo que permite preparar ejemplos para entrenar la CNN y demostraciones para Gemma 4 sin depender de un conjunto de datos clínicos extenso.

La generación permite variar la amplitud, la posición y la anchura de los componentes y obtener conjuntos de tamaño y semilla conocidos, manteniendo un formato de imagen común. Así se puede estudiar qué cambios del trazado aprende cada modelo en unas condiciones controladas y comprobar después cómo responde ante ECG del HUCA, donde intervienen también diferencias de adquisición y presentación.

5.2.- REPRESENTACIÓN MATEMÁTICA

Cada latido se expresa como la suma de diez átomos gaussianos. Un átomo es aquí una curva elemental que contribuye a formar una onda o una parte de ella. En el átomo i, la amplitud a_i, el centro temporal μ_i y la anchura σ_i definen la función

$$g_i(t) = a_i \exp\left(-\frac{(t-\mu_i)^2}{2\sigma_i^2}\right). \tag{5.1}$$

La señal completa es

$$x(t) = \sum_{i=1}^{M} g_i(t), \qquad M = 10. \tag{5.2}$$

El signo de a_i determina la dirección de la deflexión y su valor absoluto, la magnitud. El parámetro μ_i sitúa el componente en el eje temporal, mientras que σ_i controla su extensión. Al sumar los átomos se obtienen transiciones suaves y sin discontinuidades.

A diferencia del modelo dinámico de Sayadi y colaboradores [18], el generador suma directamente los componentes. Cada parámetro modifica una región identificable del latido.

Átomo	Región principal	Función dentro del generador
`P`	Onda P	Añade una deflexión auricular positiva anterior al QRS
`Q`	Inicio del QRS	Permite una pequeña deflexión negativa, aunque la configuración actual la mantiene anulada
`R`	QRS inicial	Produce el primer máximo positivo ventricular
`S`	QRS central	Forma la deflexión negativa posterior a R
`R_prime`	QRS terminal	Introduce un segundo máximo positivo y permite una forma RSR prima
`J_elev`	Punto J	Controla la transición entre el final del QRS y el segmento ST
`ST1`	ST inicial	Modela elevación temprana y la parte descendente de una forma cóncava
`ST2`	ST tardío	Controla la continuidad hacia la onda T
`T1`	Onda T principal	Define la polaridad y la magnitud principal de la repolarización
`T2`	Cola de la onda T	Suaviza y prolonga la repolarización

Tabla 5.1.- Átomos utilizados para construir un latido generado por el simulador

La Figura 5.1 muestra cómo se combinan los átomos de la Tabla 5.1.

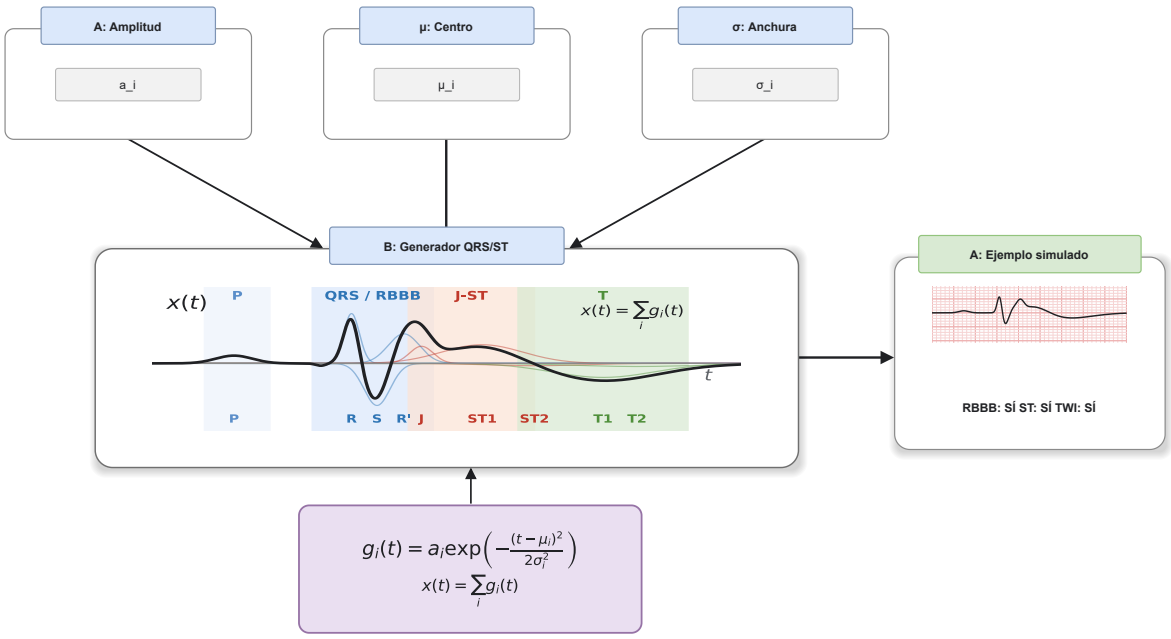


Figura 5.1.- Generador gaussiano de un latido del simulador. Los parámetros de cada átomo fijan su amplitud, posición y anchura antes de sumar las regiones P, QRS, ST y T.

5.3.- MUESTREO TEMPORAL

La configuración final utiliza una frecuencia de 500 Hz y una duración de 900 ms. El número de muestras se calcula como

$$N = \text{round}\left(\frac{D}{1000} f_s\right), \tag{5.3}$$

donde D es la duración en milisegundos y f_s la frecuencia de muestreo. Con los valores finales se obtienen 450 muestras. El vector temporal es

$$t_n = \frac{1000n}{f_s}, \qquad n \in \{0, \ldots, N-1\}. \tag{5.4}$$

Los rangos de repolarización se definieron para una duración de referencia de 900 ms. Cuando cambia la duración del latido, los centros posteriores a 390 ms se adaptan mediante

$$\mu_i^{(D)} = 390 + \left(\mu_i^{(900)} - 390\right) \frac{D - 390}{900 - 390}. \tag{5.5}$$

Las anchuras de los componentes tardíos se escalan con el mismo factor y tienen un mínimo para evitar gaussianas degeneradas. Los componentes anteriores a 390 ms permanecen fijos, de modo que el QRS conserva su posición y las regiones ST y T se ajustan a la duración disponible.

5.4.- FAMILIAS GENERADORAS

El simulador organiza la generación en cinco grupos de latidos, denominados familias, según la forma que se quiere obtener. Una familia reúne los ajustes de los componentes gaussianos necesarios para favorecer un trazado normal, una alteración concreta o una combinación de rasgos. A partir de esos ajustes se generan señales con pequeñas variaciones de amplitud, posición y anchura, y los validadores comprueban después qué etiquetas corresponden al latido completo. Así, cada familia orienta la forma de la señal y permite obtener ejemplos distintos dentro del mismo grupo.

5.4.1.- Familia normal

La familia `NORMAL` reduce la amplitud de R prima, mantiene las regiones J y ST próximas a la línea base y genera ondas T positivas. Además, rechaza cualquier señal que active alguno de los tres validadores morfológicos. Esta comprobación evita que una combinación obtenida por azar dentro de los rangos normales supere uno de sus umbrales.

5.4.2.- Morfología RBBB

La familia `RBBB` favorece una segunda deflexión positiva cuyo centro se sitúa al menos 24 ms después de S. Dentro de los límites permitidos, R prima alcanza como mínimo el 80 por ciento de la amplitud de R y es más ancha que esta.

La etiqueta sigue el uso morfológico de RBBB definido en la sección 3.2.

5.4.3.- Elevación de ST

La familia `ST_ELEVATION` asigna amplitudes positivas al punto J y a los dos componentes del ST. La primera sección del segmento se ensancha para que no adopte la forma de un pico estrecho confundible con una deflexión del QRS. El validador también exige actividad ventricular positiva y negativa suficiente, lo que permite descartar señales planas desplazadas hacia valores altos.

5.4.4.- Inversión de T

La familia `T_WAVE_INVERSION` hace negativos los dos componentes de T y los separa de la región ST. Puede generar, además, una R prima moderada y una pequeña elevación de J, lo que permite coocurrencias con RBBB y elevación del ST. Para aceptar la señal, la deflexión negativa debe aparecer tarde, alcanzar una profundidad mínima y mantenerse durante un intervalo suficiente.

5.4.5.- Familia asociada al síndrome de Brugada

La familia `BRUGADA` representa de forma esquemática un patrón tipo 1 mediante elevación del punto J, un segmento ST descendente e inversión de T. Su R prima tiene menor amplitud que en la familia RBBB, aunque puede conservar una alteración terminal del QRS.

La Tabla 5.2 resume las modificaciones de cada familia. La familia compuesta puede reservarse para transferencia.

Familia	Modificación dominante	Interpretación experimental
NORMAL	ST próximo a cero, T positiva y R prima mínima	Referencia sin los rasgos evaluados
RBBB	Segundo pico positivo tardío y ancho	Componente terminal del QRS
ST elevado	Punto J y ST positivos	Componente de elevación posterior al QRS
Inversión de T	Repolarización tardía negativa	Componente de inversión de T
BRUGADA	J elevado, ST descendente y T negativa	Familia compuesta reservable para transferencia

Tabla 5.2.- Relación entre familias generadoras y rasgos favorecidos

5.5.- RANGOS DE PARÁMETROS

Para fijar los rangos de los parámetros se ha contado con la colaboración de profesionales del HUCA. Sus indicaciones han orientado la elección de amplitudes, posiciones y anchuras con el propósito de obtener latidos de aspecto verosímil en los que puedan reconocerse los rasgos estudiados.

Las orientaciones se trasladan a intervalos para a, μ y σ, que se ajustan según la familia seleccionada. Dentro de esos intervalos se introducen variaciones para obtener diferentes ejemplos de cada forma, mientras que las reglas de coherencia mantienen el orden de las ondas y los validadores comprueban los rasgos presentes en la señal final. De este modo, el ajuste de los parámetros permite mejorar el parecido visual conservando una asignación de etiquetas común para todo el conjunto.

5.6.- REGLAS DE COHERENCIA MORFOLÓGICA

El muestreo independiente de los átomos puede alterar el orden temporal de las ondas. Para evitarlo, antes de sumar las gaussianas se imponen varias relaciones. Q precede a R. S aparece después de R y tiene mayor anchura. J se sitúa después de S. Los dos componentes del ST se ordenan tras J, y T1 y T2 ocupan la región final.

Cada familia añade restricciones como la posición tardía de R prima o el signo negativo de T.

Un cambio en una regla puede afectar a varias etiquetas. Por ejemplo, desplazar T1 modifica el validador de inversión y la media tardía del ST, por lo que cada ajuste exige revisar las frecuencias y la tasa de aceptación.

La Figura 5.2 resume las combinaciones de etiquetas presentes en el conjunto del simulador.

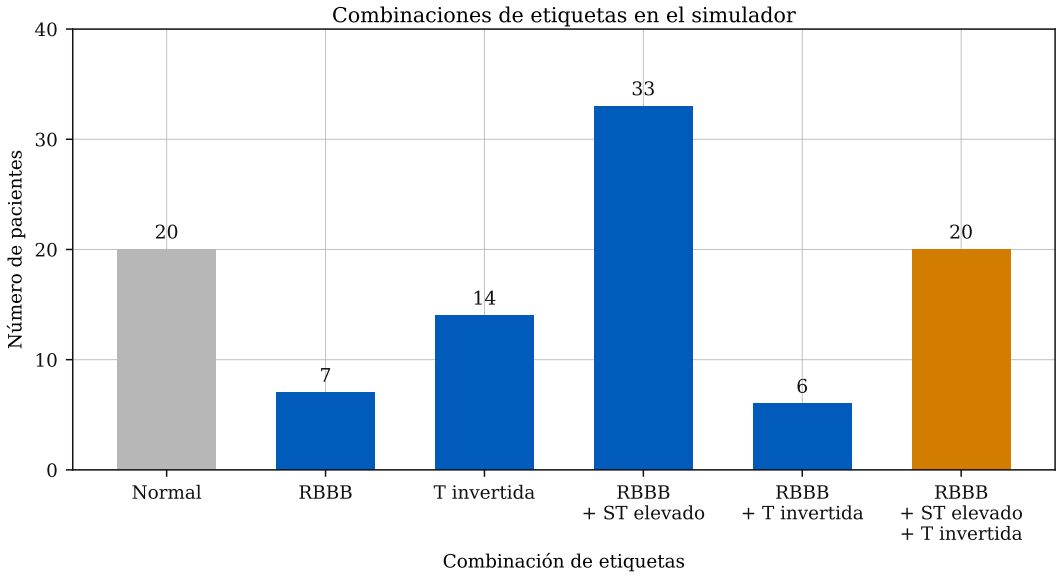


Figura 5.2.- Distribución de combinaciones de etiquetas derivadas en el conjunto del simulador LOOCV.

5.7.- MUESTREO CON RECHAZO

La generación utiliza muestreo con rechazo. Para una familia c, el procedimiento consta de los siguientes pasos.

1. Combinar los rangos base con los rangos específicos de c.
2. Adaptar los componentes tardíos a la duración solicitada.
3. Muestrear los parámetros de los diez átomos.
4. Aplicar las reglas de orden y coherencia.
5. Sumar los átomos sobre el vector temporal.
6. Evaluar el validador correspondiente a c.
7. Aceptar la señal si supera las reglas o volver al paso de muestreo.

El generador admite un máximo de 400 intentos. Si no encuentra una señal válida, devuelve un error y conserva las últimas métricas.

Sea q_c la probabilidad de aceptación de una propuesta de la familia c. El número esperado de intentos antes de una aceptación es aproximadamente

$$\mathbb{E}[A_c] = \frac{1}{q_c}. \tag{5.6}$$

Una tasa de aceptación baja indica que gran parte del espacio paramétrico queda fuera de la definición de la etiqueta. Por eso forma parte de la revisión del generador.

5.8.- VALIDADORES Y ASIGNACIÓN DE ETIQUETAS

Los validadores analizan ventanas temporales de la señal completa. Las situadas después de 390 ms se adaptan mediante la ecuación 5.5. Las amplitudes se expresan en mV y las duraciones, en ms.

Validador	Condiciones necesarias
RBBB	Dos máximos positivos entre 240 y 470 ms, separación mínima de 28 ms, primer máximo superior a 0,12 mV, segundo máximo superior a 0,20 mV, mínimo intermedio inferior a $-0,05$ mV, segundo máximo posterior a 345 ms y anchura terminal superior a 38 ms por encima de 0,10 mV
Elevación de ST	Máximo del QRS superior a 0,28 mV, mínimo del QRS inferior a $-0,14$ mV, media de J superior a 0,09 mV y media del ST superior a 0,09 mV
Inversión de T	Máximo del QRS superior a 0,22 mV, máximo de R prima superior a 0,08 mV, media del ST superior a $-0,03$ mV, mínimo de T inferior a $-0,12$ mV, mínimo posterior al umbral temporal equivalente a 640 ms y más de 45 ms por debajo de $-0,05$ mV
Normal	Máximo del QRS superior a 0,22 mV, mínimo inferior a $-0,10$ mV, media de ST entre $-0,04$ y 0,05 mV, máximo de T superior a 0,12 mV, R prima inferior a 0,10 mV y rechazo de los tres rasgos
Síndrome de Brugada	Máximo del QRS superior a 0,18 mV, mínimo inferior a $-0,16$ mV, media de J superior a 0,09 mV, media de ST superior a 0,08 mV, ST temprano al menos 0,03 mV por encima del ST tardío y mínimo de T inferior a $-0,08$ mV

Tabla 5.3.- Criterios de los validadores del simulador

La Tabla 5.3 contiene los umbrales experimentales. Tras aceptar una señal, se calculan sus tres etiquetas sobre el trazado completo, con independencia de la familia, permitiendo así la aparición de combinaciones parciales.

5.9.- RENDERIZADO Y CONTROLES VISUALES

Cada latido se representa en un lienzo cuadrado de 896 por 896 píxeles y 130 puntos por pulgada. En el eje horizontal, la cuadrícula menor marca intervalos de 40 ms y la mayor, de 200 ms. En el eje vertical, las divisiones corresponden a 0,1 y 0,5 mV, respectivamente. La señal se dibuja en negro con un grosor de dos puntos y la cuadrícula, en dos tonos de rosa.

Se conservan títulos y valores de los ejes, con límites horizontales y verticales comunes. Se comprueba que ninguna familia tenga un encuadre, margen o marcas propios. Los nombres de archivo no indican la clase y el modelo accede a las imágenes mediante el manifiesto, sin conocer la familia.

Los reflejos horizontales invertirían el orden temporal y los verticales intercambiarían elevación y depresión, por lo que se excluyen. Las variaciones pequeñas de grosor, contraste, desplazamiento y escala deben conservar la forma de la señal. Los recortes del trazado y las versiones sin ejes sirven como controles de sensibilidad. La Figura 5.3 muestra un ejemplo de cada familia.

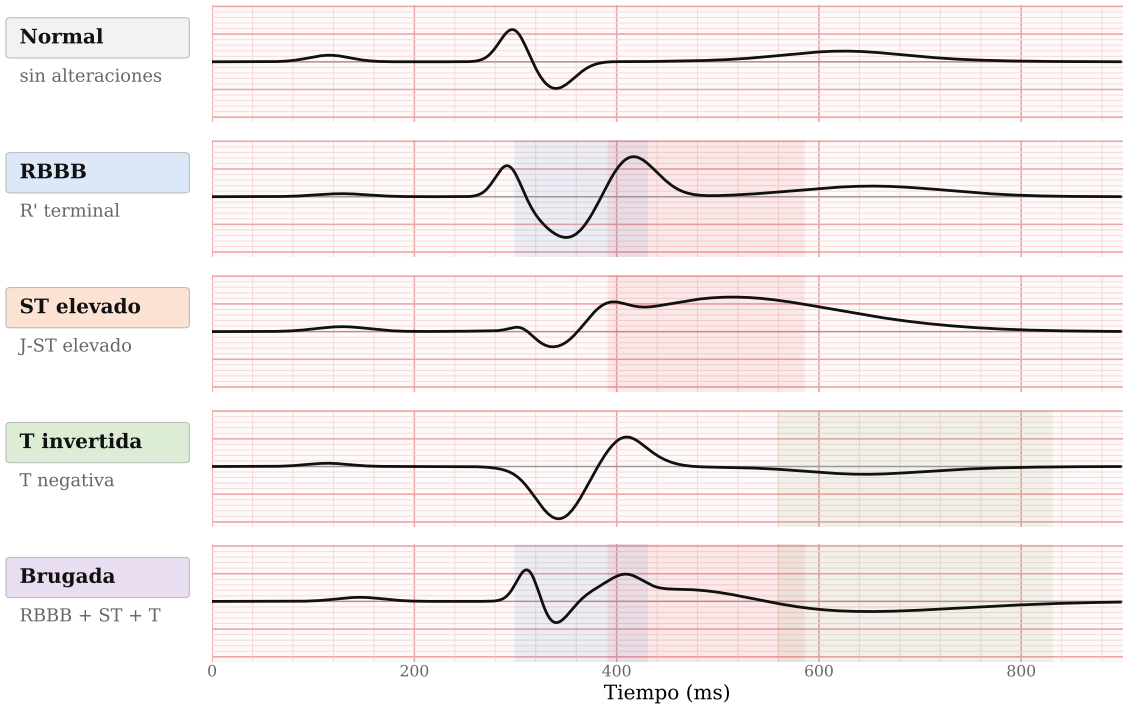


Figura 5.3.- Ejemplos generados por el simulador para validar visualmente sus familias.

Los controles visuales se complementan con la inspección Grad-CAM de la sección 6.1, para detectar activaciones en ejes, cuadrícula, antialiasing o fondo.

5.10.- LIMITACIONES DEL SIMULADOR

El simulador representa un latido aislado de apariencia precordial, por lo que su alcance se concentra en la forma local de las ondas. Quedan fuera la relación entre las doce derivaciones y los cambios de ritmo o de morfología entre latidos de un mismo registro. En particular, la familia asociada a Brugada aproxima algunos rasgos del patrón tipo 1 mediante la elevación de J, el descenso del ST y la inversión de T, mientras que los ECG reales pueden presentar formas más diversas y variaciones a lo largo del tiempo.

La suma de gaussianas produce curvas suaves y el formato de imagen es homogéneo, frente a los registros clínicos, que pueden contener ruido, deriva de línea base, anotaciones y trazos superpuestos. Las variaciones de grosor, contraste, posición o escala permiten examinar parte de estas diferencias visuales, aunque la generación sigue dependiendo de las formas y relaciones previstas al diseñarla.

Además, el muestreo con rechazo concentra los ejemplos en las regiones de parámetros aceptadas por los validadores. Esto puede hacer que un modelo aprenda regularidades propias del generador y obtenga buenos resultados con sus imágenes. Por ello, la evaluación con ECG del HUCA permite estudiar cuánto de ese aprendizaje se conserva al cambiar a registros de pacientes y qué diferencias requieren adaptación.

Capítulo 6. Dos enfoques de modelado

La ejecución de cada modelo sigue los escenarios y las particiones del capítulo 4. La configuración completa se recoge en el apéndice A.

6.1.- CNN RESNET18

6.1.1.- Arquitectura y entrenamiento

Las dos variantes utilizan ResNet18 preentrenada con ImageNet, una colección de imágenes de uso general [39]. Sus capas convolucionales extraen las características visuales y la última capa las transforma en las salidas de la tarea. En el simulador, esa capa se sustituye por tres salidas, correspondientes a RBBB, elevación del ST e inversión de T. Con los datos cedidos por el HUCA se utiliza una única salida, asociada a la etiqueta de Brugada. En ambos casos se ajustan todos los pesos, tanto del extractor como de la nueva capa de clasificación. La Figura 6.1 representa el entrenamiento y la predicción para el caso del simulador.

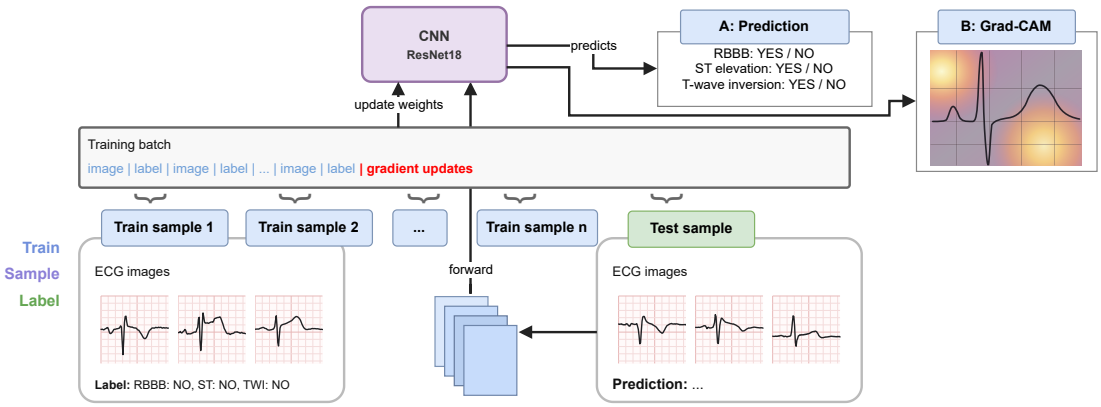


Figura 6.1.- Entrenamiento supervisado y evaluación de la CNN entrenada con el simulador.

Para presentar las imágenes a la red, se convierten a RGB, con tres canales de color, y se redimensionan a 224 por 224 píxeles. Esta conversión adapta el formato a la entrada de ResNet18 y mantiene el mismo trazado en los tres canales. A continuación se normalizan los píxeles con la media y la desviación calculadas únicamente sobre las imágenes de entrenamiento. Esos mismos valores se aplican a validación y prueba, por lo que los pacientes reservados no intervienen en la preparación de la entrada.

El entrenamiento busca que las salidas se aproximen a las etiquetas disponibles mediante la entropía cruzada binaria. En el simulador se calcula por separado para los tres rasgos, que pueden coexistir en una imagen, mientras que en los registros clínicos se aplica a su única etiqueta. Para compensar diferencias en su frecuencia, cada salida incorpora un peso positivo igual al número de negativos dividido entre el de positivos del entrenamiento utilizado. Así se aumenta la penalización de los errores en positivos cuando estos son menos frecuentes. Con la selección balanceada de los datos cedidos por el HUCA ese peso vale uno, porque ya se utiliza el mismo número de pacientes de cada clase.

Para reducir esta pérdida se emplea AdamW [46], que actualiza los pesos después de procesar cada lote de imágenes con una magnitud de ajuste regulada por la tasa de aprendizaje. Al recorrer todos los lotes se completa una época, tras la cual comienza un nuevo recorrido del conjunto de entrenamiento. La tasa de aprendizaje, el tamaño del lote y los demás parámetros utilizados se recogen en la Tabla A.3.

6.1.2.- Predicción y selección del umbral

Cada salida de la red es una puntuación, o *logit*, que la sigmoide transforma en una probabilidad entre cero y uno. En la CNN entrenada con el simulador se aplica por separado a las tres salidas, correspondientes a RBBB, elevación del ST e inversión de T, mientras que en la entrenada con los datos clínicos se aplica a la única puntuación asociada a Brugada, indicada con el subíndice B. Ambas operaciones se expresan como

$$\underbrace{p_j = \frac{1}{1+\exp(-z_j)}, \quad j=1,2,3}_{\text{Simulador}} \qquad \underbrace{p_B = \frac{1}{1+\exp(-z_B)}}_{\text{Datos clínicos}} \tag{6.1}$$

Los tres rasgos del simulador pueden coexistir, por lo que sus probabilidades no tienen que sumar uno. La clasificación positiva derivada se obtiene cuando las tres alcanzan el umbral, mientras que en los registros cedidos por el HUCA se compara con él la probabilidad p_B.

El umbral determina a partir de qué probabilidad se asigna una etiqueta positiva y se elige buscando la mayor BA en los pacientes de validación. En la CNN entrenada con el simulador, la regla conjunta se evalúa a partir de la menor de sus tres probabilidades, pues las tres deben alcanzar el mismo umbral.

En la CNN entrenada con los datos clínicos, la elección del umbral se integra en el seguimiento del entrenamiento. Al terminar cada época se predicen los ocho pacientes de validación definidos en la sección 4.3 y se obtiene la mejor BA con ese conjunto. Este resultado permite conservar los pesos que mejor clasifican a pacientes distintos de los utilizados para actualizarlos. El *early stopping* interrumpe el ajuste cuando transcurren cinco épocas sin

mejora, con un máximo de veinte, y se recuperan los pesos seleccionados para efectuar la predicción final.

Con esos pesos se fija el umbral a partir de los mismos pacientes de validación y se clasifica al paciente reservado para prueba. De este modo, los resultados agregados se construyen con las predicciones de prueba de cada pliegue.

6.1.3.- Adaptación de dominio

Se estudian cuatro variantes para aprovechar las imágenes cedidas por el HUCA al trasladar lo aprendido con el simulador, manteniendo la predicción de los tres rasgos. La primera utiliza **SimCLR** para preparar el extractor antes del ajuste supervisado. A partir de dos versiones aumentadas de cada imagen clínica, aprende representaciones que toleren cambios de brillo, pequeños desplazamientos, ruido y desenfoque. Los pesos obtenidos inicializan después la CNN que se entrena con las etiquetas del simulador.

CORAL y **MMD** incorporan la adaptación durante ese entrenamiento, combinando lotes etiquetados del simulador con imágenes clínicas sin etiquetas. Mientras la pérdida supervisada aprende a distinguir los rasgos, CORAL aproxima las covarianzas de las características de ambos conjuntos y MMD reduce su discrepancia mediante kernels de base radial a varias escalas. La contribución de estos objetivos aumenta progresivamente a lo largo del ajuste.

DANN utiliza también ambos conjuntos, pero añade un clasificador que intenta reconocer el origen de cada imagen. La inversión de gradiente orienta al extractor a dificultar esa distinción a la vez que aprende los rasgos del simulador. Esta rama auxiliar interviene durante el entrenamiento y se retira para predecir, conservando las tres salidas de la tarea.

En las cuatro variantes, las imágenes del conjunto clínico se comparten entre pliegues, incluidas las que después se evalúan, sin utilizar sus etiquetas para entrenar. Así se estudia el aprovechamiento de su apariencia, frente al ajuste supervisado con pacientes etiquetados descrito anteriormente. La Tabla A.4 reúne los parámetros de cada método y las condiciones de uso de los datos.

6.1.4.- Inspección con Grad-CAM

La inspección con Grad-CAM complementa las métricas con una representación de las regiones relacionadas con una salida de la CNN. En este trabajo se aplica al último bloque convolucional de ResNet18, antes de reducir las características a un vector para clasificar. El mapa se calcula a partir de los gradientes de la primera puntuación de salida y se amplía al tamaño de la entrada. En la CNN entrenada con el simulador, esa salida corresponde a RBBB, por lo que el ejemplo mostrado examina ese rasgo.

La Figura 6.2 presenta juntos el trazado V1, el mapa normalizado y su superposición. Esta disposición permite localizar las zonas resaltadas sobre el ECG y observar si se sitúan en torno al QRS, relacionado con el rasgo representado, o en regiones periféricas como el fondo y los márgenes, indicando el color la contribución relativa dentro de esa imagen. La inspección se utiliza como apoyo cualitativo a la lectura del comportamiento del modelo y no interviene en la selección del umbral ni en el cálculo de las métricas. El fundamento del método y sus límites interpretativos se desarrollan en la sección 3.6.

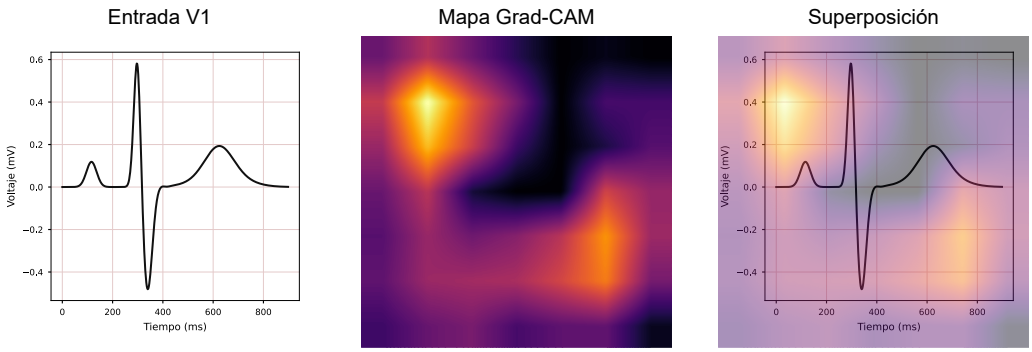


Figura 6.2.- Inspección de la salida RBBB de la CNN entrenada con el simulador mediante Grad-CAM. Se muestran la imagen V1, el mapa normalizado y su superposición.

6.2.- GEMMA CON APRENDIZAJE EN CONTEXTO

6.2.1.- Modelo y servicio

Se utiliza `google/gemma-4-E4B-it` [37], una variante preparada para seguir instrucciones que recibe conjuntamente las imágenes de ECG y el texto de la tarea. Sus pesos permanecen fijos durante los experimentos, de modo que cada predicción se obtiene a partir de las instrucciones y de los ejemplos incluidos en la consulta. El número y el origen de esas demostraciones permiten estudiar cómo cambia su respuesta al disponer de distintos contextos.

El modelo se ejecuta mediante vLLM en un clúster privado de computación equipado con dos GPU NVIDIA A100 y 96 GB de VRAM en total. El servicio mantiene el modelo cargado y genera las respuestas. Dentro de cada tarea se conservan el mismo modelo y los parámetros de inferencia, incluida una temperatura configurada de cero para reducir la variación asociada a la generación de texto. La Tabla A.5 recoge la configuración completa y el capítulo 9 desarrolla las implicaciones de privacidad asociadas al uso de grandes modelos de lenguaje con datos clínicos.

6.2.2.- Prompt y respuesta

El prompt es el mensaje de entrada que recibe el modelo. Tras seleccionar las demostraciones según la sección 4.3.2, se construye con la instrucción de sistema, los ejemplos y la imagen de consulta, en ese orden. Cada ejemplo incluye una imagen V1 y su respuesta en JSON, un formato que organiza la información en campos y valores. La consulta exige el mismo esquema. La Figura 6.3 representa la secuencia para el caso de clasificación de datos simulados.

Cada demostración se envía como una entrada de usuario con la imagen y una respuesta de asistente con la etiqueta conocida. En este estudio, no se han seleccionado demostraciones por similitud visual con la consulta ni se han estudiado permutaciones del orden, conteniendo así la última entrada la imagen que debe ser clasificada.

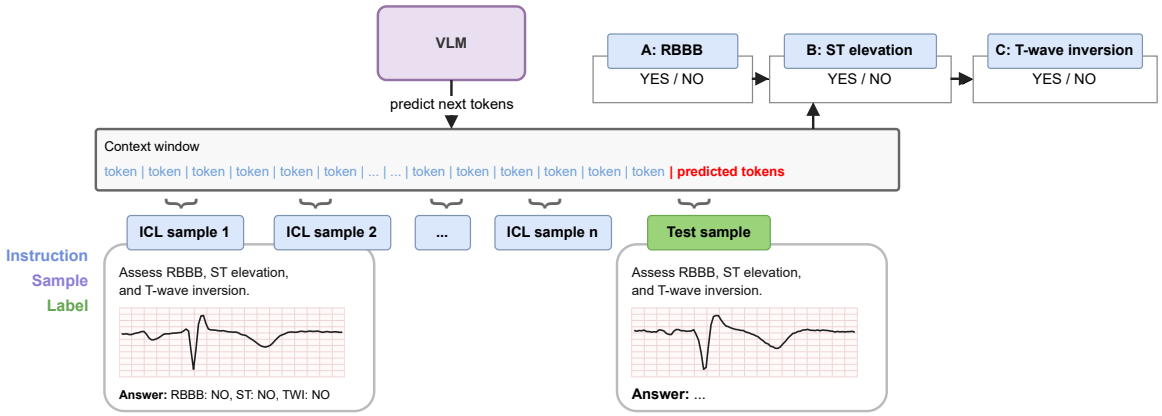


Figura 6.3.- Consulta con demostraciones y predicción de los tres rasgos del ECG simulado mediante ICL.

La tarea del simulador solicita los tres rasgos representados en la figura y la del conjunto cedido por el HUCA, una etiqueta positiva o negativa.

El formato de salida vincula la respuesta del modelo con las etiquetas utilizadas en la evaluación. En el simulador se conserva la decisión sobre cada rasgo y se obtiene una clasificación positiva derivada cuando los tres están presentes. En los registros provenientes del HUCA, la respuesta expresa directamente la etiqueta de Brugada solicitada en la tarea. El apéndice C recoge las instrucciones y los formatos empleados en cada experimento.

Capítulo 7. Resultados

7.1.- RESULTADOS CON LOS DATOS DEL SIMULADOR

La Tabla 7.1 recoge las mejores configuraciones. Las curvas de la Figura 7.1 muestran su evolución con K, y el apéndice B contiene todos los puntos.

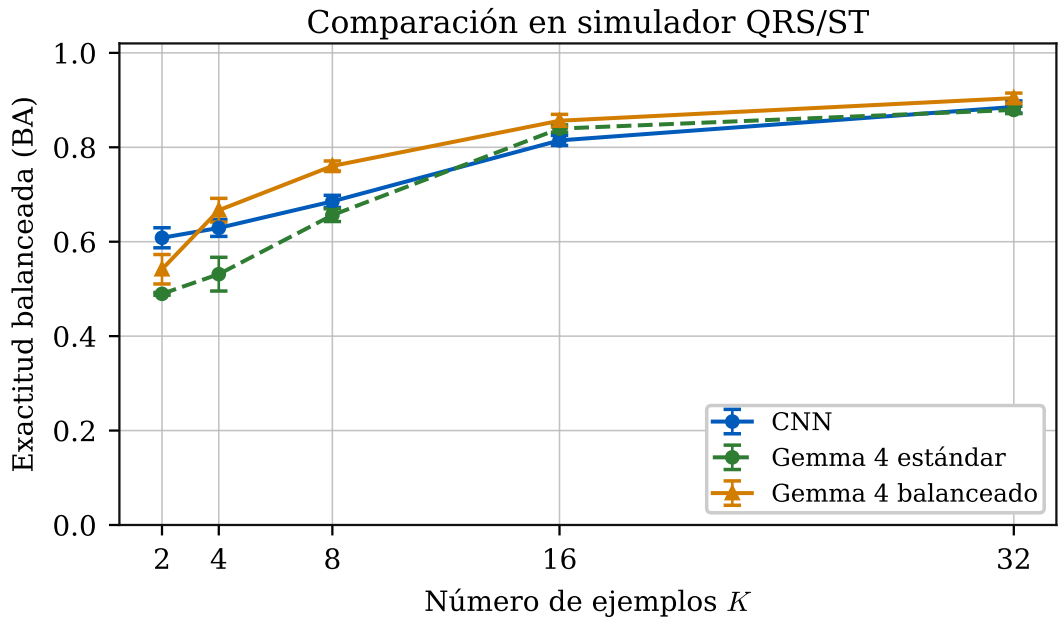
Método	K	BA	F1	Sens.	Esp.
CNN ResNet18	32	$0,885 \pm 0,013$	0,771	0,867	0,904
Gemma 4 zero-shot	0	$0,500 \pm 0,000$	0,000	0,000	1,000
Gemma 4, selección estándar	32	$0,879 \pm 0,008$	0,781	0,833	0,925
Gemma 4, selección balanceada	32	$0,904 \pm 0,011$	0,825	0,867	0,942

Tabla 7.1.- Mejores resultados en el simulador QRS/ST.

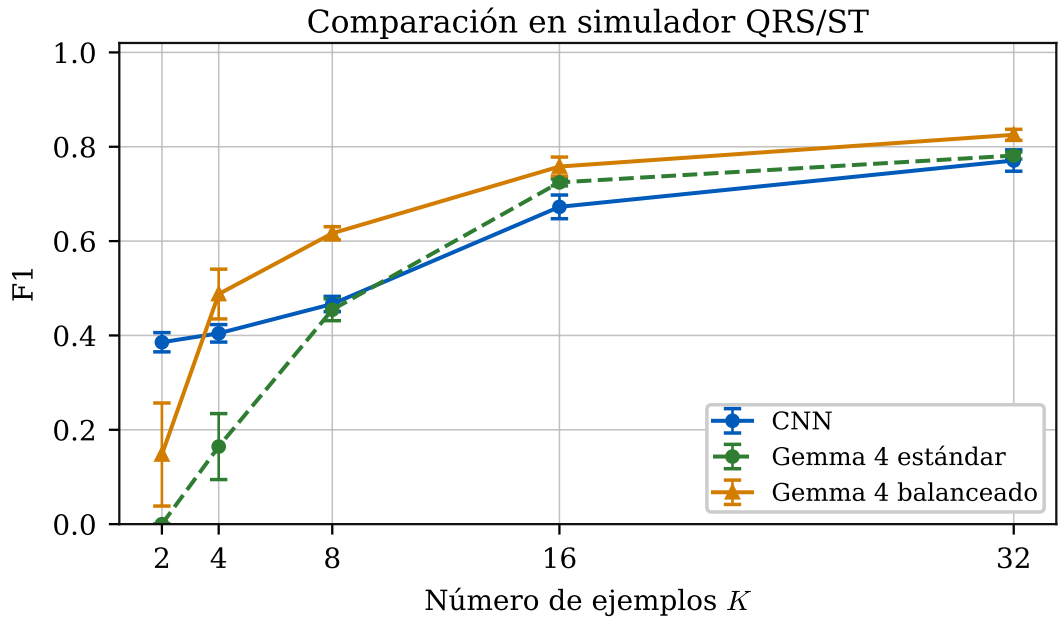
Nota. Valores medios de tres semillas, con desviación estándar indicada por $\pm$.

La CNN mejora con cada aumento de K, especialmente entre 8 y 16 pacientes, y su curva aún crece en el último punto evaluado.

Sin demostraciones, Gemma 4 clasifica todos los casos como negativos. Al recibir ejemplos, generaliza a latidos del simulador que no aparecen en su contexto y alcanza un rendimiento próximo al de la CNN. Con $K = 32$, la selección balanceada obtiene los mejores BA y F1. La Figura 7.2 muestra los errores.

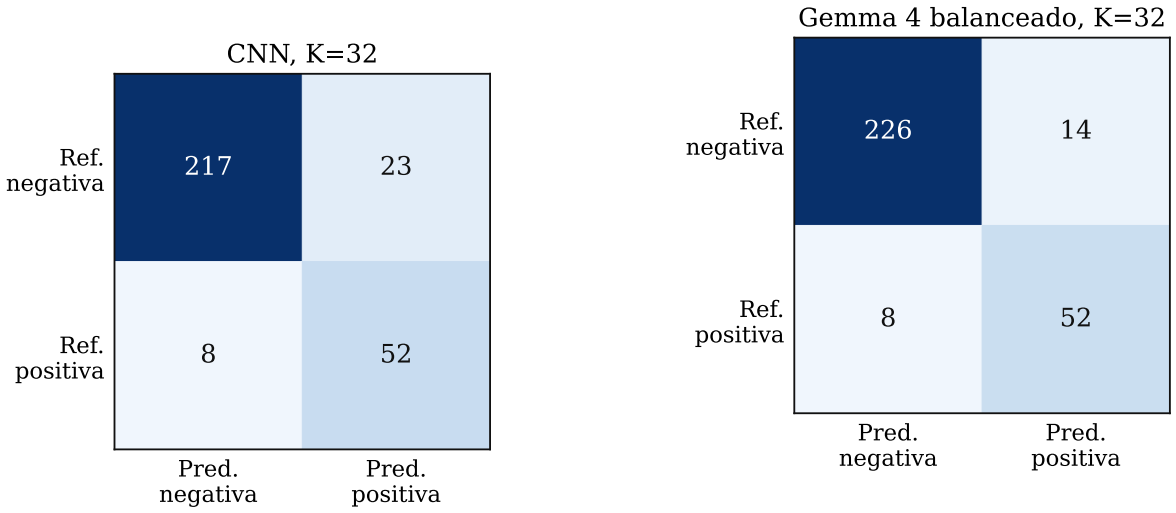


(a) Exactitud balanceada (BA).



(b) F1.

Figura 7.1.- Rendimiento de la CNN y Gemma 4 con datos del simulador según el número de ejemplos. Las barras representan la desviación estándar entre semillas.



(a) CNN, $K = 32$.

(b) Gemma 4, selección balanceada, $K = 32$.

Figura 7.2.- Matrices de confusión agregadas en el simulador. Cada matriz suma las predicciones de tres semillas sobre los mismos 100 pacientes.

Las matrices muestran que ambos modelos aprenden a distinguir las dos clases del simulador, aunque Gemma 4 produce menos falsos positivos.

7.2.- RESULTADOS CON LOS DATOS DEL HUCA

Todos los resultados de este apartado utilizan las etiquetas de los pacientes descritos en la sección 4.1.1.

7.2.1.- Transferencia desde el simulador

La CNN entrenada con el simulador alcanza su mejor BA sobre el HUCA con $K = 4$. Al aumentar los ejemplos mejora en los datos generados, pero cae hasta 0,498 sobre los ECG reales con $K = 32$. Aprender mejor las reglas del simulador no se traduce, por tanto, en reconocer mejor a los pacientes del HUCA. La Tabla 7.2 compara ese mejor punto con CORAL y MMD.

Configuración	K	BA	F1	Sens.	Esp.
CNN base, mejor global	4	$0,551 \pm 0,034$	0,506	0,670	0,433
CORAL	16	$0,545 \pm 0,011$	0,501	0,670	0,421
MMD	32	$0,546 \pm 0,011$	0,502	0,678	0,413

Tabla 7.2.- Puntos principales de la CNN sobre los datos del HUCA. CORAL y MMD se comparan con sus bases del mismo valor de K.

Nota. Valores medios de tres semillas, con desviación estándar indicada por $\pm$.

MMD eleva la BA de 0,498 a 0,546 con $K = 32$ y CORAL, de 0,520 a 0,545 con $K = 16$. La mejora es limitada y el rendimiento sigue cerca del azar.

Con demostraciones del simulador y selección balanceada, Gemma 4 obtiene su mejor BA, $0,514 \pm 0,008$, en $K = 16$, con sensibilidad de 0,063 y especificidad de 0,965. La mayoría de los positivos no se detecta, lo que muestra que estos ejemplos tampoco permiten trasladar a los ECG del HUCA el reconocimiento conseguido en el simulador. En $K = 32$, la BA baja a 0,512, la sensibilidad sube a 0,072 y la especificidad baja a 0,952.

En conjunto, ni la CNN ni Gemma 4 consiguen generalizar adecuadamente a los registros reales con los ejemplos del simulador. La Figura 7.3 resume las cuatro variantes de adaptación y Gemma 4 con demostraciones del simulador.

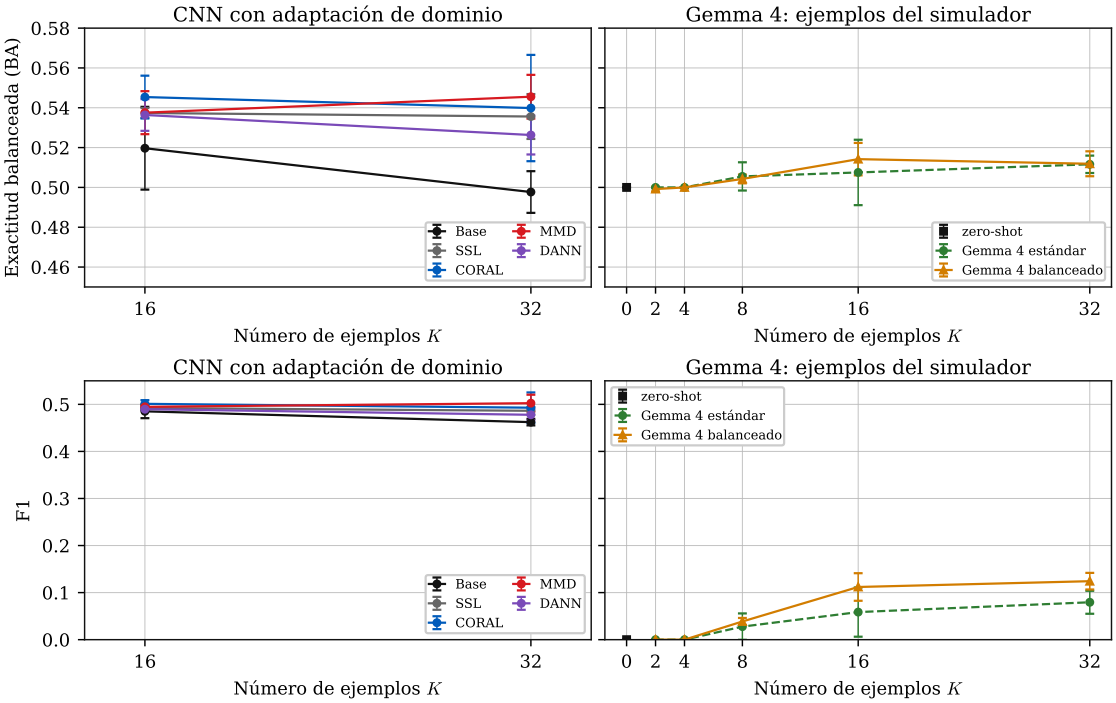


Figura 7.3.- Transferencia desde el simulador a los ECG clínicos. A la izquierda se comparan las variantes de adaptación de la CNN. A la derecha se muestra Gemma 4 con demostraciones del simulador.

7.2.2.- Aprendizaje con ejemplos clínicos

Conforme recibe más ejemplos del conjunto cedido por el HUCA, Gemma 4 mejora la clasificación de pacientes que no forman parte de las demostraciones de su consulta. Esta generalización contrasta con la CNN entrenada con esos datos, que permanece cerca del azar y no mejora de forma continua al aumentar los ejemplos. La Tabla 7.3 recoge las mejores configuraciones de ambos modelos.

Método	K	BA	F1	Sens.	Esp.
CNN estándar	32	$0,532 \pm 0,002$	$0,469 \pm 0,007$	$0,580 \pm 0,018$	$0,483 \pm 0,013$
CNN balanceada	16	$0,546 \pm 0,017$	$0,478 \pm 0,017$	$0,580 \pm 0,028$	$0,511 \pm 0,033$
Gemma 4 estándar	32	$0,743 \pm 0,011$	$0,675 \pm 0,014$	$0,690 \pm 0,014$	$0,796 \pm 0,008$
Gemma 4 balanceado	32	$0,761 \pm 0,011$	$0,699 \pm 0,013$	$0,741 \pm 0,014$	$0,781 \pm 0,008$

Tabla 7.3.- Mejores configuraciones de la CNN entrenada con el HUCA y de Gemma 4 con demostraciones de ese mismo conjunto.

Nota. Valores medios de tres semillas, con desviación estándar indicada por $\pm$.

Sin demostraciones, Gemma 4 obtiene una BA de 0,499 y no identifica ningún positivo del HUCA. Al igual que en el simulador, su configuración *zero-shot* no consigue resolver la tarea con las instrucciones utilizadas. La mejor CNN supera ligeramente a Gemma 4 con $K = 2$, 0,519 frente a 0,492, y con $K = 4$, 0,520 frente a 0,503. Desde $K = 8$ cambia el orden y Gemma 4 con selección balanceada alcanza 0,661 frente a 0,507 de la mejor CNN. Con $K = 16$, las mejores BA son 0,710 y 0,546, y con $K = 32$, 0,761 y 0,535.

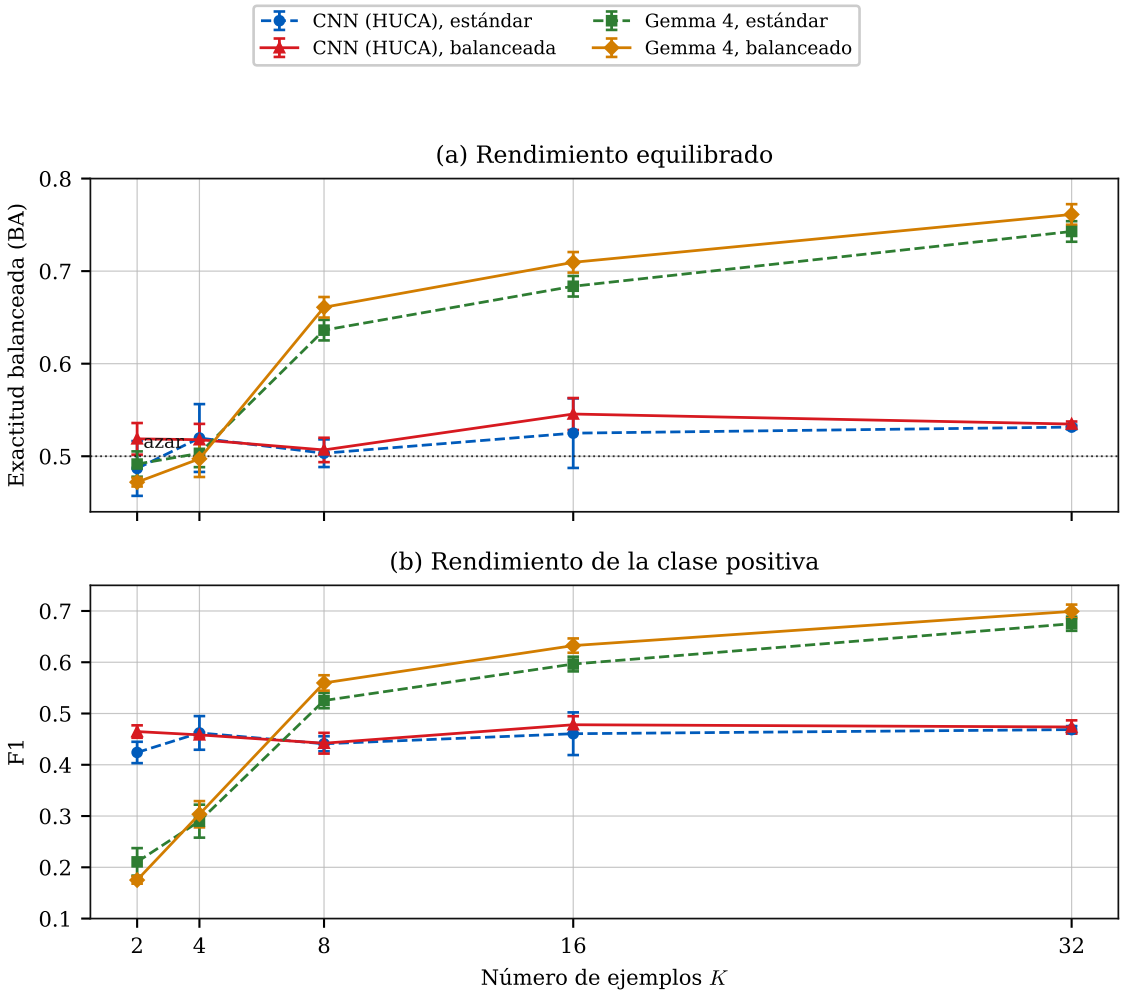


Figura 7.4.- BA y F1 de la CNN y Gemma 4 al aprender con ejemplos del HUCA. Las barras representan la desviación estándar de tres semillas.

La Figura 7.4 muestra la separación en BA y F1. La diferencia entre los mejores puntos es 0,216 de BA, y con $K = 32$ fijo es 0,226.

Las matrices de la Figura 7.5 muestran que Gemma 4 mejora la clasificación de ambas clases. Con ejemplos del HUCA reconoce positivos y negativos de pacientes que no forman parte de las demostraciones de su consulta. Esta generalización dentro del conjunto contrasta con el resultado obtenido sin ejemplos o con ejemplos del simulador, pero no demuestra todavía el mismo rendimiento en otros centros. Cada matriz reúne tres evaluaciones de los mismos pacientes.

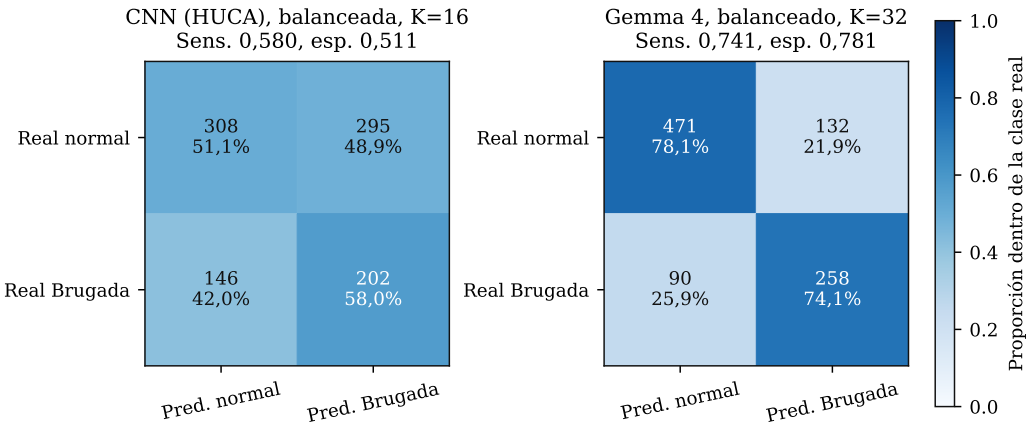


Figura 7.5.- Matrices de confusión normalizadas por clase real para la CNN entrenada con selección balanceada de pacientes del HUCA en $K = 16$ y Gemma 4 con demostraciones del HUCA balanceadas en $K = 32$.

En esta comparación, Gemma 4 detecta más positivos y genera menos falsas alertas que la CNN, lo que apoya investigar su uso para priorizar revisiones en el triaje. Los positivos que omite impiden plantearlo como filtro de descarte y hacen necesario mantener la evaluación clínica completa.

7.2.3.- Comparación entre el simulador y el HUCA

Las Figuras 7.6 y 7.7 permiten comparar las curvas completas. La CNN pasa de un máximo de 0,885 en el simulador a 0,551 sobre el HUCA. Gemma 4 pasa de 0,904 en el simulador a 0,761 con consultas y ejemplos clínicos. Con ejemplos del simulador y consulta clínica, su máximo es 0,514.

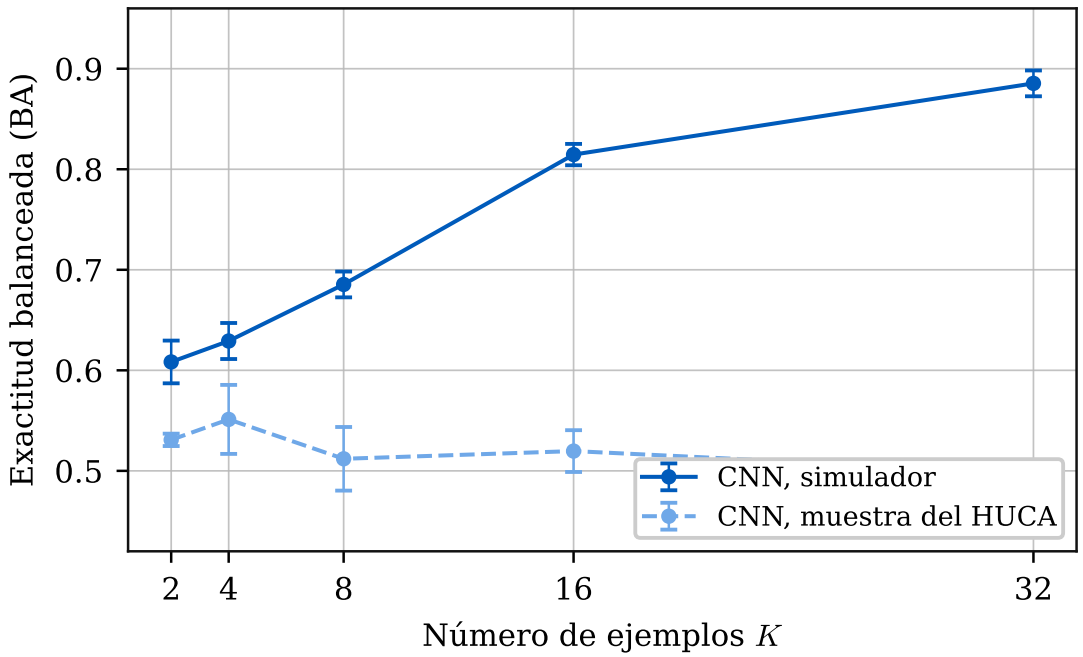


Figura 7.6.- Exactitud balanceada de la CNN entrenada en el simulador y evaluada con imágenes del simulador o clínicas, según el número de ejemplos.

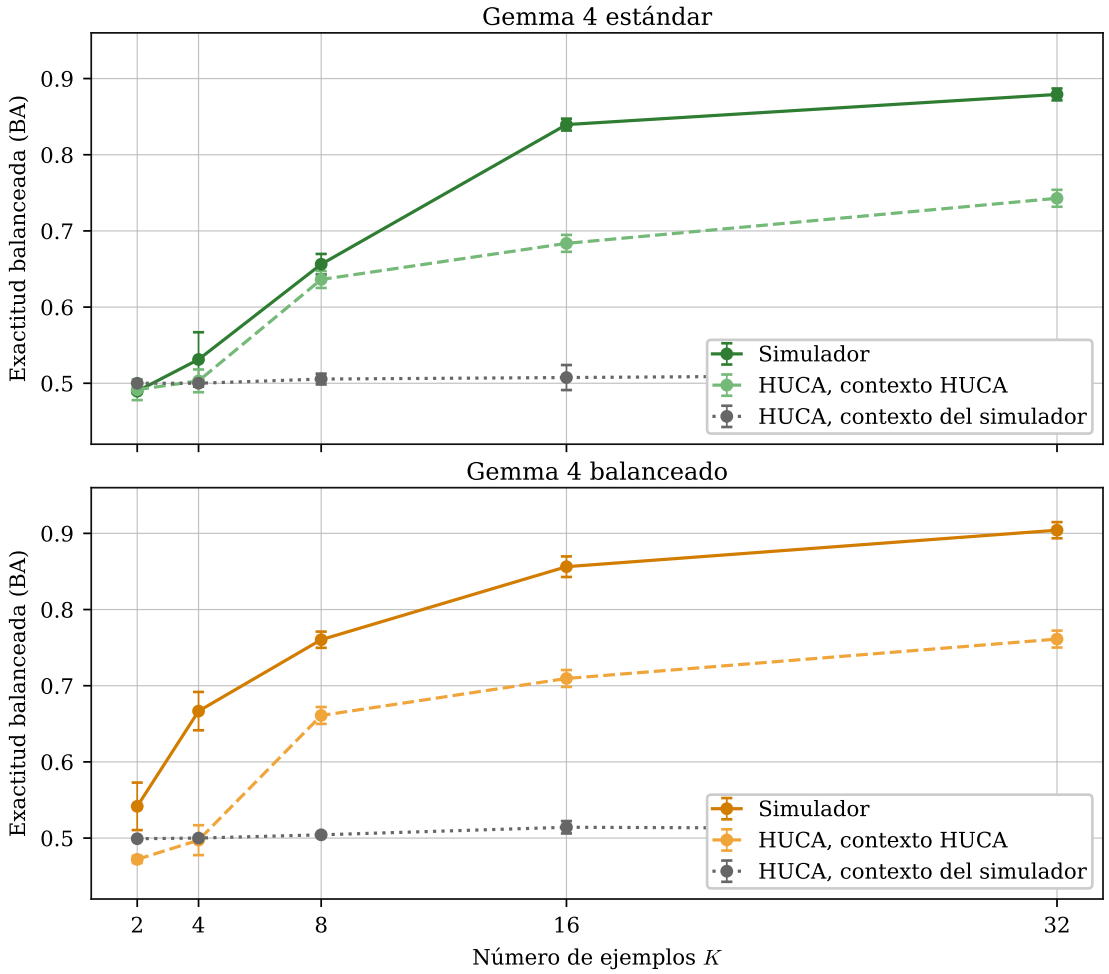


Figura 7.7.- Exactitud balanceada de Gemma 4 según el número de ejemplos y el origen de las demostraciones y de la consulta.

Capítulo 8. Discusión y conclusiones

8.1.- INTERPRETACIÓN DE LOS RESULTADOS

La comparación desarrollada en este trabajo permite valorar cómo se aprovechan unos pocos ejemplos etiquetados al ajustar una CNN o al incorporarlos al contexto de Gemma 4. El contraste entre los resultados del simulador y los del HUCA muestra que su utilidad depende también de cuánto se corresponden con los casos que se pretende clasificar.

8.1.1.- Aprendizaje con datos del simulador

Ambos métodos mejoran al aumentar K en el simulador y alcanzan sus mejores resultados con 32 ejemplos. La CNN mejora de forma continua mientras que Gemma 4 llega a un rendimiento comparable y obtiene una ligera ventaja con la selección balanceada en ese último punto. Esta evolución responde a la primera pregunta del trabajo y es coherente con un aprendizaje favorecido por la homogeneidad de las imágenes y por una relación directa entre la forma del trazado y la etiqueta.

Los latidos comparten el mismo formato y varían dentro de las formas previstas por el generador. Las regiones del ECG resultan por ello más fáciles de comparar entre ejemplos y las etiquetas corresponden a rasgos presentes en la propia imagen. Aumentar los ejemplos permite mostrar más variaciones de esas combinaciones sin introducir toda la diversidad de los registros clínicos. El buen rendimiento indica que ambos modelos pueden aprovechar esa regularidad aunque no permite asegurar que hayan aprendido únicamente los rasgos previstos ni que reconozcan todas las manifestaciones clínicas de Brugada.

La dependencia de Gemma 4 respecto de las demostraciones refuerza esta interpretación porque no detecta positivos cuando recibe solo las instrucciones. Los ejemplos parecen ayudarle a concretar qué diferencias visuales debe asociar con cada respuesta y esa orientación resulta suficiente para clasificar otros latidos del mismo generador. Su éxito en este escenario debe entenderse como aprendizaje dentro de una tarea controlada cuya utilidad clínica depende únicamente de lo que se conserve al pasar a pacientes reales.

8.1.2.- Adaptación al dominio de los datos clínicos

La evaluación sobre el HUCA muestra que se conserva muy poco de ese rendimiento y que añadir ejemplos del simulador no resuelve la transferencia. La CNN mejora al reconocer los latidos generados mientras pierde rendimiento con los pacientes reales y Gemma 4 con demostraciones sintéticas sigue clasificando casi todos los ECG clínicos como negativos. Este contraste es compatible con un aprendizaje de regularidades propias del generador que dejan de ser suficientes cuando cambian las imágenes y la tarea que representan sus etiquetas.

La homogeneidad que facilita el aprendizaje en el simulador limita también la variedad de formas que los modelos conocen a través de sus ejemplos. Los registros clínicos presentan más variación y su etiqueta corresponde al paciente en lugar de describir directamente la combinación de rasgos usada en el simulador. La pérdida de rendimiento puede deberse tanto a la apariencia del trazado como a esa diferencia entre las tareas.

Las variantes de adaptación intentan reducir las diferencias visuales pero siguen aprendiendo con las etiquetas del simulador. CORAL y MMD mejoran frente a la CNN base con el mismo K aunque ninguna de las variantes supera el mejor resultado sin adaptación y el rendimiento permanece próximo al azar. El experimento no separa el efecto de una alineación visual insuficiente del cambio de tarea pero sí muestra que la adaptación probada no compensa ambas dificultades y que los ejemplos sintéticos no son capaces de aportar el contexto suficiente para esta clasificación.

8.1.3.- Aprendizaje con datos clínicos

El origen de los ejemplos cambia el resultado cuando Gemma 4 recibe demostraciones del HUCA y clasifica otros pacientes del mismo conjunto. Su rendimiento mejora al aumentar K y supera al de la CNN entrenada con esos datos desde ocho ejemplos. Con dos y cuatro ambos métodos permanecen cerca del azar aunque la CNN obtiene una ligera ventaja con apoyo de validación etiquetada adicional. La comparación responde así a la segunda pregunta del trabajo y muestra que el aprendizaje en contexto aprovecha mejor los ejemplos clínicos en los tamaños mayores evaluados.

Las demostraciones del HUCA comparten con la consulta tanto la variación real del trazado como la definición de la etiqueta que se quiere predecir. Esta correspondencia ayuda a explicar la mejora respecto del uso de ejemplos sintéticos y sugiere que Gemma 4 puede utilizar sus características visuales previas para relacionar nuevos casos con las referencias del contexto. Para la CNN evaluada resulta imposible modelar adecuadamente la patología con tan pocos ejemplos.

La mejora en el dominio clínico sigue siendo parcial porque incluso la mejor configuración omite aproximadamente una cuarta parte de los positivos. Aunque no alcanza valores

comparables a los del simulador Gemma 4 podría servir como herramienta de triaje para priorizar la revisión de casos sospechosos y facilitar un estudio más exhaustivo de la enfermedad.

8.2.- APORTACIONES Y LIMITACIONES

La principal aportación del trabajo es una comparación de dos formas de aprender con pocos ejemplos que contempla tanto un entorno controlado como su relación con datos clínicos. La evaluación por paciente permite estudiar el efecto de K sin incluir al paciente de prueba entre los ejemplos etiquetados de cada pliegue y la separación de escenarios ayuda a distinguir el reconocimiento de las familias sintéticas de la clasificación con etiquetas del HUCA. El simulador aporta un marco para estudiar combinaciones morfológicas conocidas y la comparación con pacientes reales permite identificar hasta dónde llegan esas reglas al enfrentarse a la tarea clínica.

El alcance de los resultados está limitado por la falta de anotaciones morfológicas por derivación con las que comprobar si los modelos reconocen los rasgos que motivan la sospecha de Brugada o si aprovechan otras regularidades de las imágenes. Esta limitación afecta especialmente a la interpretación de una etiqueta asignada al paciente a partir de información que puede exceder lo visible en el latido V1 seleccionado.

La muestra procede de un único centro hospitalario y excluye los casos cuya clasificación no estaba clara al preparar el estudio. Su composición no representa necesariamente la variedad de pacientes que llegaría a un circuito de triaje y limita la posibilidad de trasladar directamente las métricas a ese contexto. El uso de una sola derivación y de un latido por paciente también reduce la información disponible frente a una valoración clínica completa que puede requerir otras derivaciones o registros obtenidos en distintos momentos.

La falta de validación externa y prospectiva impide valorar todavía la utilidad en el triaje de las configuraciones estudiadas. No se han medido la calibración de las probabilidades ni el efecto de los errores sobre la carga de revisión y tampoco se dispone de una evaluación suficientemente precisa por subgrupos.

8.3.- CONTINUACIÓN DEL TRABAJO

La continuación del proyecto debería comenzar con la revisión especializada de las etiquetas y de los casos dudosos para disponer de una base clínica contrastada sobre la que repetir la evaluación. Incorporar anotaciones de los rasgos visibles en cada derivación ayudaría a relacionar la respuesta de los modelos con la morfología del ECG y a distinguir los errores de reconocimiento de las discordancias entre una imagen aislada y la etiqueta del paciente.

Esa información también permitiría revisar el simulador para acercar sus reglas a una tarea clínica definida con mayor precisión.

La ampliación del número de pacientes y de casos positivos permitiría estudiar si la CNN mejora de forma sostenida al disponer de más datos. Sobre esa base tendría sentido comparar el ajuste completo de ResNet18 con un extractor de características congelado y con arquitecturas especializadas en ECG. La incorporación de otras derivaciones y de varios latidos por paciente ayudaría además a comprobar cuánto limita el uso exclusivo de V1 y si una representación más completa aporta información útil para la clasificación.

También podría explorarse el ajuste fino de Gemma 4 con datos del simulador como etapa de adaptación al análisis de imágenes de ECG. Generar más ejemplos con mayor variedad de trazados permitiría actualizar sus pesos para reforzar el reconocimiento de los rasgos morfológicos y combinar después ese ajuste con demostraciones clínicas. Su evaluación sobre el HUCA permitiría comprobar si esa preparación mejora la clasificación respecto del modelo original o si el aprendizaje continúa ligado a las regularidades del simulador.

La continuación del estudio del aprendizaje en contexto pasa por estudiar la selección de demostraciones por similitud y el efecto de su orden dentro de la consulta. Mantener controlados esos factores permitiría valorar mejor la contribución del balance de clases y comprobar si la ventaja observada con Gemma 4 se conserva con otros modelos o instrucciones.

La evaluación con pacientes de otros hospitales sería necesaria para comprobar la generalización frente a cambios de equipo o de presentación de las imágenes. Ese estudio debería reservar datos ajenos a cualquier ajuste y acompañarse de intervalos de incertidumbre y de una revisión experta de los errores. Una fase prospectiva posterior permitiría medir el efecto sobre la priorización de casos y sobre la carga de trabajo antes de valorar una aplicación de triaje clínico.

La posible utilización de Gemma 4 para apoyar el triaje debe estudiarse dentro de ese proceso de validación. Priorizar ECG para su revisión podría facilitar la recogida de nuevos casos confirmados con los que investigar después modelos supervisados de mayor rendimiento o con mayor explicabilidad.

8.4.- CONCLUSIONES

Este Trabajo de Fin de Grado ha comparado el ajuste supervisado de una CNN ResNet18 y el aprendizaje en contexto de Gemma 4 para clasificar imágenes de ECG con pocos ejemplos etiquetados. La evaluación muestra que ambos métodos pueden distinguir las clases del simulador y mejorar al aumentar los ejemplos aunque ese aprendizaje no se traslada de forma suficiente a los pacientes del HUCA. Las mejoras limitadas de las variantes de adaptación

confirman que las soluciones probadas no resuelven la diferencia entre el entorno generado y la tarea definida por las etiquetas clínicas.

La aportación más relevante para el escenario con pocos datos es la mejora de Gemma 4 cuando recibe demostraciones del propio HUCA. Su ventaja frente a la CNN entrenada con esos datos desde ocho ejemplos muestra que el aprendizaje en contexto puede resultar útil para clasificar otros pacientes del mismo conjunto sin ajustar los pesos del modelo. La ausencia de detección de positivos sin demostraciones y la escasa transferencia desde el simulador indican que esa utilidad depende de ofrecer ejemplos pertinentes para la tarea y no puede deducirse únicamente del conocimiento previo del modelo.

El trabajo permite así identificar una vía de investigación para el apoyo al triaje y precisar las condiciones que todavía deben estudiarse. Los resultados corresponden a la muestra y a las configuraciones evaluadas y necesitan contrastarse mediante revisión clínica de las etiquetas y validación en otros centros. Su posible aplicación se orienta a priorizar la revisión especializada de casos sospechosos dentro de la evaluación clínica completa. Comprobar que esa priorización mejora la atención sin excluir pacientes que requieren valoración es el siguiente paso para determinar su utilidad.

Capítulo 9. Aspectos éticos y protección de datos

9.1.- RESPONSABILIDAD CLÍNICA

La posible aplicación como apoyo al triaje dejaría la revisión de las alertas y las decisiones diagnósticas y terapéuticas bajo responsabilidad del personal sanitario. Una predicción negativa no debería impedir una evaluación más exhaustiva si existe sospecha clínica, según la sección 3.2.1. Antes de incorporarla a la asistencia habría que evaluar los riesgos de omitir casos o generar falsas alertas y proteger también los datos que se recogieran durante ese proceso, con las limitaciones descritas en la sección 8.2.

La salida del modelo debe interpretarse junto con la historia clínica, la exploración y el resto de pruebas disponibles. En este TFG, la imagen del ECG y la etiqueta utilizada en la evaluación representan solo una parte del contexto necesario para valorar un caso. Por ello, una alerta puede servir para ordenar revisiones y facilitar la identificación de casos que merezcan atención, pero requiere una comprobación profesional antes de orientar cualquier decisión.

Si el sistema llegara a incorporarse a un circuito asistencial, habría que definir quién revisa cada alerta, qué información acompaña a la predicción y cómo se documenta la decisión final. También sería necesario vigilar cambios en la distribución de los registros y en la frecuencia de errores, porque el comportamiento observado en este conjunto puede variar al trabajar con otros centros, equipos o prácticas de adquisición. Estas condiciones deberían fijarse antes de su uso y revisarse durante el seguimiento.

9.2.- PROTECCIÓN DE DATOS

El HUCA facilitó para este trabajo un conjunto ya anonimizado mediante Safe Harbor [47]. El proyecto no realizó esa anonimización ni recibió identificadores directos. Se utilizaron únicamente las imágenes, las etiquetas y los campos necesarios para formar los pliegues, ejecutar los modelos y calcular las métricas.

Las imágenes se procesaron en un clúster privado de computación, donde también se ejecutó el servicio de inferencia de Gemma 4. La memoria presenta los resultados de forma agregada. Su reutilización con otra finalidad requeriría revisar esas garantías.

Apéndice A. Configuración experimental

Estas tablas reúnen la configuración completa utilizada en los experimentos del capítulo 4.

A.1.- CONJUNTO GENERADO POR EL SIMULADOR QRS/ST

Propiedad	Valor
Fuente	Simulador QRS/ST descrito en el capítulo 5
Pacientes	100
Imágenes únicas	100
Predicciones agregadas	300, correspondientes a tres semillas
Familias fuente	Cinco familias morfológicas descritas en el capítulo 5
Pacientes por familia	20
Derivaciones renderizadas	V1
Frecuencia de muestreo	500 Hz
Duración del latido	900 ms
Resolución de guardado	130 ppp
Positivos derivados	20
Negativos o incompletos	80
Valores de K	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026

Tabla A.1.- Configuración del conjunto generado por el simulador.

La regla de etiqueta se define en la sección 4.1 y el umbral de la CNN, en la sección 6.1.2.

A.2.- MUESTRA DEL HUCA

Propiedad	Valor
Fuente	Hospital Universitario Central de Asturias (HUCA), recurso Brugada-HUCA 1.0.0
Pacientes brutos	363
Pacientes excluidos	46 casos de clasificación dudosa, por recomendación de los médicos colaboradores
Pacientes incluidos	317
Imágenes únicas incluidas	317
Predicciones agregadas	951, correspondientes a tres semillas
Etiqueta positiva	116
Etiqueta negativa	201
Derivaciones	V1
Ventana	300 ms antes de R y 600 ms después de R
Frecuencia de origen	100 Hz
Resolución de guardado	130 ppp
Separación	Leave-one-out por paciente

Tabla A.2.- Configuración de la muestra procesada del HUCA.

La selección y la preparación de los pacientes se describen en la sección 4.1.

A.3.- CONFIGURACIÓN DE LAS CNN

Propiedad	CNN entrenada con el simulador	CNN entrenada con el HUCA
Arquitectura	ResNet18	
Pesos iniciales	Preentrenados con ImageNet	
Entrada	Una imagen V1, RGB, 224 por 224 píxeles	
Salida	RBBB, elevación ST e inversión T	Una salida logística para la etiqueta clínica
Etiquetas	Validadores del simulador	Presencia o ausencia de Brugada
Pérdida	BCE multietiqueta	BCE de una salida
Ponderación positiva	Automática con el entrenamiento de cada pliegue	
Optimizador	AdamW	
Tasa de aprendizaje	3×10^{-4}	
Lote	32 imágenes	
Épocas máximas	20	20, con *early stopping*
Paciencia	No corresponde	5 épocas sin mejora de BA
Weight decay	No registrado	10^{-4}
Entrenamiento	K pacientes del simulador	K pacientes del HUCA
Valores de K	$2, 4, 8, 16, 32$	
Balance de clases	No corresponde	Estándar y balanceada
Semillas	42, 123 y 2026	
Validación	Por pliegue	8 pacientes, 4 por clase
Umbral	Máxima BA por paciente en validación	
Métrica principal	Exactitud balanceada por paciente	
Paneles Grad-CAM	12 (simulador) y 6 (HUCA)	No corresponde

Tabla A.3.- Configuración completa de las dos CNN.

A.4.- CONFIGURACIÓN DE ADAPTACIÓN DE DOMINIO

Propiedad	Valor
Origen etiquetado	Conjunto del simulador QRS/ST
Destino no etiquetado	Conjunto del HUCA
Métodos	SSL, CORAL, MMD y DANN [42, 43, 44, 41]
Valores de K	$K = 16$ y $K = 32$
Semillas	42, 123 y 2026
Peso de adaptación	0,1
Escalas MMD	0,5, 1,0, 2,0 y 4,0
SSL	SimCLR durante 3 épocas
Uso de imágenes del HUCA	Compartidas entre pliegues durante la adaptación, sin utilizar sus etiquetas para entrenar

Tabla A.4.- Configuración de los experimentos de adaptación de dominio.

A.5.- CONFIGURACIÓN DE GEMMA 4

Elemento	Valor
Modelo informado	`google/gemma-4-E4B-it`
Servicio	vLLM en un clúster privado de computación con dos GPU NVIDIA A100 y 96 GB de VRAM en total
Temperatura	0
Respuesta	JSON estructurado
Entrada	Imagen ECG y demostraciones imagen-etiqueta
Valores de K	$K = \{0, 2, 4, 8, 16, 32\}$
Selección de demostraciones	Sin ejemplos, estándar y balanceada
Contextos sobre el conjunto del HUCA	Demostraciones de la propia muestra o del simulador
Salida morfológica	RBBB, elevación del ST e inversión de T
Salida clínica	Etiqueta positiva o negativa de Brugada
Métrica principal	Exactitud balanceada por paciente

Tabla A.5.- Configuración de Gemma 4 con aprendizaje en contexto.

La construcción del mensaje se describe en la sección 6.2 y los prompts se conservan en el apéndice C.

Apéndice B. Resultados completos

Las tablas reúnen los resultados completos de la campaña final con las métricas de la sección 4.4.

B.1.- CNN ENTRENADA CON EL SIMULADOR

Datos de prueba	K	Acc.	BA	F1	Prec.	Sens.	Esp.
Simulador	2	0,593	$0,608 \pm 0,021$	0,386	0,279	0,633	0,583
Simulador	4	0,627	$0,629 \pm 0,018$	0,404	0,297	0,633	0,625
Simulador	8	0,687	$0,685 \pm 0,013$	0,467	0,355	0,683	0,688
Simulador	16	0,853	$0,815 \pm 0,011$	0,673	0,611	0,750	0,879
Simulador	32	0,897	$0,885 \pm 0,013$	0,771	0,695	0,867	0,904
HUCA	2	0,492	$0,531 \pm 0,006$	0,493	0,389	0,675	0,386
HUCA	4	0,519	$0,551 \pm 0,034$	0,506	0,407	0,670	0,433
HUCA	8	0,481	$0,512 \pm 0,032$	0,469	0,376	0,629	0,395
HUCA	16	0,479	$0,520 \pm 0,021$	0,485	0,381	0,670	0,370
HUCA	32	0,462	$0,498 \pm 0,010$	0,462	0,364	0,632	0,363

Tabla B.1.- Resultados completos de la CNN entrenada con el simulador y evaluada con datos generados o ECG del HUCA.

Nota. Valores medios de tres semillas, con desviación estándar indicada por $\pm$.

B.2.- CNN ENTRENADA CON EL HUCA

Condición	K	BA	F1	Sens.	Esp.
Estándar	2	$0,487 \pm 0,030$	$0,424 \pm 0,021$	$0,526 \pm 0,015$	$0,448 \pm 0,054$
Estándar	4	$0,520 \pm 0,037$	$0,462 \pm 0,033$	$0,583 \pm 0,039$	$0,456 \pm 0,048$
Estándar	8	$0,503 \pm 0,015$	$0,441 \pm 0,015$	$0,549 \pm 0,035$	$0,458 \pm 0,046$
Estándar	16	$0,525 \pm 0,038$	$0,461 \pm 0,042$	$0,569 \pm 0,062$	$0,481 \pm 0,033$
Estándar	32	$0,532 \pm 0,002$	$0,469 \pm 0,007$	$0,580 \pm 0,018$	$0,483 \pm 0,013$
Balanceada	2	$0,519 \pm 0,017$	$0,465 \pm 0,012$	$0,595 \pm 0,009$	$0,443 \pm 0,031$
Balanceada	4	$0,518 \pm 0,017$	$0,458 \pm 0,005$	$0,575 \pm 0,022$	$0,461 \pm 0,055$
Balanceada	8	$0,507 \pm 0,013$	$0,442 \pm 0,020$	$0,546 \pm 0,039$	$0,468 \pm 0,017$
Balanceada	16	$0,546 \pm 0,017$	$0,478 \pm 0,017$	$0,580 \pm 0,028$	$0,511 \pm 0,033$
Balanceada	32	$0,535 \pm 0,003$	$0,474 \pm 0,013$	$0,592 \pm 0,041$	$0,478 \pm 0,036$

Tabla B.2.- Resultados completos de la CNN entrenada directamente con la etiqueta de Brugada del HUCA.

Nota. Valores medios de tres semillas, con desviación estándar indicada por $\pm$.

B.3.- ADAPTACIÓN DE DOMINIO DE LA CNN

Método	K	Acc.	BA	F1	Prec.	Sens.	Esp.
Base	16	0,479	$0,520 \pm 0,021$	0,485	0,381	0,670	0,370
SSL	16	0,506	$0,537 \pm 0,003$	0,492	0,395	0,655	0,420
CORAL	16	0,512	$0,545 \pm 0,011$	0,501	0,401	0,670	0,421
MMD	16	0,504	$0,538 \pm 0,011$	0,495	0,395	0,664	0,411
DANN	16	0,507	$0,536 \pm 0,008$	0,490	0,394	0,647	0,426
Base	32	0,462	$0,498 \pm 0,010$	0,462	0,364	0,632	0,363
SSL	32	0,509	$0,536 \pm 0,011$	0,486	0,394	0,635	0,436
CORAL	32	0,509	$0,540 \pm 0,027$	0,493	0,396	0,655	0,425
MMD	32	0,510	$0,546 \pm 0,011$	0,502	0,400	0,678	0,413
DANN	32	0,499	$0,526 \pm 0,010$	0,478	0,387	0,626	0,426

Tabla B.3.- Resultados completos de adaptación no supervisada sobre el conjunto del HUCA.

Nota. Valores medios de tres semillas, con desviación estándar indicada por $\pm$.

B.4.- GEMMA 4 CON APRENDIZAJE EN CONTEXTO

B.4.1.- Resultados con datos del simulador

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	$0,500 \pm 0,000$	0,000	0,000	1,000
Estándar	2	$0,490 \pm 0,003$	0,000	0,000	0,979
Estándar	4	$0,531 \pm 0,036$	0,164	0,100	0,963
Estándar	8	$0,656 \pm 0,014$	0,454	0,417	0,896
Estándar	16	$0,840 \pm 0,008$	0,724	0,767	0,913
Estándar	32	$0,879 \pm 0,008$	0,781	0,833	0,925
Balanceado	2	$0,542 \pm 0,031$	0,148	0,083	1,000
Balanceado	4	$0,667 \pm 0,025$	0,488	0,367	0,967
Balanceado	8	$0,760 \pm 0,011$	0,617	0,617	0,904
Balanceado	16	$0,856 \pm 0,014$	0,758	0,783	0,929
Balanceado	32	$0,904 \pm 0,011$	0,825	0,867	0,942

Tabla B.4.- Resultados de Gemma 4 en el simulador QRS/ST.

Nota. Valores medios de tres semillas, con desviación estándar indicada por $\pm$.

B.4.2.- Pacientes del HUCA con demostraciones del mismo conjunto

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	$0,499 \pm 0,001$	0,000	0,000	0,998
Estándar	2	$0,492 \pm 0,014$	0,211	0,152	0,831
Estándar	4	$0,503 \pm 0,015$	0,290	0,239	0,768
Estándar	8	$0,636 \pm 0,011$	0,525	0,491	0,781
Estándar	16	$0,684 \pm 0,011$	0,596	0,586	0,781
Estándar	32	$0,743 \pm 0,011$	0,675	0,690	0,796
Balanceado	2	$0,472 \pm 0,005$	0,175	0,126	0,818
Balanceado	4	$0,497 \pm 0,020$	0,304	0,261	0,733
Balanceado	8	$0,661 \pm 0,011$	0,560	0,526	0,796
Balanceado	16	$0,710 \pm 0,011$	0,632	0,638	0,781
Balanceado	32	$0,761 \pm 0,011$	0,699	0,741	0,781

Tabla B.5.- Resultados de Gemma 4 sobre la muestra del HUCA con demostraciones del propio conjunto.

Nota. Valores medios de tres semillas, con desviación estándar indicada por $\pm$.

B.4.3.- Pacientes del HUCA con demostraciones del simulador

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	$0,500 \pm 0,000$	0,000	0,000	1,000
Estándar	2	$0,500 \pm 0,000$	0,000	0,000	1,000
Estándar	4	$0,500 \pm 0,000$	0,000	0,000	1,000
Estándar	8	$0,506 \pm 0,007$	0,028	0,014	0,997
Estándar	16	$0,508 \pm 0,016$	0,059	0,032	0,983
Estándar	32	$0,512 \pm 0,004$	0,079	0,043	0,980
Balanceado	2	$0,499 \pm 0,001$	0,000	0,000	0,998
Balanceado	4	$0,500 \pm 0,000$	0,000	0,000	1,000
Balanceado	8	$0,504 \pm 0,002$	0,039	0,020	0,988
Balanceado	16	$0,514 \pm 0,008$	0,112	0,063	0,965
Balanceado	32	$0,512 \pm 0,006$	0,124	0,072	0,952

Tabla B.6.- Resultados de Gemma 4 sobre los datos del HUCA con demostraciones del simulador.

Nota. Valores medios de tres semillas, con desviación estándar indicada por $\pm$.

Apéndice C. Prompts y respuestas estructuradas

C.1.- CRITERIO DE CONSERVACIÓN

Los prompts forman parte del protocolo experimental. En un modelo de visión y lenguaje, cambios pequeños en instrucciones, orden o formato pueden modificar la respuesta. Por esa razón se conserva el contenido de los prompts y el esquema de salida exigido.

C.2.- SISTEMA PARA TAREA MORFOLÓGICA

```
You are evaluating single-beat right precordial ECG images from lead V1.
Use only the visible morphology in the ECG image. Treat each finding as an
independent visual attribute of the beat, not as a final diagnosis.

Return only the requested JSON. Do not include prose, markdown, caveats, a
diagnosis, or a clinical recommendation.
```

C.3.- TAREA MORFOLÓGICA

```
Analyze this single-beat right precordial ECG image from lead {lead}.

Inspect the beat from left to right:
  - identify the QRS complex, including any second positive terminal deflection
  - use the flat PR/TP segment around the beat as the visual baseline when visible
  - inspect the J point and ST segment immediately after the QRS
  - inspect the T wave that follows the ST segment

Evaluate these morphology findings independently:

RBBB:
  - true when the QRS has a right-precordial terminal conduction pattern such as
    RSR', rSr', rsR', or a clear late positive R' after the initial QRS deflection
  - also true when the terminal part of the QRS looks delayed or widened in a way
```

```
    compatible with right bundle branch block morphology
  - false when there is no clear terminal R' or delayed terminal QRS morphology

ST_ELEVATION:
  - true when the J point or ST segment after the QRS remains above the visual
    baseline
  - coved/convex elevation and saddleback elevation count when visually present
  - false when the ST segment returns to baseline or is not visibly elevated

T_WAVE_INVERSION:
  - true when the T wave after the ST segment is predominantly negative, below
    the visual baseline
  - false when the T wave is upright, flat without a clear negative component, or
    not visible enough to judge as inverted

Return only valid JSON with boolean values for exactly these keys:

{
  "RBBB": true,
  "ST_ELEVATION": true,
  "T_WAVE_INVERSION": true
}
```

C.4.- SISTEMA PARA TAREA CLÍNICA

```
You are evaluating a single lead V1 right precordial ECG beat image from one
patient.

Use only the visible morphology in the image and the in-context examples. The
label is a research reference for suspected Brugada triage. It must not be used
as an autonomous diagnosis.

Return only the requested JSON. Do not include prose, markdown, caveats, a
diagnosis, or a clinical recommendation.
```

C.5.- TAREA CLÍNICA DIRECTA

```
Analyze this single right precordial ECG beat image from lead {lead} from one
    patient.

```

```
Decide whether the patient is compatible with the Brugada-positive research
reference used in this study.

Look for right-precordial Brugada-type visual evidence in V1:
  - J-point or ST elevation immediately after the QRS
  - a coved or convex descending ST segment, especially when followed by a
    predominantly negative T wave
  - a saddleback ST shape can be supportive but is less specific by itself
  - terminal right-precordial QRS features such as rSr' or RSR' can support the
    visual pattern, but should not be the only reason for a positive label

Return false when the beat is visually closer to a normal V1 morphology, when ST
elevation is absent, or when the image does not show enough Brugada-type
evidence. Use the support examples, when present, to calibrate the study label.

Return only valid JSON with exactly this key:

{
  "clinical_brugada": true
}
```

C.6.- VALIDACIÓN DE LAS RESPUESTAS

Las respuestas se validan de forma estricta. Una salida con claves ausentes, claves adicionales, texto libre o tipos incorrectos se registra como fallo de formato. En la evaluación final, la tasa de JSON inválido fue 0, por lo que las diferencias de rendimiento proceden de las decisiones del modelo y no de errores sintácticos.

Bibliografía

[1] Zeppenfeld, K. y colaboradores. 2022 ESC Guidelines for the management of patients with ventricular arrhythmias and the prevention of sudden cardiac death. *European Heart Journal*, 43(40), 3997–4126, 2022. https://doi.org/10.1093/eurheartj/ehac262.

[2] Kligfield, P., Gettes, L. S., Bailey, J. J. y colaboradores. Recommendations for the standardization and interpretation of the electrocardiogram. Part I. The electrocardiogram and its technology. *Circulation*, 115(10), 1306–1324, 2007. https://doi.org/10.1161/CIRCULATIONAHA.106.180200.

[3] Surawicz, B., Childers, R., Deal, B. J., Gettes, L. S. y colaboradores. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part III. Intraventricular conduction disturbances. *Circulation*, 119(10), e235–e240, 2009. https://doi.org/10.1161/CIRCULATIONAHA.108.191095.

[4] Rautaharju, P. M., Surawicz, B. y Gettes, L. S. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part IV. The ST segment, T and U waves, and the QT interval. *Circulation*, 119(10), e241–e250, 2009. https://doi.org/10.1161/CIRCULATIONAHA.108.191096.

[5] Sieira, J. y Brugada, P. The definition of the Brugada syndrome. *European Heart Journal*, 38(40), 3029–3034, 2017. https://doi.org/10.1093/eurheartj/ehx490.

[6] Wilde, A. A. M., Amin, A. S. y colaboradores. Use, misuse, and pitfalls of the drug challenge test in the diagnosis of the Brugada syndrome. *European Heart Journal*, 44(27), 2427–2439, 2023. https://doi.org/10.1093/eurheartj/ehad295.

[7] BrugadaDrugs.org Advisory Board. Diagnostic drugs for Brugada syndrome. BrugadaDrugs.org. https://www.brugadadrugs.org/druglist_diagnostic/.

[8] CardioNetworks y ECGpedia. Brugada syndrome type1 example4. Wikimedia Commons, licencia CC BY-SA 3.0. https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_(CardioNetworks_ECGpedia).png.

[9] Napolitano, C. y Priori, S. G. Brugada syndrome. *Orphanet Journal of Rare Diseases*, 1, 35, 2006. https://doi.org/10.1186/1750-1172-1-35.

[10] Corrado, D., Pelliccia, A., Heidbuchel, H. y colaboradores. Recommendations for interpretation of 12 lead electrocardiogram in the athlete. *European Heart Journal*, 31(2), 243–259, 2010. https://doi.org/10.1093/eurheartj/ehp473.

[11] Ribeiro, A. H. y colaboradores. Automatic diagnosis of the 12 lead ECG using a deep neural network. *Nature Communications*, 11, 1760, 2020. https://doi.org/10.1038/s41467-020-15432-4.

[12] Wagner, P., Strodthoff, N., Bousseljot, R. D. y colaboradores. PTB XL, a large publicly available electrocardiography dataset. *Scientific Data*, 7, 154, 2020. https://doi.org/10.1038/s41597-020-0495-6.

[13] Gow, B., Pollard, T., Nathanson, L. A. y colaboradores. MIMIC IV ECG. Diagnostic Electrocardiogram Matched Subset. Version 1.0. PhysioNet, 2023. https://doi.org/10.13026/4nqg-sb35.

[14] Gliner, V., Keidar, N., Makarov, V. y colaboradores. Automatic classification of healthy and disease conditions from images or digital standard 12 lead electrocardiograms. *Scientific Reports*, 10, 16331, 2020. https://doi.org/10.1038/s41598-020-73060-w.

[15] Sangha, V. y colaboradores. Automated multilabel diagnosis on electrocardiographic images and signals. *Nature Communications*, 13, 1583, 2022. https://doi.org/10.1038/s41467-022-29153-3.

[16] Wu, H., Patel, K. H. K., Li, X. y colaboradores. A fully automated paper ECG digitisation algorithm using deep learning. *Scientific Reports*, 12, 20963, 2022. https://doi.org/10.1038/s41598-022-25284-1.

[17] Gliner, V., Makarov, V., Avetisyan, A. I., Schuster, A. y Yaniv, Y. Using domain adaptation for classification of healthy and disease conditions from mobile captured images of standard 12 lead electrocardiograms. *Scientific Reports*, 13, 14023, 2023. https://doi.org/10.1038/s41598-023-40693-6.

[18] Sayadi, O., Shamsollahi, M. B. y Clifford, G. D. Synthetic ECG generation and Bayesian filtering using a Gaussian wave based dynamical model. *Physiological Measurement*, 31(10), 1309–1329, 2010. https://doi.org/10.1088/0967-3334/31/10/002.

[19] Gillette, K. y colaboradores. MedalCare XL. 16 900 healthy and pathological synthetic 12 lead ECGs from electrophysiological simulations. *Scientific Data*, 10, 531, 2023. https://doi.org/10.1038/s41597-023-02416-4.

[20] Lopez Alcaraz, J. M. y Strodthoff, N. Diffusion based conditional ECG generation with structured state space models. arXiv:2301.08227, 2023. https://doi.org/10.48550/arXiv.2301.08227.

[21] Liu, R., Bai, Y., Yue, X. y Zhang, P. Teaching multimodal language models to comprehend 12 lead electrocardiographic images. *npj Digital Medicine*, 9, 349, 2026. https://doi.org/10.1038/s41746-026-02551-3.

[22] Zhang, D., Lan, X., Geng, S. y colaboradores. MEETI. A multimodal ECG dataset from MIMIC IV ECG with signals, images, features and interpretations. *Scientific Data*, 13, 527, 2026. https://doi.org/10.1038/s41597-026-06796-1.

[23] Dong, Q., Li, L., Dai, D., Zheng, C. y colaboradores. A survey on in-context learning. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, 1107–1128, 2024. https://aclanthology.org/2024.emnlp-main.64/.

[24] Alayrac, J. B., Donahue, J., Luc, P. y colaboradores. Flamingo. A visual language model for few shot learning. *Advances in Neural Information Processing Systems*, 35, 23716–23736, 2022. https://arxiv.org/abs/2204.14198.

[25] Chen, S., Han, Z., He, B., Liu, J., Buckley, M., Qin, Y., Torr, P., Tresp, V. y Gu, J. Can multimodal large language models truly perform multimodal in context learning. *IEEE/CVF Winter Conference on Applications of Computer Vision*, 6000–6010, 2025. https://doi.org/10.1109/WACV61041.2025.00585.

[26] Qin, L., Chen, Q., Fei, H., Chen, Z., Li, M. y Che, W. What factors affect multimodal in context learning. An in depth exploration. *Advances in Neural Information Processing Systems*, 37, 2024. https://arxiv.org/abs/2410.20482.

[27] Camba, S., Otero, A., García, D., Sánchez, L. y Costa, N. Can In-Context Learning Enable Large Vision Language Models to Detect ECG Abnormalities? En *Artificial Intelligence in Biomedicine. CIABiomed 2025*, Lecture Notes in Computer Science, vol. 16148, 200–213. Springer, Cham, 2026. https://doi.org/10.1007/978-3-032-10661-2_16.

[28] Ferber, D., Wölflein, G., Wiest, I. C. y colaboradores. In-context learning enables multimodal large language models to classify cancer pathology images. *Nature Communications*, 15, 10104, 2024. https://doi.org/10.1038/s41467-024-51465-9.

[29] Koh, P. W., Nguyen, T., Tang, Y. S., Mussmann, S., Pierson, E., Kim, B. y Liang, P. Concept Bottleneck Models. *Proceedings of the 37th International Conference on Machine Learning*, PMLR 119, 5338–5348, 2020. https://proceedings.mlr.press/v119/koh20a.html.

[30] Costa, N., Otero, A., García Iglesias, D. y Sánchez, L. Few-shot ECG analysis with large vision language models in data-scarce clinical settings. *Computers in Biology and Medicine*, 213, 111816, 2026. https://doi.org/10.1016/j.compbiomed.2026.111816.

[31] Radford, A., Kim, J. W., Hallacy, C. y colaboradores. Learning Transferable Visual Models From Natural Language Supervision. *Proceedings of the 38th International Conference on Machine Learning*, PMLR 139, 8748–8763, 2021. https://proceedings.mlr.press/v139/radford21a.html.

[32] Zhou, K., Yang, J., Loy, C. C. y Liu, Z. Learning to Prompt for Vision-Language Models. *International Journal of Computer Vision*, 130, 2337–2348, 2022. https://doi.org/10.1007/s11263-022-01653-1.

[33] Zhou, K., Yang, J., Loy, C. C. y Liu, Z. Conditional Prompt Learning for Vision-Language Models. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 16816–16825, 2022. https://arxiv.org/abs/2203.05557.

[34] Khattak, M. U., Rasheed, H., Maaz, M., Khan, S. y Khan, F. S. MaPLe: Multi-Modal Prompt Learning. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 19113–19122, 2023. https://openaccess.thecvf.com/content/CVPR2023/html/Khattak_MaPLe_Multi-Modal_Prompt_Learning_CVPR_2023_paper.html.

[35] Ge, C., Huang, R., Xie, M., Lai, Z., Song, S., Li, S. y Huang, G. Domain Adaptation via Prompt Learning. *arXiv*, 2202.06687, 2022. https://arxiv.org/abs/2202.06687.

[36] Shu, M., Nie, W., Huang, D.-A., Yu, Z., Goldstein, T., Anandkumar, A. y Xiao, C. Test-Time Prompt Tuning for Zero-Shot Generalization in Vision-Language Models. *Advances in Neural Information Processing Systems*, 35, 2022. https://proceedings.neurips.cc/paper_files/paper/2022/hash/5bf2b802e24106064dc547ae9283bb0c-Abstract-Conference.html.

[37] Google DeepMind. Gemma 4 model card. Google AI for Developers. https://ai.google.dev/gemma/docs/core/model_card_4.

[38] Google Health AI Developer Foundations. MedGemma 1.5 model card. Google for Developers. https://developers.google.com/health-ai-developer-foundations/medgemma/model-card.

[39] He, K., Zhang, X., Ren, S. y Sun, J. Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770–778, 2016. https://doi.org/10.1109/CVPR.2016.90.

[40] Selvaraju, R. R. y colaboradores. Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE International Conference on Computer Vision*, 618–626, 2017. https://doi.org/10.1109/ICCV.2017.74.

[41] Ganin, Y. y colaboradores. Domain adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59), 1–35, 2016. https://jmlr.org/papers/v17/15-239.html.

[42] Chen, T., Kornblith, S., Norouzi, M. y Hinton, G. A simple framework for contrastive learning of visual representations. *Proceedings of the 37th International Conference on Machine Learning*, PMLR 119, 1597–1607, 2020. https://proceedings.mlr.press/v119/chen20j.html.

[43] Sun, B. y Saenko, K. Deep CORAL. Correlation alignment for deep domain adaptation. En *European Conference on Computer Vision Workshops*, 443–450, 2016. https://arxiv.org/abs/1607.01719.

[44] Long, M., Cao, Y., Wang, J. y Jordan, M. I. Learning transferable features with deep adaptation networks. *Proceedings of the 32nd International Conference on Machine Learning*, PMLR 37, 97–105, 2015. https://proceedings.mlr.press/v37/long15.html.

[45] Tsoumakas, G. y Katakis, I. Multi label classification. An overview. *International Journal of Data Warehousing and Mining*, 3(3), 1–13, 2007. https://doi.org/10.4018/jdwm.2007070101.

[46] Loshchilov, I. y Hutter, F. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019. https://arxiv.org/abs/1711.05101.

[47] Costa Cortez, N. y García Iglesias, D. Brugada-HUCA. 12-Lead ECG Recordings for the Study of Brugada Syndrome. Version 1.0.0. PhysioNet, 2026. https://doi.org/10.13026/0m2w-dy83.

[48] Bossuyt, P. M., Reitsma, J. B., Bruns, D. E. y colaboradores. STARD 2015: an updated list of essential items for reporting diagnostic accuracy studies. *BMJ*, 351, h5527, 2015. https://doi.org/10.1136/bmj.h5527.

[49] Sounderajah, V., Guni, A., Liu, X., STARD-AI Steering Committee y colaboradores. The STARD-AI reporting guideline for diagnostic accuracy studies using artificial intelligence. *Nature Medicine*, 31(10), 3283–3289, 2025. https://doi.org/10.1038/s41591-025-03953-8.

[50] Collins, G. S., Moons, K. G. M., Dhiman, P. y colaboradores. TRIPOD+AI statement. Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378, 2024. https://doi.org/10.1136/bmj-2023-078378.

Índice de figuras

2.1. Esquema de Deep CORAL. El extractor compartido aprende la tarea con las etiquetas del simulador y recibe además una penalización que aproxima las covarianzas de las representaciones del simulador y del HUCA, sin utilizar etiquetas clínicas. 7

3.1. Representación clínica de un ECG real de doce derivaciones a partir del renderizado de un registro de PTB-XL/PhysioNet [12]. 10
3.2. Componentes morfológicos de un latido ECG. La figura identifica las ondas P, Q, R, S y T, el punto J y el segmento ST. 11
3.3. Ejemplos clínicos de morfología asociada al síndrome de Brugada. La imagen izquierda procede de ECGpedia, CC BY-SA 3.0 [8]. La imagen derecha procede de Napolitano y Priori, CC BY 2.0 [9]. 12
3.4. Representación esquemática de rasgos morfológicos asociados al patrón tipo 1 del síndrome de Brugada. 13
3.5. Esquema de demostraciones y consulta en ICL, basado en Dong y colaboradores [23]. 17

4.1. Diseño experimental con preparación de imágenes, entrenamiento de la CNN o consulta de Gemma 4 y evaluación por paciente. 18
4.2. Ejemplo del simulador y trazado clínico V1. 19
4.3. Operaciones de un pliegue de la comparación con los datos clínicos del HUCA. 21

5.1. Generador gaussiano de un latido del simulador. Los parámetros de cada átomo fijan su amplitud, posición y anchura antes de sumar las regiones P, QRS, ST y T. 24
5.2. Distribución de combinaciones de etiquetas derivadas en el conjunto del simulador LOOCV. 28
5.3. Ejemplos generados por el simulador para validar visualmente sus familias. 30

6.1. Entrenamiento supervisado y evaluación de la CNN entrenada con el simulador. 32
6.2. Inspección de la salida RBBB de la CNN entrenada con el simulador mediante Grad-CAM. Se muestran la imagen V1, el mapa normalizado y su superposición. 35
6.3. Consulta con demostraciones y predicción de los tres rasgos del ECG simulado mediante ICL. 36

7.1. Rendimiento de la CNN y Gemma 4 con datos del simulador según el número de ejemplos. Las barras representan la desviación estándar entre semillas. . 38
7.2. Matrices de confusión agregadas en el simulador. Cada matriz suma las predicciones de tres semillas sobre los mismos 100 pacientes. 39
7.3. Transferencia desde el simulador a los ECG clínicos. A la izquierda se comparan las variantes de adaptación de la CNN. A la derecha se muestra Gemma 4 con demostraciones del simulador. 40
7.4. BA y F1 de la CNN y Gemma 4 al aprender con ejemplos del HUCA. Las barras representan la desviación estándar de tres semillas. 42
7.5. Matrices de confusión normalizadas por clase real para la CNN entrenada con selección balanceada de pacientes del HUCA en $K = 16$ y Gemma 4 con demostraciones del HUCA balanceadas en $K = 32$. 43
7.6. Exactitud balanceada de la CNN entrenada en el simulador y evaluada con imágenes del simulador o clínicas, según el número de ejemplos. 44
7.7. Exactitud balanceada de Gemma 4 según el número de ejemplos y el origen de las demostraciones y de la consulta. 45

Índice de tablas

1. Siglas y abreviaturas utilizadas en la memoria. III

4.1. Conjuntos finales. Cada paciente aporta una imagen V1. 18

5.1. Átomos utilizados para construir un latido generado por el simulador 24
5.2. Relación entre familias generadoras y rasgos favorecidos 27
5.3. Criterios de los validadores del simulador 29

7.1. Mejores resultados en el simulador QRS/ST. 37
7.2. Puntos principales de la CNN sobre los datos del HUCA. CORAL y MMD se comparan con sus bases del mismo valor de K. 40
7.3. Mejores configuraciones de la CNN entrenada con el HUCA y de Gemma 4 con demostraciones de ese mismo conjunto. 41

A.1. Configuración del conjunto generado por el simulador. 52
A.2. Configuración de la muestra procesada del HUCA. 53
A.3. Configuración completa de las dos CNN. 54
A.4. Configuración de los experimentos de adaptación de dominio. 55
A.5. Configuración de Gemma 4 con aprendizaje en contexto. 55

B.1. Resultados completos de la CNN entrenada con el simulador y evaluada con datos generados o ECG del HUCA. 56
B.2. Resultados completos de la CNN entrenada directamente con la etiqueta de Brugada del HUCA. 57
B.3. Resultados completos de adaptación no supervisada sobre el conjunto del HUCA. 57
B.4. Resultados de Gemma 4 en el simulador QRS/ST. 58
B.5. Resultados de Gemma 4 sobre la muestra del HUCA con demostraciones del propio conjunto. 59
B.6. Resultados de Gemma 4 sobre los datos del HUCA con demostraciones del simulador. 59