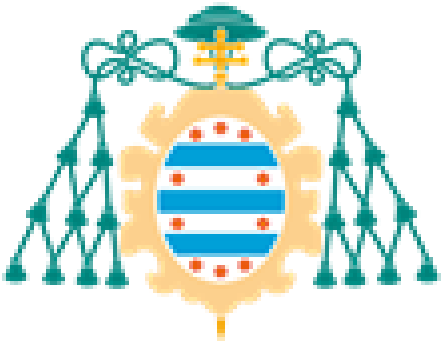


Universidad de Oviedo

UNIVERSIDAD DE OVIEDO

ESCUELA POLITÉCNICA DE INGENIERÍA DE GIJÓN

Análisis de ECGs con grandes modelos de lenguaje: aplicación a enfermedades raras

Trabajo de Fin de Grado

Autor: Alejandro Moris Lara

Tutor: Nahuel Costa Cortez

18 de agosto de 2026

Resumen

Este Trabajo de Fin de Grado estudia el análisis automático de electrocardiogramas disponibles como imágenes, no como series temporales originales. El caso de estudio es la sospecha de síndrome de Brugada, una enfermedad rara para la que resulta difícil reunir conjuntos amplios de pacientes etiquetados. El objetivo es comparar distintas formas de aprovechar pocos ejemplos para priorizar ECG que requieren revisión especializada.

Se comparan dos enfoques: una red convolucional entrenada de forma supervisada y un modelo de visión y lenguaje con aprendizaje en contexto. Ambos reciben una imagen V1 y se evalúan por paciente para $K = \{2, 4, 8, 16, 32\}$. Los experimentos utilizan un simulador QRS/ST con 100 pacientes y una cohorte procesada del Hospital Universitario Central de Asturias (HUCA) con 317.

La ResNet18 aprende tres hallazgos morfológicos a partir de pacientes del simulador. Su evaluación sobre el HUCA mide transferencia sintético-real, ya que la cohorte no contiene anotaciones independientes de RBBB, elevación del ST e inversión de T para entrenar esa cabeza multietiqueta.

Gemma 4 utiliza los ejemplos como demostraciones en el prompt, sin modificar sus pesos. Se comparan zero-shot, ICL estándar con cobertura mínima de ambas clases e ICL balanceado, utilizando contexto sintético o clínico.

En el simulador, la CNN alcanza una *Balanced Accuracy* (BA) de $0,885 \pm 0,013$ en $K = 32$; el ICL balanceado llega a $0,904 \pm 0,011$, frente a 0,500 en zero-shot. Sobre el HUCA, la CNN obtiene su máximo, $0,551 \pm 0,034$, en $K = 4$. MMD eleva el punto de $K = 32$ a $0,546 \pm 0,011$, sin superar ese máximo. Gemma 4 con demostraciones sintéticas permanece cerca de una predicción negativa constante y alcanza $0,514 \pm 0,008$ en $K = 16$. Con demostraciones de la propia cohorte, el ICL balanceado llega a $0,761 \pm 0,011$ en $K = 32$, con sensibilidad de 0,741 y especificidad de 0,781.

Los dos enfoques aprenden la regla del dominio sintético, pero su transferencia mediante ejemplos del simulador es limitada. El aprendizaje en contexto obtiene su mejor resultado cuando las demostraciones representan la tarea clínica local. Ningún modelo dispone aún de evidencia suficiente para un triaje fiable. La principal aportación consiste en cuantificar esta brecha mediante un protocolo documentado y señalar la necesidad de anotaciones morfológicas clínicas, más casos positivos y validación externa.

Palabras clave: electrocardiograma como imagen, síndrome de Brugada, pocos datos etiquetados, aprendizaje supervisado, redes neuronales convolucionales, modelos de visión y lenguaje, aprendizaje en contexto, triaje clínico.

Abstract

This Bachelor's Thesis studies automatic ECG analysis when the electrocardiogram is available as an image rather than as the original time series. The case study is suspected Brugada syndrome, a rare disease for which large labelled cohorts are difficult to assemble. The goal is to compare ways of using a small number of examples to prioritise ECGs for specialist review.

Two approaches are compared: a convolutional network trained under supervision and a vision-language model using in-context learning. Both receive one V1 image and are evaluated at patient level for $K = \{2, 4, 8, 16, 32\}$. The experiments combine a QRS/ST simulator with 100 patients and a processed cohort from the Hospital Universitario Central de Asturias (HUCA) with 317 patients.

The ResNet18 learns three morphological findings from simulator patients. Its HUCA evaluation measures synthetic-to-real transfer because the cohort lacks independent RBBB, ST-elevation and T-wave-inversion annotations for training the multi-label head.

Gemma 4 uses labelled examples as prompt demonstrations without modifying its weights. Zero-shot, standard ICL with minimum coverage of both classes, and balanced ICL are compared using synthetic or clinical context.

On the simulator, the CNN reaches a Balanced Accuracy (BA) of 0.885 ± 0.013 at $K = 32$, while balanced ICL reaches 0.904 ± 0.011, compared with 0.500 in zero-shot. On HUCA, the CNN peaks at 0.551 ± 0.034 for $K = 4$. MMD raises the $K = 32$ point to 0.546 ± 0.011 without surpassing that maximum. Gemma 4 with synthetic demonstrations remains close to a constant negative prediction and reaches 0.514 ± 0.008 at $K = 16$. With demonstrations from the HUCA cohort, balanced ICL reaches 0.761 ± 0.011 at $K = 32$, with 0.741 sensitivity and 0.781 specificity.

Both approaches learn the synthetic rule, but transfer based on simulator examples remains limited. In-context learning performs best when demonstrations represent the local clinical task. Neither model has sufficient evidence for reliable clinical triage. The main contribution is to quantify this gap through a documented protocol and to identify the need for clinical morphology annotations, more positive cases, and external validation.

Keywords: ECG as image, Brugada syndrome, few labelled data, supervised learning, convolutional neural networks, vision-language models, in-context learning, clinical triage.

Glosario de siglas

Este glosario reúne las siglas y abreviaturas que aparecen en la memoria. Se incluye el significado con el que se utilizan dentro del trabajo para mantener una lectura consistente entre capítulos, tablas y apéndices.

Tabla 1.- Siglas y abreviaturas utilizadas en la memoria.

Sigla	Significado	Uso en este trabajo
Acc.	Exactitud	Proporción global de predicciones correctas. Se informa como métrica complementaria en los apéndices.
ACCF	American College of Cardiology Foundation	Sociedad científica citada en recomendaciones de estandarización electrocardiográfica.
AHA	American Heart Association	Sociedad científica citada en guías y recomendaciones clínicas sobre electrocardiografía.
AP	Precisión media	Área bajo la curva precisión-recall. Se usa como métrica complementaria en las tablas completas.
API	Interfaz de programación de aplicaciones	Se menciona al discutir modelos servidos por proveedores externos.
AUC	Área bajo la curva	Resumen escalar de una curva de rendimiento, usado junto a ROC.
aVR, aVL, aVF	Derivaciones aumentadas de miembros	Derivaciones del electrocardiograma convencional citadas al describir el registro de doce derivaciones.
BA	Balanced Accuracy	Métrica principal. Promedia sensibilidad y especificidad para no favorecer a la clase mayoritaria.
BCE	Entropía cruzada binaria	Función de pérdida para clasificación binaria o multietiqueta.
CAM	Mapa de activación de clase	En Grad-CAM relaciona regiones de la imagen con una predicción.
CC BY	Creative Commons Attribution	Licencia de reutilización asociada a una de las imágenes clínicas citadas.
CC BY-SA	Creative Commons Attribution ShareAlike	Licencia de reutilización con atribución y obligación de compartir bajo condiciones equivalentes.

Sigla	Significado	Uso en este trabajo
CNN	Red neuronal convolucional	Modelo supervisado que ajusta pesos a partir de ejemplos etiquetados. En la memoria se concreta en ResNet18.
CORAL	Correlation Alignment	Método de adaptación de dominio incluido como resultado complementario.
CSV	Comma-separated values	Formato tabular utilizado en manifiestos y resultados.
DANN	Domain-Adversarial Neural Network	Método de adaptación de dominio incluido como resultado complementario.
ECG	Electrocardiograma	Trazado cardíaco utilizado como imagen, no como señal digital cruda.
ECGBench	ECG Benchmark	Banco de evaluación multimodal citado en trabajos relacionados.
ECGInstruct	ECG Instruction Dataset	Conjunto de instrucciones con imagen y texto citado en trabajos relacionados.
Esp.	Especificidad	Proporción de pacientes normales identificados correctamente.
F1	Medida F1	Media armónica entre precisión y sensibilidad.
FN	Falso negativo	Caso positivo clasificado como negativo.
FP	Falso positivo	Paciente normal clasificado como positivo.
HRS	Heart Rhythm Society	Sociedad científica citada en recomendaciones clínicas.
HUCA	Hospital Universitario Central de Asturias	Origen de la cohorte de ECG clínicos utilizada en la evaluación.
ICL	Aprendizaje en contexto	Uso de ejemplos etiquetados dentro del prompt sin modificar los pesos del modelo.
ImageNet	ImageNet	Colección de imágenes usada como origen habitual de pesos preentrenados en modelos visuales.
JSON	JavaScript Object Notation	Formato estructurado exigido en las respuestas del modelo multimodal.
K	Número de ejemplos	Tamaño del conjunto usado en cada pliegue. En la CNN indica pacientes de entrenamiento y en el VLM indica demostraciones de contexto.
LOOCV	Validación leave-one-out	Evaluación por paciente reservado. En cada pliegue se deja un paciente fuera.
MEETI	MIMIC ECG Event-based Text-image	Recurso multimodal de electrocardiografía revisado en el estado del arte.

Sigla	Significado	Uso en este trabajo
MIMIC	Medical Information Mart for Intensive Care	Familia de recursos clínicos abiertos citada en trabajos relacionados.
MMD	Maximum Mean Discrepancy	Medida usada como método complementario de adaptación de dominio.
PDF	Portable Document Format	Formato habitual de documento clínico o de intercambio del electrocardiograma renderizado.
PR	Intervalo PR	Intervalo electrocardiográfico entre la activación auricular y ventricular.
Prec.	Precisión	Proporción de predicciones positivas que corresponden a positivos reales.
PTB XL	Physikalisch-Technische Bundesanstalt XL	Conjunto abierto de electrocardiogramas de doce derivaciones citado en trabajos relacionados.
PULSE	PULSE	Modelo multimodal especializado en ECG citado en el estado del arte.
QRS	Complejo QRS	Región asociada a la despolarización ventricular.
QRS/ST	Complejo QRS y segmento ST	Nombre abreviado del dominio sintético utilizado en la memoria.
QT	Intervalo QT	Intervalo electrocardiográfico relacionado con despolarización y repolarización ventricular.
QTc	Intervalo QT corregido	Intervalo QT ajustado por frecuencia cardíaca, mencionado en el contexto clínico.
RBBB	Bloqueo de rama derecha	En el simulador se usa como etiqueta morfológica compatible, no como diagnóstico completo.
ResNet18	Residual Network 18	Arquitectura convolucional utilizada como referencia supervisada.
RGB	Red, green, blue	Representación de imagen con tres canales de color.
ROC	Receiver Operating Characteristic	Curva que relaciona sensibilidad y tasa de falsos positivos.
RSR	Morfología RSR prima	Patrón visual con segunda deflexión positiva terminal en el complejo QRS.
Sens.	Sensibilidad	Proporción de positivos identificados correctamente.
SimCLR	Simple Framework for Contrastive Learning of Visual Representations	Método autosupervisado citado en la configuración complementaria.
SSL	Aprendizaje autosupervisado	Estrategia complementaria de adaptación de dominio incluida en resultados completos.

Sigla	Significado	Uso en este trabajo
ST	Segmento ST	Región posterior al QRS cuya elevación participa en la formulación morfológica del estudio.
TFG	Trabajo de Fin de Grado	Documento académico en el que se enmarca el proyecto.
TN	Verdadero negativo	Paciente normal clasificado correctamente como negativo.
TP	Verdadero positivo	Caso positivo clasificado correctamente como positivo.
TWI	Inversión de onda T	Deflexión tardía negativa utilizada como rasgo visible en el simulador.
V1–V6	Derivaciones precordiales	Derivaciones torácicas del electrocardiograma. En los experimentos se usa exclusivamente V1.
VLM	Modelo de visión y lenguaje	Modelo multimodal que recibe imágenes y texto en un mismo prompt.

Índice general

Resumen I

Abstract II

Glosario de siglas III

1. Introducción **1**

1.1. Motivación clínica 1

1.1.1. Circuito clínico de confirmación 2

1.1.2. Papel del sistema propuesto 2

1.2. Motivación metodológica 3

1.3. Alcance y contribuciones 3

1.4. Estructura de la memoria 3

2. Fundamentos clínicos y técnicos **5**

2.1. Origen y representación del electrocardiograma 5

2.2. Morfología básica de un latido 6

2.3. Hallazgos morfológicos utilizados en el proyecto 7

2.3.1. Síndrome de Brugada como caso motivador y circuito diagnóstico . 8

2.3.2. Morfología compatible con bloqueo de rama derecha 10

2.3.3. Elevación del segmento ST 10

2.3.4. Inversión de la onda T 11

2.4. La señal y la imagen como representaciones 11

2.5. Datos sintéticos y modelos gaussianos 12

2.6. Clasificación multietiqueta 13

2.7. Redes neuronales convolucionales 13

2.8. Modelos de visión y lenguaje 14

2.9. Aprendizaje multimodal en contexto 15

2.10. Explicabilidad y fidelidad 16

2.11. Adaptación de dominio 16

2.12. Implicaciones para el diseño experimental 16

3. Antecedentes y estado del arte **18**

3.1. Alcance de la revisión 18

3.2. Aprendizaje profundo sobre señales electrocardiográficas 18

3.3. Análisis directo de imágenes de ECG . . . 19
3.4. Datos sintéticos para ECG . . . 20
3.5. Conjuntos que integran señal, imagen y texto . . . 20
3.6. Modelos multimodales especializados en ECG . . . 21
3.7. Aprendizaje multimodal en contexto . . . 22
3.8. Modelos abiertos, médicos y propietarios . . . 23
3.9. Hueco de investigación . . . 24

4. Diseño experimental 25
4.1. Planteamiento común . . . 26
4.2. Datos evaluados . . . 26
4.3. Valores de K y validación . . . 27
4.4. Métricas . . . 28

5. El simulador QRS/ST 29
5.1. Objetivo del dominio sintético . . . 29
5.2. Representación matemática . . . 29
5.3. Muestreo temporal . . . 31
5.4. Rangos de parámetros . . . 32
5.5. Familias generadoras . . . 32
5.5.1. Familia normal . . . 32
5.5.2. Morfología RBBB . . . 32
5.5.3. Elevación de ST . . . 33
5.5.4. Inversión de T . . . 33
5.5.5. Familia Brugada . . . 33
5.6. Reglas de coherencia morfológica . . . 34
5.7. Muestreo con rechazo . . . 34
5.8. Validadores y semántica de las etiquetas . . . 35
5.9. Renderizado de las señales . . . 36
5.10. Construcción del conjunto de datos . . . 37
5.11. Comprobación de integración . . . 38
5.12. Riesgos de atajos visuales . . . 38
5.13. Limitaciones del simulador . . . 39

6. Dos enfoques de modelado 40
6.1. Entrada y unidad de análisis . . . 40
6.2. Enfoque supervisado con CNN . . . 40
6.2.1. Qué aprende . . . 40
6.2.2. Riesgos con pocos ejemplos . . . 41

6.3. VLM con ICL . . . 41
6.3.1. Qué cambia frente al entrenamiento . . . 41
6.3.2. Tres condiciones de consulta . . . 41
6.4. Comparación entre enfoques . . . 42
6.5. Enfoque supervisado con CNN ResNet18 . . . 42
6.5.1. Arquitectura y entrada . . . 42
6.5.2. Entrenamiento . . . 43
6.5.3. Evaluación con la cohorte del HUCA . . . 44
6.5.4. Validación por paciente . . . 44
6.5.5. Selección de umbral . . . 44
6.5.6. Adaptación de dominio . . . 45
6.5.7. Grad-CAM . . . 45
6.5.8. Qué se mide . . . 46
6.6. VLM con ICL . . . 46
6.6.1. Motivación . . . 46
6.6.2. Modelos médicos, modelos cerrados y privacidad . . . 46
6.6.3. Modelo evaluado . . . 47
6.6.4. Construcción del prompt . . . 47
6.6.5. Condiciones de consulta . . . 48
6.6.6. Origen del contexto . . . 48

7. Resultados **49**
7.1. Dominio sintético . . . 49
7.2. Cohorte del HUCA . . . 51
7.2.1. Cohorte y unidad experimental . . . 51
7.2.2. Transferencia desde el simulador . . . 53
7.2.3. Contexto clínico y comparación principal . . . 55
7.2.4. Brecha sintético-real . . . 57

8. Conclusiones generales **58**
8.1. Conclusión principal . . . 58
8.2. Aportaciones . . . 58
8.3. Limitaciones . . . 59
8.4. Trabajo futuro . . . 60

9. Aspectos éticos y protección de datos **61**
9.1. Aspectos éticos . . . 61
9.2. Protección de datos . . . 61

A. Configuración experimental **63**
A.1. Conjunto sintético QRS/ST . . . 63
A.2. Cohorte del HUCA . . . 64
A.3. Configuración CNN . . . 65
A.4. Configuración de adaptación de dominio . . . 65
A.5. Configuración VLM/ICL . . . 66

B. Resultados completos **67**
B.1. CNN . . . 67
B.2. Adaptación de dominio de la CNN . . . 68
B.3. VLM con aprendizaje en contexto . . . 68
B.3.1. Dominio sintético . . . 68
B.3.2. Cohorte del HUCA con contexto clínico . . . 69
B.3.3. Cohorte del HUCA con contexto sintético . . . 69

C. Prompts y respuestas estructuradas **70**
C.1. Criterio de conservación . . . 70
C.2. Sistema para tarea morfológica . . . 70
C.3. Tarea morfológica . . . 70
C.4. Sistema para tarea clínica . . . 71
C.5. Tarea clínica directa . . . 71
C.6. Construcción del contexto . . . 72

Bibliografía **73**

Índice de figuras **78**

Índice de tablas **80**

Capítulo 1. Introducción

Este Trabajo de Fin de Grado estudia el análisis automático de electrocardiogramas a partir de la imagen del trazado, en lugar de utilizar la serie temporal original. Este planteamiento permite evaluar qué información morfológica puede aprovecharse cuando no se dispone de las muestras digitales de la señal.

El caso de estudio es la sospecha de síndrome de Brugada, una canalopatía hereditaria poco frecuente asociada al riesgo de arritmias ventriculares y muerte súbita. La escasez de pacientes confirmados dificulta el entrenamiento y la evaluación de modelos con los volúmenes de datos habituales en aprendizaje profundo.

La pregunta metodológica es cómo analizar ECG como imágenes cuando solo se dispone de unos pocos pacientes etiquetados. La representación visual conserva información morfológica, pero prescinde de parte de la estructura de la señal original.

Para responder a esta pregunta se comparan dos formas de aprovechar el mismo conjunto reducido de pacientes etiquetados. En la primera, una red neuronal convolucional (CNN) actualiza sus pesos a partir de K pacientes de entrenamiento. En la segunda, un modelo de visión y lenguaje (VLM) mantiene sus pesos fijos y recibe K demostraciones dentro del contexto. Por tanto, K expresa el número de ejemplos disponibles para cada método, aunque su función sea distinta en el entrenamiento supervisado y en el aprendizaje en contexto.

1.1.- MOTIVACIÓN CLÍNICA

El síndrome de Brugada es un trastorno arrítmico hereditario relacionado con alteraciones de los canales de sodio cardíacos. Predispone a fibrilación ventricular y muerte súbita, especialmente en varones jóvenes durante el reposo o el sueño [1, 7]. Su prevalencia estimada se sitúa entre una de cada 2 000 y una de cada 5 000 personas. Sin embargo, es probable que esté infradiagnosticado porque muchos portadores permanecen asintomáticos.

El patrón electrocardiográfico tipo 1 se caracteriza por una elevación del segmento ST de morfología convexa de al menos 2 mm en una derivación precordial derecha, seguida de una onda T negativa [7]. Los patrones tipo 2 y tipo 3 no son diagnósticos por sí solos. También existen fenocopias producidas por fiebre, alteraciones electrolíticas, isquemia o fármacos. Estas pueden imitar el trazado y deben excluirse antes de confirmar la enfermedad [6].

La dificultad aumenta porque el patrón tipo 1 puede ser intermitente. Un ECG basal normal no descarta el síndrome y un trazado sospechoso debe interpretarse dentro del contexto

clínico. Esa variabilidad convierte Brugada en un buen caso para estudiar métodos de apoyo a la revisión del ECG, ya que obliga a distinguir entre reconocer un patrón visual y establecer una conclusión clínica.

1.1.1.- Circuito clínico de confirmación

Ante una sospecha de Brugada, el circuito asistencial sigue una secuencia de complejidad creciente:

1. **ECG estándar de 12 derivaciones.** Se revisan especialmente V1 y V2 en busca de patrones sugestivos.
2. **Revisión por especialista.** Un cardiólogo o electrofisiólogo valora el trazado, la historia clínica y los antecedentes familiares.
3. **Reposicionamiento de V1/V2.** Si la sospecha persiste, se registra un nuevo ECG colocando V1 y V2 en espacios intercostales superiores para aumentar la sensibilidad [6].
4. **Prueba farmacológica.** En pacientes seleccionados se administra un bloqueante del canal de sodio, como ajmalina o flecainida, en un entorno monitorizado con capacidad de reanimación [8].
5. **Decisión clínica.** El diagnóstico y las decisiones terapéuticas corresponden al equipo médico.

1.1.2.- Papel del sistema propuesto

El sistema se evalúa como posible apoyo previo a la confirmación diagnóstica, limitado a priorizar la revisión de trazados sospechosos. En este marco, una predicción positiva indica que el ECG debe revisarse con mayor atención dentro del circuito clínico habitual. La valoración especializada, la indicación de pruebas complementarias y las decisiones terapéuticas quedan fuera del alcance del modelo.

Este alcance condiciona la interpretación de las métricas. En una enfermedad de baja prevalencia, un clasificador con sensibilidad alta puede generar muchas alertas no confirmadas si su especificidad es insuficiente. Aumentar la sensibilidad reduce el riesgo de retrasar la revisión de un caso sospechoso, pero suele incrementar los falsos positivos y la carga sobre el circuito asistencial. La evaluación debe considerar, por tanto, tanto la capacidad de detectar positivos como la proporción de pacientes normales derivados de forma innecesaria.

1.2.- MOTIVACIÓN METODOLÓGICA

Los modelos profundos han alcanzado un buen rendimiento en el análisis de ECG cuando disponen de grandes colecciones de pacientes y etiquetas consistentes [12, 16]. Estas condiciones rara vez se cumplen en enfermedades de baja prevalencia. En Brugada, cada caso confirmado exige revisión especializada y, en muchos pacientes, información clínica adicional o una prueba farmacológica.

La comparación metodológica se organiza alrededor de K. En la línea supervisada, una ResNet18 ajusta sus pesos con los K pacientes etiquetados y produce un clasificador específico para la tarea. En la línea multimodal, Gemma 4 mantiene sus pesos fijos y recibe K ejemplos en el prompt como pares imagen-respuesta [29].

La diferencia entre ambos enfoques reside en cómo incorporan la información de los ejemplos. La CNN los utiliza para calcular el gradiente durante el entrenamiento, mientras que el VLM los interpreta como demostraciones de contexto durante la inferencia. El experimento compara ambas alternativas con un número reducido de pacientes etiquetados. El aprendizaje en contexto evita entrenar un modelo nuevo para cada conjunto local, pero solo resulta útil si las demostraciones mejoran la predicción sin degradar en exceso la especificidad.

1.3.- ALCANCE Y CONTRIBUCIONES

El estudio se limita a un análisis experimental y retrospectivo de métodos de aprendizaje con pocos datos etiquetados. Sus resultados no validan un producto sanitario ni permiten estimar su utilidad clínica prospectiva. La comparación utiliza dos tipos de referencia. En el dominio sintético, las etiquetas se derivan de reglas aplicadas a tres hallazgos morfológicos del trazado. En la cohorte del HUCA, la etiqueta se asigna por paciente y distingue entre casos de Brugada confirmados y pacientes normales.

El trabajo aporta un protocolo para estudiar ECG como imágenes, un simulador QRS/ST revisado y el procesamiento de 317 pacientes del HUCA. También establece una referencia basada en CNN para los dominios sintético y real y evalúa Gemma 4 en zero-shot, ICL estándar e ICL balanceado.

1.4.- ESTRUCTURA DE LA MEMORIA

La memoria se organiza desde el contexto del problema hasta la comparación de los métodos. El capítulo 3 sitúa el trabajo frente al estado del arte. El capítulo 2 introduce los fundamentos clínicos y técnicos. El capítulo 4 formula el protocolo común. El capítulo 5 describe

el simulador. El capítulo 6 presenta la comparación entre entrenamiento supervisado y aprendizaje en contexto.

Dentro del capítulo de modelado, las secciones 6.5 y 6.6 desarrollan la CNN y el enfoque VLM/ICL sin mezclar método y resultados. El capítulo 7 compara ambos enfoques en el simulador y en los ECG reales. El capítulo 8 cierra la interpretación científica y el capítulo 9 recoge la gestión ética, regulatoria y de privacidad.

Capítulo 2. Fundamentos clínicos y técnicos

2.1.- ORIGEN Y REPRESENTACIÓN DEL ELECTROCARDIOGRAMA

El electrocardiograma registra las diferencias de potencial producidas por la actividad eléctrica del corazón. La señal de una derivación no corresponde a una estructura anatómica aislada, sino a la proyección de un proceso eléctrico tridimensional sobre el eje definido por sus electrodos. Una misma activación puede generar, por tanto, deflexiones distintas según la derivación desde la que se observe.

El ECG convencional obtiene doce derivaciones a partir de diez electrodos. I, II, III, aVR, aVL y aVF describen la actividad en el plano frontal, mientras que V1 a V6 ofrecen una perspectiva precordial en el plano horizontal. La apariencia final depende de la colocación de los electrodos, la ganancia, la velocidad de registro y el filtrado. Las recomendaciones de estandarización exigen conservar estos parámetros, ya que cualquier cambio puede alterar amplitudes, duraciones y relaciones espaciales utilizadas durante la interpretación [2].

La representación clínica habitual emplea una velocidad de 25 mm por segundo y una ganancia de 10 mm por mV. Con esta convención, un milímetro horizontal equivale a 40 ms y uno vertical, a 0,1 mV. Estas relaciones permiten estimar intervalos y amplitudes directamente sobre el trazado. Sin embargo, la escala física puede perderse al exportarlo como imagen digital si esta se redimensiona, se recorta o se guarda sin una referencia. La Figura 2.1 muestra un ejemplo del formato clínico original.

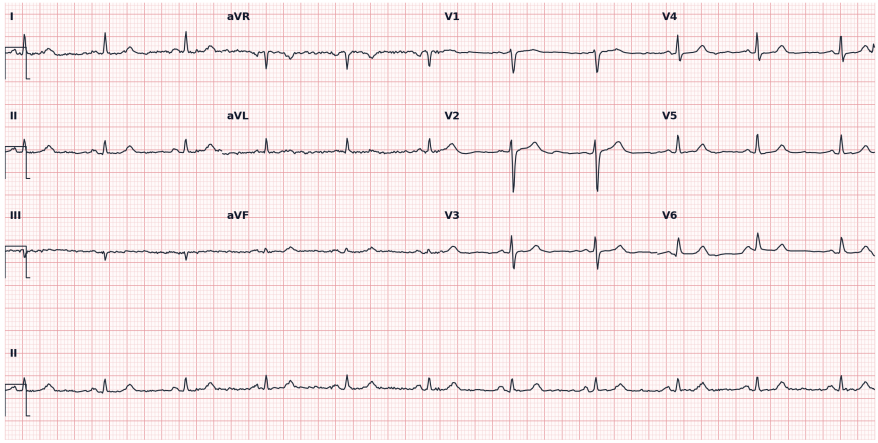


Figura 2.1.- Representación clínica de un ECG real de doce derivaciones renderizado desde un registro de PTB-XL/PhysioNet [13].

2.2.- MORFOLOGÍA BÁSICA DE UN LATIDO

Un latido normal se describe mediante una secuencia de ondas, intervalos y segmentos. La onda P refleja la despolarización auricular y el intervalo PR, la propagación desde las aurículas hasta el sistema de conducción ventricular. El complejo QRS representa la despolarización ventricular. A continuación, el punto J marca el final del QRS y el comienzo del segmento ST, y la onda T se relaciona con la repolarización ventricular. La Figura 2.2 sitúa estos componentes en un latido.

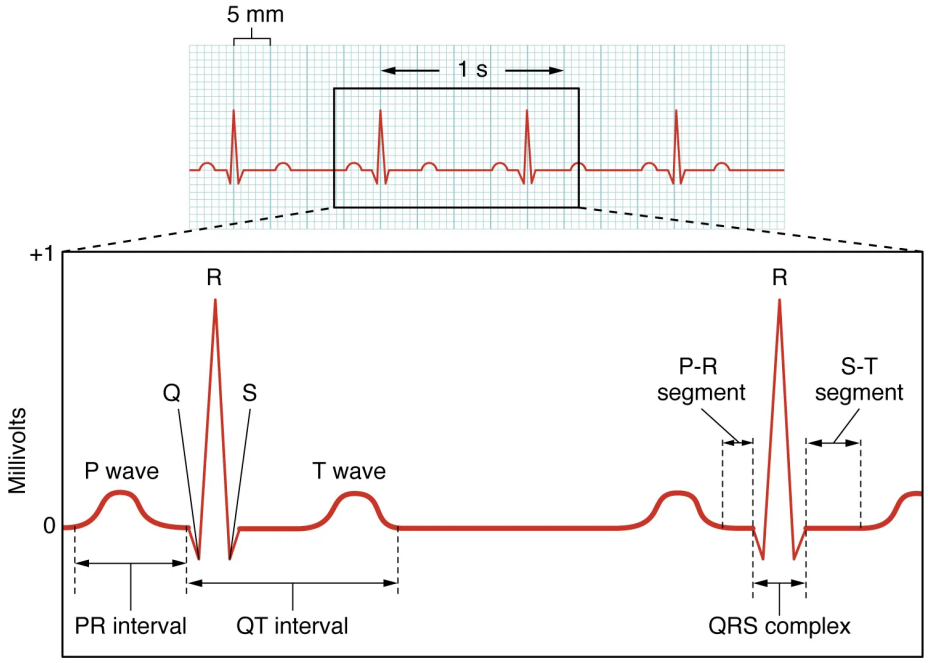


Figura 2.2.- Componentes morfológicos de un latido ECG: onda P, complejo QRS, onda T, segmentos PR y ST, e intervalos PR y QT. Fuente: OpenStax [5].

Las letras Q, R y S no designan posiciones anatómicas fijas, sino la sucesión de deflexiones del complejo ventricular. Q es la primera deflexión negativa anterior a una positiva; R, la primera deflexión positiva; y S, la deflexión negativa posterior a R. Una segunda deflexión positiva se denomina R prima. Esta nomenclatura describe la geometría de la señal y no establece por sí sola un diagnóstico.

El segmento ST se evalúa respecto de una referencia isoeléctrica, que en un registro real puede aproximarse mediante el segmento TP o el PR según el contexto. Su elevación o depresión no se interpreta de forma aislada: también importan la derivación, la magnitud, la morfología, la distribución espacial y el cuadro clínico. Por esta razón, las recomendaciones de la AHA, el ACCF y la HRS describen por separado el segmento ST, la onda T y el intervalo QT [4].

La polaridad de la onda T también depende de la derivación. Una deflexión negativa puede ser fisiológica en algunas posiciones y patológica en otras. Su significado varía con la edad, el sexo, la secuencia de activación ventricular, los cambios del segmento ST y otras alteraciones. En este trabajo, la inversión de T se trata como un rasgo morfológico que debe interpretarse junto con el resto del ECG y el contexto clínico.

2.3.- HALLAZGOS MORFOLÓGICOS UTILIZADOS EN EL PROYECTO

2.3.1.- Síndrome de Brugada como caso motivador y circuito diagnóstico

El síndrome de Brugada es una canalopatía hereditaria del canal de sodio, asociada con frecuencia a mutaciones en el gen *SCN5A*, que predispone a fibrilación ventricular y muerte súbita cardíaca. Su prevalencia se estima entre 1 y 5 casos por cada 10 000 personas. Aunque predomina en varones adultos jóvenes, puede manifestarse a cualquier edad. Su relevancia clínica deriva de la asociación con arritmias malignas [6].

El hallazgo electrocardiográfico central es el patrón tipo 1, también denominado *coved*. Se caracteriza por una elevación descendente del segmento ST de al menos 2 mm en las derivaciones precordiales derechas V1 o V2, seguida de una onda T negativa. Es el único patrón considerado diagnóstico por las guías vigentes [1]. Los patrones tipo 2 y tipo 3, descritos históricamente, no bastan por sí solos para establecer el diagnóstico.

Los criterios diagnósticos han cambiado con el tiempo. En la actualidad, se acepta el patrón tipo 1, espontáneo o inducido, cuando se han descartado otras causas que puedan explicarlo [1]. La interpretación incorpora además el contexto clínico. El síncope inexplicado, la respiración agónica nocturna, los antecedentes familiares de muerte súbita y las arritmias ventriculares documentadas refuerzan la sospecha y orientan la estratificación del riesgo.

2.3.1.1.- Circuito diagnóstico clínico

El diagnóstico del síndrome de Brugada combina el ECG con la valoración clínica y no puede reducirse al reconocimiento automático de un patrón en una imagen:

1. **ECG basal de 12 derivaciones.** La evaluación comienza con un ECG estándar. Si aparece un patrón tipo 1 espontáneo en V1 o V2, el diagnóstico puede establecerse después de excluir fenocopias y otras causas de elevación del ST.

2. **Recolocación de derivaciones precordiales.** Cuando el ECG basal es sospechoso pero no concluyente, las guías recomiendan registrar V1 y V2 en espacios intercostales superiores (segundo o tercero en lugar del cuarto estándar). Esta posición acerca los electrodos al tracto de salida del ventrículo derecho y aumenta la sensibilidad para detectar el patrón tipo 1 [8].

3. **Valoración clínica integral.** Se revisan los síntomas actuales y pasados, la historia familiar de muerte súbita o síndrome de Brugada confirmado y las comorbilidades. También se comprueba la exposición a fármacos o situaciones que puedan provocar fenocopias (fiebre, trastornos electrolíticos o isquemia).

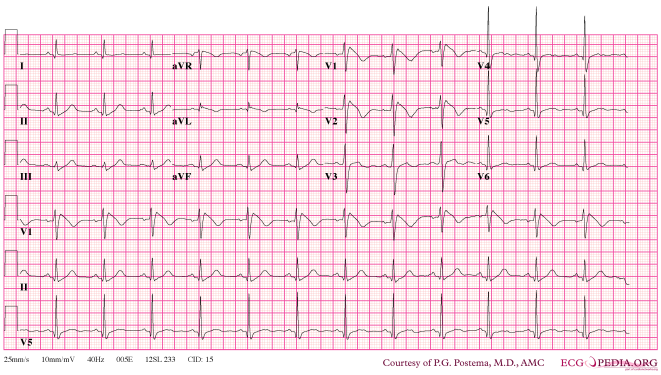
4. **Prueba farmacológica con bloqueantes del canal de sodio.** En pacientes seleccionados con sospecha persistente y un ECG basal no diagnóstico, se realiza una prueba de

provocación farmacológica. Se emplean bloqueantes del canal de sodio de clase I, como ajmalina, flecainida, procainamida o pilsicainida, según la disponibilidad local [7]. La prueba requiere un entorno monitorizado, personal entrenado y equipo de desfibrilación. Se considera positiva si aparece un patrón tipo 1 durante o después de administrar el fármaco, y no está indicada cuando este patrón ya se presenta de forma espontánea.

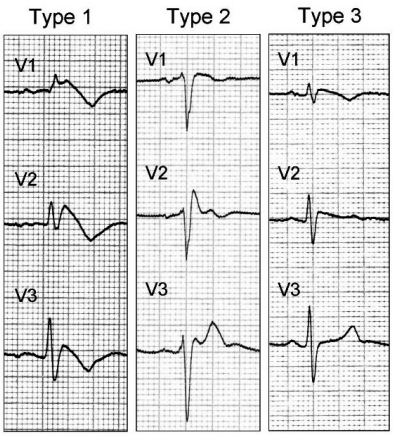
5. **Estudio genético.** Se recomienda la evaluación del gen *SCN5A* en pacientes índice para apoyar la caracterización molecular y facilitar el cribado familiar.

6. **Decisión clínica final.** La decisión sobre estratificación de riesgo y tratamiento es siempre clínica, multifactorial y realizada por especialistas.

Este circuito delimita el alcance de cualquier resultado automático. En este trabajo, una predicción positiva se interpreta únicamente como una señal para priorizar la revisión del trazado. La indicación de una prueba farmacológica, su interpretación y las decisiones posteriores permanecen bajo responsabilidad médica [7]. La Figura 2.3 reúne ejemplos de la morfología considerada.



(a) ECG con morfología tipo 1 en V1 y V2.



(b) Patrones tipo 1–3.

Figura 2.3.- Ejemplos clínicos de morfología Brugada. La imagen izquierda procede de ECGpedia, CC BY-SA 3.0 [9]. La imagen derecha procede de Napolitano y Priori, CC BY 2.0 [10].

El patrón tipo 1 puede recordar a una alteración terminal del QRS, pero no equivale a un bloqueo de rama derecha. La onda J del patrón de Brugada se concentra en las derivaciones precordiales derechas y no requiere la onda S lateral recíproca propia del bloqueo de rama derecha [11]. La semejanza con RBBB se utiliza aquí como descripción morfológica, no como criterio clínico de Brugada. La Figura 2.4 resume los rasgos considerados en el trabajo.

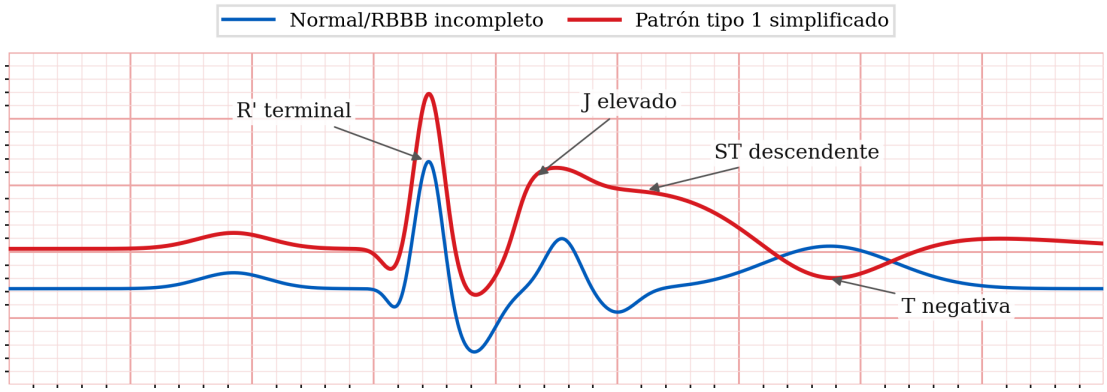


Figura 2.4.- Representación esquemática de rasgos morfológicos asociados al patrón tipo 1 de Brugada.

2.3.2.- Morfología compatible con bloqueo de rama derecha

El bloqueo de rama derecha es una alteración de la conducción intraventricular. En su forma completa se caracteriza por una duración del QRS igual o superior a 120 ms y por una morfología terminal compatible en las derivaciones apropiadas. Las recomendaciones de estandarización describen patrones como rsR prima o rSR prima en V1 o V2, junto con una onda S ensanchada en derivaciones laterales [3].

La activación tardía del ventrículo derecho produce la segunda deflexión positiva en las derivaciones precordiales derechas. Sin embargo, una forma semejante a rsR prima en una sola derivación no basta para diagnosticar un bloqueo completo. También deben considerarse la duración global del QRS, la morfología en I y V6, la posición de los electrodos y otras causas de retraso terminal. En esta memoria, RBBB designa un rasgo visual compatible, no un diagnóstico completo de bloqueo.

2.3.3.- Elevación del segmento ST

El segmento ST comienza en el punto J y termina con el inicio de la onda T. Su desplazamiento se mide con respecto a una referencia isoeléctrica. La magnitud clínicamente relevante depende de la derivación, del sexo, de la edad y de la situación diagnóstica. Además, una elevación puede aparecer en contextos diferentes, entre ellos isquemia aguda, pericarditis, repolarización precoz, alteraciones de conducción y síndromes de onda J.

Un modelo visual puede aprender a reconocer una región elevada después del QRS sin distinguir por ello un patrón de Brugada, un infarto agudo u otra causa. Esta diferenciación requeriría varias derivaciones, contexto clínico y un conjunto de etiquetas mucho más amplio.

2.3.4.- Inversión de la onda T

La onda T refleja la repolarización ventricular y suele aparecer después del segmento ST. Su polaridad normal varía entre derivaciones. También puede modificarse como consecuencia secundaria de una secuencia anómala de despolarización. Por ejemplo, una alteración de conducción puede producir cambios discordantes del segmento ST y de la onda T.

La inversión de T es una propiedad visual localizada que debe interpretarse dentro del ECG completo. Por sí sola no permite determinar si es primaria, secundaria, fisiológica o patológica. En este trabajo se utiliza como rasgo morfológico, no como diagnóstico aislado.

2.4.- LA SEÑAL Y LA IMAGEN COMO REPRESENTACIONES

Una señal digital conserva muestras de amplitud ordenadas en el tiempo, lo que permite medir intervalos, aplicar filtros y comparar derivaciones con una escala conocida. La imagen surge al renderizar esas muestras. Conserva la forma visible del trazado, pero incorpora también las decisiones adoptadas durante su presentación.

El renderizado determina el tamaño del lienzo, la cuadrícula, el grosor de la línea, los márgenes y la disposición de las derivaciones. Si alguno de estos elementos se correlaciona con la etiqueta, una red puede utilizarlo como atajo. El conjunto de imágenes debe evitar, por tanto, que la clase pueda deducirse de una marca, un recorte o una diferencia de resolución.

La imagen ofrece una alternativa práctica cuando la señal original no está disponible. Sangha y colaboradores evaluaron un modelo multietiqueta sobre ECG renderizados, registros externos y trazados impresos [16]. Gliner y colaboradores estudiaron también el uso de una CNN con fotografías de ECG y aplicaron estrategias específicas para adaptar el formato de entrada [18].

Otra posibilidad consiste en digitalizar primero la imagen. Wu y colaboradores desarrollaron una herramienta automática para segmentar trazados impresos y reconstruir las señales [17]. Este proceso permite reutilizar modelos temporales, pero puede introducir errores cuando las derivaciones se solapan o la calidad del documento es baja. El análisis directo de la imagen y la digitalización responden, por tanto, a compromisos distintos y no son excluyentes.

La doble representación del ECG como señal temporal e imagen motiva la comparación entre CNN y VLM. Una CNN entrenada con pocos ejemplos debe aprender la tarea a partir de los píxeles disponibles y de sus pesos iniciales. Un modelo de visión y lenguaje parte, además, de representaciones visuales y textuales adquiridas durante el preentrenamiento. El experimento evalúa si esta diferencia permite aprovechar mejor un conjunto etiquetado pequeño.

2.5.- DATOS SINTÉTICOS Y MODELOS GAUSSIANOS

Los datos sintéticos permiten aislar factores difíciles de separar en una colección clínica. Con ellos se pueden generar clases equilibradas, registrar los parámetros que originan cada señal y repetir el proceso. También permiten desarrollar las primeras fases del método sin utilizar información de pacientes.

La síntesis no elimina las limitaciones de los datos, sino que las desplaza al proceso de generación. Su validez depende de que las reglas representen los rasgos estudiados sin introducir atajos visuales. Una morfología demasiado regular puede facilitar la clasificación y, al mismo tiempo, aportar poca información sobre el comportamiento en registros reales.

Las ondas gaussianas se han utilizado anteriormente para representar ECG. Sayadi y colaboradores describieron un modelo dinámico basado en ellas para generar señales y realizar filtrado bayesiano [19]. Este proyecto utiliza una variante más sencilla y directamente parametrizable. Cada componente se define como

$$g_i(t) = a_i \exp\left(-\frac{(t-\mu_i)^2}{2\sigma_i^2}\right), \tag{2.1}$$

donde a_i define la amplitud, μ_i determina la posición temporal y σ_i regula la anchura. El latido completo se obtiene mediante

$$x(t) = \sum_{i=1}^{M} g_i(t). \tag{2.2}$$

La suma incluye componentes para P, Q, R, S, R prima, punto J, segmento ST y onda T. Sus parámetros se muestrean en intervalos específicos de cada familia generadora y se someten después a relaciones temporales que preservan el orden del latido. Por último, un validador comprueba que la señal cumpla las condiciones mínimas de la familia solicitada.

El procedimiento corresponde a un muestreo con rechazo: las señales que no superan el validador se descartan y se generan de nuevo. Esta estrategia mejora la consistencia interna, pero puede concentrar las muestras en las regiones aceptadas por las reglas. Por ello, la verificación de calidad debe incluir la tasa de aceptación y la distribución de los parámetros.

Los simuladores de mayor fidelidad emplean modelos electrofisiológicos y geometrías cardíacas completas. MedalCare XL, por ejemplo, ofrece miles de ECG sintéticos de doce derivaciones obtenidos mediante simulaciones electrofisiológicas [20]. Su objetivo es el realismo fisiológico y exige un coste computacional mayor. El simulador de este TFG prioriza, en cambio, la interpretación y el ajuste local de las reglas, por lo que ambos enfoques no son equivalentes.

2.6.- CLASIFICACIÓN MULTIETIQUETA

En clasificación multiclase, cada ejemplo se asigna a una categoría exclusiva. En clasificación multietiqueta, una muestra puede asociarse con varias etiquetas. Esta formulación permite representar hallazgos que coexisten [37].

Sea L el número de etiquetas. Para una imagen x, la referencia se representa mediante un vector

$$\mathbf{y} = (y_1, \ldots, y_L), \qquad y_j \in \{0, 1\}. \tag{2.3}$$

Una red convolucional produce un logit z_j por etiqueta. La función sigmoide transforma cada logit en una probabilidad independiente

$$\hat{p}_j = \frac{1}{1 + \exp(-z_j)}. \tag{2.4}$$

La pérdida habitual es la entropía cruzada binaria

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{L} \sum_{j=1}^{L} \left[y_j \log(\hat{p}_j) + (1 - y_j) \log(1 - \hat{p}_j) \right]. \tag{2.5}$$

La independencia de las salidas no implica que las etiquetas sean estadísticamente independientes. La red puede aprender representaciones compartidas y aprovechar sus coocurrencias. Sin embargo, una asociación demasiado rígida puede crear atajos. Si todas las ondas T negativas aparecen junto con elevación del ST, el modelo puede predecir una etiqueta a partir de la otra sin observar la región correspondiente.

La decisión binaria requiere un umbral. El valor 0,5 ofrece una referencia común, aunque no tiene por qué ser óptimo para todas las etiquetas. Los umbrales deben fijarse con el conjunto de validación y mantenerse durante el test. Ajustarlos con el conjunto de prueba produciría una estimación optimista.

Los modelos de visión y lenguaje no devuelven una probabilidad sigmoide, sino texto o un objeto estructurado. Para evaluarlos, la respuesta debe convertirse en un vector binario y las salidas que incumplan el esquema deben registrarse por separado. El protocolo incorpora esta diferencia al comparar ambos tipos de modelo.

2.7.- REDES NEURONALES CONVOLUCIONALES

Una convolución aplica filtros compartidos sobre regiones locales de una imagen. Las primeras capas responden a transiciones y contornos; las posteriores combinan esas respuestas en patrones de mayor escala. En una imagen de ECG, la red puede aprender inclinaciones,

picos, valles y relaciones entre regiones temporales.

Los pesos compartidos aportan cierta tolerancia a desplazamientos pequeños. No obstante, el ECG no es completamente invariante a la posición: una deflexión negativa tiene un significado distinto dentro del QRS y en la región de la onda T. La arquitectura debe conservar suficiente información espacial y el preprocesado, alinear los latidos.

La referencia convolucional de este trabajo es una ResNet18 preentrenada. Sus conexiones residuales facilitan la optimización de redes profundas al aprender transformaciones relativas a la entrada de cada bloque [31]. Los pesos de ImageNet no garantizan una ventaja en ECG, pero proporcionan filtros iniciales para contornos, trazos y texturas cuando hay pocos ejemplos etiquetados.

La evaluación debe comprobar si esta transferencia visual se mantiene fuera del simulador. Un resultado alto en imágenes sintéticas podría deberse, en parte, al aprendizaje de reglas de renderizado. Una reducción en el dominio clínico sería compatible con el efecto del ruido, la variabilidad clínica o las diferencias en la definición de las etiquetas. Esta limitación motiva el estudio de alternativas al entrenamiento supervisado con pocos ejemplos.

2.8.- MODELOS DE VISIÓN Y LENGUAJE

Un modelo de visión y lenguaje (VLM) combina una representación visual con un modelo generativo de texto. La imagen se transforma en vectores a los que el componente lingüístico atiende durante la generación. La salida puede ser una respuesta libre, una explicación o una estructura con campos definidos. A diferencia de una CNN dedicada a la clasificación, el VLM relaciona la entrada visual con las representaciones textuales adquiridas durante el preentrenamiento.

Flamingo mostró que un modelo multimodal entrenado con secuencias intercaladas de imagen y texto podía adaptarse a distintas tareas mediante ejemplos incluidos en el contexto [25]. Este procedimiento no actualiza los pesos del modelo. Las demostraciones indican durante la inferencia la relación esperada entre la entrada y la salida.

Esta propiedad resulta pertinente cuando solo se dispone de pocos ejemplos etiquetados de un fenómeno infrecuente como el patrón de Brugada. En esas condiciones, una CNN puede no recibir datos suficientes para ajustar sus parámetros. El VLM parte de representaciones visuales y textuales previas, aunque no se presupone que estas incluyan conocimiento útil sobre ECG. El TFG evalúa si ese punto de partida mejora el rendimiento con un conjunto etiquetado pequeño.

Los modelos multimodales médicos ocupan una posición intermedia entre los modelos generalistas y los sistemas entrenados para una sola tarea. MedGemma 1.5 es un modelo médico abierto de la familia Gemma, adaptado a modalidades como radiología, histopatología,

dermatología, fondo de ojo, documentos y registros clínicos [30]. Su documentación no incluye el ECG entre las modalidades principales y recomienda validar el modelo de forma específica antes de aplicarlo a una tarea concreta.

La evaluación cuantitativa utiliza Gemma 4 E4B, un VLM de pesos abiertos que admite texto e imagen y permite ajustar el presupuesto de tokens visuales [29]. Un presupuesto mayor conserva más detalle, pero aumenta el coste computacional. El modelo se ejecuta mediante vLLM en infraestructura universitaria y se consulta a través de un endpoint compatible con la API de OpenAI.

2.9.- APRENDIZAJE MULTIMODAL EN CONTEXTO

El aprendizaje en contexto (ICL) se estudia en este TFG como alternativa al entrenamiento supervisado. El modelo recibe una secuencia de demostraciones

$$\mathcal{D}_K = \{(x_1, y_1), \ldots, (x_K, y_K)\} \tag{2.6}$$

antes de la consulta objetivo x^*. El modelo genera una estimación condicionada por la instrucción y por las demostraciones

$$\hat{y}^* = f_\theta\left(x^*, \mathcal{D}_K, \text{instrucción}\right), \tag{2.7}$$

sin modificar los parámetros θ. La CNN utiliza los K ejemplos etiquetados para actualizar sus pesos, mientras que el VLM los recibe dentro del prompt. En este último caso, los pesos permanecen fijos y las demostraciones condicionan la generación de la respuesta.

Esta formulación permite comparar ambos enfoques mediante el número de ejemplos K. Con el mismo valor, la CNN ajusta sus pesos para distinguir los patrones visuales y el VLM utiliza los ejemplos como guía dentro del prompt. El experimento estudia cómo cambia el rendimiento de cada método al aumentar K, sin asumir de antemano un umbral a partir del cual uno de ellos sea preferible.

El número de ejemplos no determina por sí solo la calidad del contexto. También influyen su selección, diversidad y orden, así como la coherencia entre cada imagen y su etiqueta. Qin y colaboradores identificaron la recuperación multimodal, el orden interno de las demostraciones y la posición de la instrucción como factores relevantes [27].

Chen y colaboradores observaron que varios modelos podían depender más del texto que de la información visual de las demostraciones [26]. Este resultado aconseja interpretar el ICL con cautela. La comparación de esta memoria distingue entre zero-shot, ICL estándar e ICL balanceado. Una mejora respecto a zero-shot sería consistente con un efecto útil del contexto. Las diferencias entre las dos variantes de ICL permitirían valorar, además, la influencia de la

composición de las demostraciones.

2.10.- EXPLICABILIDAD Y FIDELIDAD

Los mapas de activación de clase permiten visualizar qué regiones de una imagen influyen en una salida. Grad-CAM utiliza los gradientes de una clase para ponderar los mapas de activación de una capa convolucional [32]. En una tarea de ECG, se espera que las regiones resaltadas difieran entre el QRS, el segmento ST y la onda T.

Un mapa visual no establece causalidad clínica. Su resolución suele ser inferior a la de la imagen de entrada y el resultado depende de la capa seleccionada. También puede señalar una región amplia aunque el modelo utilice un artefacto local. En este proyecto se emplea para detectar comportamientos incompatibles con la tarea, no para certificar una explicación.

Las explicaciones generadas por un modelo de visión y lenguaje presentan otra limitación. El texto puede describir correctamente la morfología sin que esa descripción haya determinado la predicción. La plausibilidad lingüística y la fidelidad del razonamiento son propiedades distintas. Por ello, la evaluación principal utiliza respuestas estructuradas y analiza las justificaciones como un resultado cualitativo separado.

2.11.- ADAPTACIÓN DE DOMINIO

El dominio sintético y el dominio real difieren en fisiología, adquisición y presentación. El simulador genera un único latido alineado, con una cuadrícula uniforme y sin variabilidad entre pacientes. Un ECG real contiene ruido, deriva de línea base, diferencias de frecuencia cardíaca, trazos superpuestos, anotaciones y múltiples derivaciones.

Una red puede obtener un rendimiento elevado en el dominio sintético y fallar en el clínico si aprende características exclusivas del renderizado. El interés no reside solo en comprobar si la CNN aprende las reglas sintéticas, sino también en determinar si la representación conserva utilidad ante ECG clínicos. Esta diferencia entre dominios se evalúa de forma específica sobre la cohorte del HUCA.

2.12.- IMPLICACIONES PARA EL DISEÑO EXPERIMENTAL

Estos fundamentos determinan las principales decisiones experimentales. Las etiquetas se definen como hallazgos morfológicos y la salida se interpreta como apoyo a la revisión. Ambos enfoques reciben la misma imagen objetivo y el mismo número de ejemplos K. La

diferencia reside en su uso: la CNN actualiza sus pesos con ellos y el VLM los recibe como demostraciones dentro del contexto.

En el conjunto sintético, cada imagen se genera de forma independiente y no existe una agrupación clínica por paciente. En una cohorte clínica, la partición debe impedir que registros de una misma persona aparezcan en entrenamiento y test. También debe preservarse la escala o documentarse cualquier normalización.

Cuando la tarea es morfológica, el rendimiento se analiza por etiqueta porque cada hallazgo ocupa una región distinta. La coincidencia exacta indica si se recupera el conjunto completo; la sensibilidad y la especificidad describen qué tipo de error domina; y F1 resume el equilibrio entre precisión y sensibilidad. Las mismas definiciones se aplican a CNN y VLM/ICL para mantener un criterio de evaluación común.

Las conclusiones sobre utilidad clínica exigirían una evaluación específica con una cohorte clínica y dentro de un circuito asistencial definido. El dominio sintético permite estudiar la capacidad de aprendizaje, la sensibilidad al contexto y el comportamiento relativo de los modelos, pero no estima la seguridad de un sistema médico. Cualquier interpretación clínica debe limitarse a la priorización de la revisión y mantener el diagnóstico completo dentro del circuito asistencial.

Capítulo 3. Antecedentes y estado del arte

3.1.- ALCANCE DE LA REVISIÓN

La revisión reúne los trabajos necesarios para situar la pregunta experimental del TFG. Se organiza en cinco líneas: diagnóstico automático a partir de señales de ECG, análisis del trazado como imagen, generación de datos sintéticos, modelos multimodales aplicados a imágenes electrocardiográficas y aprendizaje en contexto con demostraciones visuales. Las dos últimas se desarrollan con mayor detalle por su relación directa con los experimentos del proyecto.

Se priorizan artículos revisados por pares, conjuntos de datos con documentación técnica, guías clínicas y documentación oficial de los modelos. Los resultados se interpretan dentro de cada estudio, ya que las cohortes, las etiquetas, las tareas y las métricas no coinciden.

Una Accuracy alta en una tarea binaria no es directamente comparable con el rendimiento de una clasificación multietiqueta. Tampoco equivale evaluar imágenes renderizadas desde señales limpias y fotografías de documentos clínicos. La revisión se utiliza, por tanto, para justificar decisiones de diseño e identificar el hueco metodológico, no para ordenar los métodos mediante una única cifra.

3.2.- APRENDIZAJE PROFUNDO SOBRE SEÑALES ELECTROCARDIOGRÁFICAS

El análisis automático de ECG se ha desarrollado principalmente sobre señales temporales. Las convoluciones unidimensionales aprenden filtros directamente sobre las muestras y reducen la necesidad de diseñar características a mano. Al apilar capas, la red amplía su campo receptivo e integra información distribuida a lo largo de varios segundos.

Ribeiro y colaboradores entrenaron una red profunda con más de dos millones de ECG de doce derivaciones procedentes de una red brasileña de telemedicina [12]. El sistema reconocía seis alteraciones y se comparó con médicos en un subconjunto anotado. El estudio ilustra el rendimiento que puede alcanzar un clasificador temporal cuando dispone de una colección clínica a gran escala.

Esa escala no está disponible para todas las enfermedades. Reunir millones de registros con etiquetas fiables resulta especialmente difícil en condiciones poco frecuentes. Además, las etiquetas obtenidas durante la práctica habitual pueden reflejar criterios locales, versiones de software y variabilidad entre observadores.

PTB XL proporcionó un punto de referencia abierto con 21 837 ECG de doce derivaciones y 71 enunciados potencialmente multietiqueta [13]. Sus particiones recomendadas facilitan comparaciones reproducibles. MIMIC IV ECG amplió la escala hasta aproximadamente 800 000 registros vinculables con información clínica [14]. Ambos recursos son útiles para preentrenamiento y validación, pero pueden contener pocos ejemplos de una condición rara concreta.

Estos trabajos aportan dos referencias para el TFG. Por una parte, una arquitectura supervisada puede aprender morfología electrocardiográfica si dispone de datos adecuados. Por otra, su rendimiento depende de la correspondencia entre el dominio de entrenamiento y la población objetivo. El simulador estudia un régimen de datos escasos y no pretende competir con sistemas entrenados sobre millones de registros.

3.3.- ANÁLISIS DIRECTO DE IMÁGENES DE ECG

El análisis directo de imágenes resulta pertinente cuando el trazado solo está disponible como documento. Gliner y colaboradores compararon redes que recibían señales digitales con otras que utilizaban imágenes de doce derivaciones [15]. El estudio incluyó ocho condiciones para el modelo temporal, una evaluación visual centrada en fibrilación auricular y transformaciones que imitaban capturas con teléfono.

Sangha y colaboradores desarrollaron una CNN multietiqueta a partir de 2 228 236 registros brasileños convertidos en imágenes [16]. El modelo predijo seis etiquetas clínicas y se evaluó en un conjunto externo alemán y en ECG impresos. Sus resultados muestran que la representación visual puede mantener rendimiento fuera del conjunto de entrenamiento cuando este incorpora escala, diversidad y variaciones de formato.

La principal diferencia con este TFG es la cantidad de datos disponible. Sangha y colaboradores estudian aprendizaje supervisado a gran escala. Aquí se analiza un escenario previo, con pocos pacientes etiquetados, y se compara el entrenamiento de una CNN con el uso de demostraciones en un modelo abierto.

La imagen también puede convertirse de nuevo en señal. Wu y colaboradores desarrollaron un sistema automático de digitalización y evaluaron la correlación entre la señal reconstruida y la original [17]. La correlación fue alta en formatos favorables y disminuyó cuando las derivaciones se solapaban, lo que muestra que la digitalización introduce errores propios.

Gliner y colaboradores estudiaron en 2023 la transferencia desde imágenes limpias a fo-

tografías y formatos no observados [18]. Su arquitectura adversarial utiliza muestras objetivo sin etiqueta para reducir la dependencia del estilo de adquisición. Este planteamiento sirve como referencia para la transición entre el simulador y el dominio clínico.

3.4.- DATOS SINTÉTICOS PARA ECG

La generación sintética de ECG abarca varios niveles de fidelidad. En los modelos gaussianos, cada onda se expresa mediante una función paramétrica cuyos cambios se relacionan con la amplitud, la posición o la anchura. Sayadi y colaboradores utilizaron esta representación dentro de un sistema dinámico para generación y filtrado [19].

Los modelos electrofisiológicos, en cambio, simulan la propagación eléctrica sobre geometrías cardíacas. MedalCare XL contiene 16 900 ECG sintéticos de doce derivaciones correspondientes a un grupo sano y siete patologías [20]. La colección aporta señales con una base mecanística y facilita el estudio de condiciones difíciles de equilibrar con datos clínicos.

Una tercera línea utiliza modelos generativos aprendidos. Los modelos de difusión condicionados pueden producir señales asociadas a enunciados diagnósticos [21]. Ofrecen más flexibilidad que un simulador manual, pero dificultan la relación directa entre cada parámetro y la morfología obtenida. Su evaluación debe considerar la diversidad, la fidelidad clínica y la utilidad en tareas posteriores.

El simulador del proyecto adopta una representación más sencilla. No reproduce el torso, una geometría cardíaca tridimensional ni una distribución clínica completa, sino un latido con tres hallazgos localizados. Esta simplificación reduce el realismo, pero permite auditar cada regla de generación.

Los datos generados pueden amplificar los supuestos del simulador. Si la variabilidad omite ruido, cambios de escala y formas intermedias, el clasificador aprenderá una frontera más limpia que la presente en la práctica clínica. Por ello, los resultados sintéticos deben contrastarse con una cohorte clínica.

3.5.- CONJUNTOS QUE INTEGRAN SEÑAL, IMAGEN Y TEXTO

Los modelos multimodales requieren datos alineados. Una imagen sin informe permite entrenar un clasificador, pero no relaciona de forma detallada la morfología con el lenguaje. Del mismo modo, un informe sin trazado impide comprobar si la explicación se apoya en evidencia visual.

MEETI, publicado en 2026 como extensión de MIMIC IV ECG, sincroniza señales, imágenes renderizadas, parámetros por latido e interpretaciones textuales [23]. Incluye hasta 784

680 registros de 160 597 pacientes. Las imágenes mantienen una escala estándar y las interpretaciones detalladas se generan con un modelo de lenguaje a partir de informes y parámetros.

El recurso facilita el estudio del alineamiento multimodal a gran escala, pero exige distinguir el origen de cada anotación. Parte del texto procede de un modelo y no constituye una nueva valoración clínica independiente. MEETI puede utilizarse para preentrenamiento, recuperación y generación de informes; una evaluación diagnóstica, sin embargo, debe mantener etiquetas y conjuntos de referencia validados.

MEETI no se utiliza en los experimentos porque la tarea de esta memoria se limita a un latido sintético y tres hallazgos. El conjunto sí ofrece una posible ampliación hacia doce derivaciones y permitiría comparar imagen, señal y texto sobre los mismos registros.

3.6.- MODELOS MULTIMODALES ESPECIALIZADOS EN ECG

Los modelos generalistas de visión y lenguaje se entrenan principalmente con imágenes naturales, documentos y contenido web. Un ECG presenta una estructura distinta: la información se distribuye entre deflexiones delgadas, relaciones temporales y comparaciones entre derivaciones. Esta distancia de dominio motiva dos aproximaciones. La primera adapta un modelo de gran tamaño al ámbito médico; la segunda utiliza un modelo generalista sin modificar sus pesos. El TFG revisa ambas y evalúa cuantitativamente la segunda.

Liu y colaboradores presentaron ECGInstruct, PULSE y ECGBench [22]. ECGInstruct reúne más de un millón de pares de imagen y texto sobre reconocimiento de características, ritmo, morfología y generación de informes. PULSE es un modelo de siete mil millones de parámetros adaptado a ECG. ECGBench evalúa cuatro tareas en nueve conjuntos con imágenes sintéticas y reales.

Los autores informan de que PULSE supera a varios modelos multimodales generalistas en ECGBench [22], un resultado consistente con el valor de la especialización visual. Sin embargo, PULSE se entrena con una colección masiva de instrucciones y responde a una pregunta distinta. Este TFG evalúa un modelo generalista abierto *sin ajuste* de pesos y con pocos ejemplos de una condición rara como Brugada.

PULSE representa un nivel adicional de especialización. Incorporarlo al protocolo permitiría comparar una CNN supervisada con pocas muestras, un modelo generalista mediante ICL y un modelo multimodal ya adaptado a ECG. Este experimento ayudaría a aislar el efecto de cada nivel de especialización en una tarea de baja prevalencia.

La existencia de un modelo especializado no resuelve todos los escenarios. Puede no cubrir una modalidad infrecuente, una definición local o un nuevo protocolo de anotación. El ICL permite realizar una primera evaluación sin entrenar un modelo específico, aunque sus resultados deben compararse después con métodos especializados cuando estos estén

disponibles.

3.7.- APRENDIZAJE MULTIMODAL EN CONTEXTO

En el aprendizaje en contexto (*in-context learning*, ICL), los ejemplos se incorporan a la ventana de contexto durante la inferencia. No se emplean para actualizar los pesos mediante descenso por gradiente. Cada demostración contiene una imagen y su etiqueta o descripción textual. A continuación, el modelo predice la salida de una nueva imagen con los parámetros fijos. Este procedimiento permite estudiar tareas con unas pocas decenas de muestras, como ocurre en condiciones cardíacas de baja prevalencia. La Figura 3.1 resume el mecanismo.

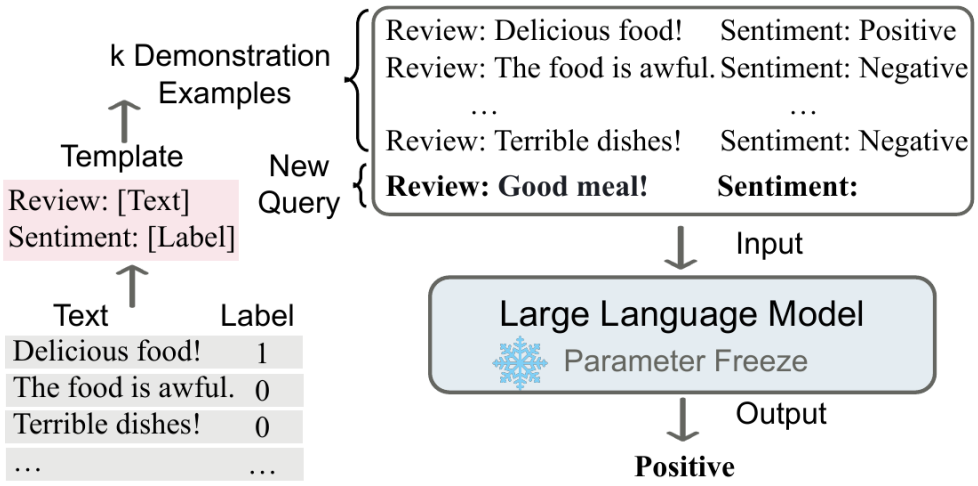


Figura 3.1.- Esquema general del aprendizaje en contexto: varias demostraciones se concatenan con una consulta y el modelo congelado produce la respuesta sin actualizar parámetros. Fuente: Dong y colaboradores [24].

Flamingo constituyó una referencia temprana para esta capacidad. El modelo recibe secuencias intercaladas de imágenes y texto y resuelve tareas a partir de demostraciones [25]. Sus resultados mostraron que un modelo multimodal preentrenado puede modificar su respuesta durante la inferencia cuando recibe ejemplos visuales y textuales relevantes, sin un ajuste específico de los pesos para cada tarea.

Estudios posteriores han mostrado que la contribución de cada componente de las demostraciones no es homogénea. Chen y colaboradores evaluaron el uso de la información visual en varios bancos de pruebas [26]. Observaron una dependencia dominante del texto, aunque la selección por similitud visual seguía aportando valor. Este resultado plantea una pregunta relevante para el TFG: cuando las demostraciones contienen ECG, ¿el modelo utiliza la morfología de la imagen o se apoya principalmente en las descripciones textuales?

Qin y colaboradores estudiaron la selección, el orden y la construcción de los ejemplos

[27]. Sus resultados indican que la recuperación multimodal, la posición de la instrucción y la diversidad de las demostraciones afectan al rendimiento. Por tanto, K no describe por sí solo la información del contexto: dos selecciones con el mismo número de ejemplos pueden producir resultados distintos.

El protocolo repite cada valor positivo de K con tres semillas para estimar la variabilidad asociada a la selección. Además, distingue zero-shot, ICL estándar e ICL balanceado. Esta comparación permite valorar si las demostraciones modifican el rendimiento y cómo influye su composición de clases en la sensibilidad y la especificidad.

Aplicar ICL a ECG añade una dificultad de dominio. El modelo debe interpretar deflexiones de pocos milímetros, elevaciones del segmento ST y relaciones temporales entre ondas, en lugar de los objetos habituales de los conjuntos de imágenes naturales. No puede presuponerse que una representación preentrenada con fotografías y documentos capture estas diferencias. El trabajo evalúa esta cuestión sobre imágenes de un solo latido y una condición rara.

3.8.- MODELOS ABIERTOS, MÉDICOS Y PROPIETARIOS

La literatura multimodal reúne modelos generalistas, entrenados con texto e imagen de dominios amplios, y modelos médicos adaptados a modalidades clínicas concretas. Para este TFG, la elección depende tanto del rendimiento como de la privacidad, la reproducibilidad y la dependencia de servicios externos.

Los modelos propietarios accesibles mediante API ofrecen una referencia de rendimiento multimodal. Algunos trabajos indican, además, que los VLM pueden detectar anomalías en ECG como imagen mediante ICL [28]. En un prototipo con datos sanitarios, no obstante, la ejecución en infraestructura universitaria reduce la exposición de las imágenes, mantiene la trazabilidad del entorno y evita cambios de versión no documentados.

MedGemma 1.5 es un modelo médico abierto adaptado a varias modalidades clínicas, entre ellas radiología y dermatología [30]. Su documentación no incluye el ECG entre las modalidades principales. Por ello, cualquier uso en este dominio requiere una validación específica antes de extraer conclusiones sobre morfología electrocardiográfica.

Gemma 4 es la familia abierta y multimodal elegida para la evaluación cuantitativa [29]. La variante E4B admite texto e imagen, un contexto extenso y resolución visual variable. Su tamaño permite ejecutarla en el entorno universitario disponible. El servicio mediante vLLM fija la versión, mantiene los datos en la infraestructura autorizada y permite evaluar ICL sin ajustar los pesos.

3.9.- HUECO DE INVESTIGACIÓN

La literatura revisada muestra que el ECG puede analizarse como señal o como imagen cuando existen suficientes datos etiquetados. Los resultados, sin embargo, no son directamente comparables por las diferencias de tarea, cohorte y métrica. Tampoco representan el escenario de este TFG, limitado a unas pocas decenas de ejemplos de una condición de baja prevalencia.

La CNN proporciona la referencia supervisada para este escenario. Permite medir el rendimiento con un K reducido y comprobar qué se conserva al transferir una regla sintética al dominio real. Su función no es demostrar capacidad diagnóstica, sino caracterizar las limitaciones del entrenamiento específico cuando los datos son escasos.

El VLM ofrece una forma distinta de utilizar los mismos datos. En lugar de actualizar sus pesos, recibe los K ejemplos como demostraciones dentro de la ventana de contexto. Así se evita un ciclo de entrenamiento específico, aunque el resultado sigue dependiendo de la selección y del orden de los ejemplos. El experimento comprueba si las representaciones adquiridas durante el preentrenamiento aportan alguna ventaja en este régimen.

En la literatura revisada no se ha identificado una comparación directa con el diseño de este TFG. La propuesta utiliza el mismo K de imágenes de ECG de una condición rara para entrenar una CNN o construir el contexto de un VLM abierto. Ribeiro et al. [12] y Sangha et al. [16] estudian entrenamiento supervisado a gran escala. Alayrac et al. [25], Chen et al. [26] y Qin et al. [27] analizan ICL multimodal sobre otras tareas. Liu et al. [22] especializan un modelo con más de un millón de instrucciones. Estos trabajos aportan las referencias de cada enfoque, pero no evalúan la comparación con el mismo K en este escenario.

El diseño experimental ofrece el mismo número de ejemplos a ambos enfoques. La CNN emplea las K muestras para actualizar sus pesos y Gemma 4 las incorpora al contexto de inferencia. El simulador proporciona primero una tarea definida por reglas antes de introducir la variabilidad del dominio clínico.

La contribución metodológica no consiste en una nueva arquitectura ni en un nuevo modelo entrenado, sino en comparar dos usos de los mismos ejemplos. La CNN caracteriza el entrenamiento de un modelo visual específico con pocos datos y su transferencia al dominio real. El VLM permite comprobar, con el mismo K, cómo cambian la sensibilidad, la especificidad y el coste de inferencia cuando los ejemplos se utilizan como contexto.

Capítulo 4. Diseño experimental

Este trabajo parte de una limitación concreta: el número de pacientes etiquetados es reducido y la entrada disponible es una imagen del ECG. El diseño experimental compara dos formas de aprovechar esos ejemplos. Ambas emplean información visual, mantienen la separación entre pacientes y se evalúan con las mismas métricas.

En el enfoque supervisado, una ResNet18 aprende a partir de los ejemplos disponibles y actualiza sus pesos durante el entrenamiento. Gemma 4, en cambio, recibe los ejemplos como demostraciones dentro del prompt, sin modificar sus parámetros. Esta distinción determina el significado de K: en la CNN denota pacientes de entrenamiento y, en el VLM, demostraciones incluidas en el contexto.

El sistema se plantea como una herramienta experimental de priorización, no como un método diagnóstico. Una predicción positiva identifica un trazado que convendría revisar, pero no equivale a confirmar ni a descartar el síndrome de Brugada. La valoración clínica requeriría el ECG completo y, según el caso, otras pruebas como el reposicionamiento de V1/V2 o el test farmacológico. Desde esta perspectiva, la sensibilidad indica qué proporción de positivos genera una alerta, mientras que la especificidad refleja cuántos pacientes negativos no serían derivados innecesariamente.

El protocolo distingue los datos, las particiones, las métricas, el papel previsto del sistema y los resultados. Además, incluye matrices 2×2, sensibilidad y especificidad para facilitar la interpretación [42, 40, 41]. Al trabajar con imágenes clínicas, también se especifican la entrada del modelo, la agregación de las predicciones y la información que queda fuera de la imagen. La Figura 4.1 resume las ramas comparadas.

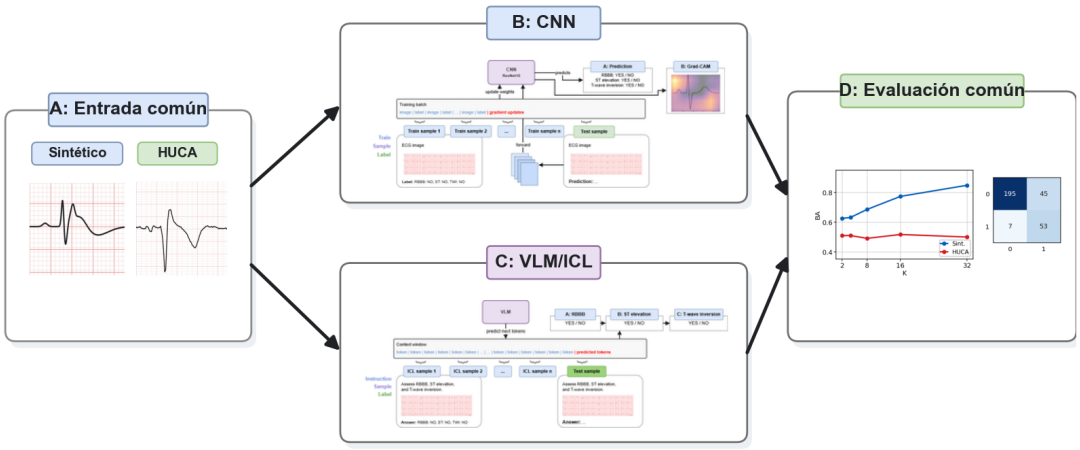


Figura 4.1.- Resumen del diseño experimental común: entrada de ECG como imagen, uso supervisado de ejemplos en la CNN, uso contextual de ejemplos en el VLM/ICL y evaluación con métricas compartidas.

4.1.- PLANTEAMIENTO COMÚN

La rama supervisada entrena una ResNet18 con pocos ejemplos. La rama VLM/ICL utiliza Gemma 4 y contempla tres condiciones: zero-shot, ICL estándar e ICL balanceado. El uso de los mismos valores de K, la separación por paciente y un procedimiento común de agregación permite compararlas bajo un protocolo homogéneo, aunque cada modelo aprovecha los ejemplos etiquetados de manera distinta.

La comparación abarca dos dominios. El simulador QRS/ST permite estudiar si las imágenes contienen información morfológica discriminativa en un entorno controlado. La cohorte del HUCA introduce ECG clínicos reales, con ruido de adquisición, variabilidad entre pacientes y una etiqueta cuyo significado no coincide exactamente con las reglas empleadas en la simulación.

4.2.- DATOS EVALUADOS

El paciente constituye siempre la unidad de separación. En el conjunto sintético, cada paciente simulado aporta una imagen de V1. En la cohorte del HUCA se utiliza, de forma análoga, una única ventana renderizada de V1 por paciente. Cada imagen genera una predicción, que se interpreta directamente a nivel de paciente.

Conjunto	Pacientes	Imágenes	Positivos	Negativos	Tarea
Sintético QRS/ST	100	100	20	80	Patrón derivado de Brugada con RBBB, elevación ST e inversión T presentes
Datos HUCA	317	317	116	201	Referencia binaria de la campaña final tras el filtrado local

Tabla 4.1.- Conjuntos utilizados en los experimentos finales. Cada paciente aporta una imagen; las matrices de confusión acumulan las predicciones obtenidas con las tres semillas.

Las etiquetas no representan exactamente el mismo fenómeno en ambos dominios. En el simulador, la clase positiva responde a una regla morfológica definida mediante criterios explícitos. En la cohorte del HUCA, procede de una variable clínica incluida en los metadatos. Por tanto, el paso del entorno sintético al clínico introduce tanto un cambio visual como un cambio semántico.

4.3.- VALORES DE K Y VALIDACIÓN

Los experimentos con pocos ejemplos emplean $K = \{2, 4, 8, 16, 32\}$. En el VLM se añade $K = 0$, correspondiente a la condición zero-shot. Cada valor positivo se evalúa con las semillas 42, 123 y 2026. Los ejemplos se seleccionan de nuevo en cada pliegue, sin incluir nunca al paciente reservado para prueba.

Las variantes de ICL se diferencian únicamente en esa selección. Para $K \geq 2$, el ICL estándar incorpora al menos una demostración positiva y otra negativa; las posiciones restantes se completan de forma seudoaleatoria entre los pacientes disponibles. No se trata, por tanto, de una recuperación aleatoria pura. El ICL balanceado intenta asignar $K/2$ demostraciones a cada clase y solo completa con la clase disponible si una de ellas no reúne suficientes casos. En ambos métodos, la semilla fija la selección y el paciente de prueba queda excluido.

En la evaluación sobre la cohorte del HUCA, el origen de K varía entre las ramas. La CNN se ajusta con K pacientes del simulador, ya que la cohorte clínica no contiene las etiquetas morfológicas requeridas por la cabeza multietiqueta. En el VLM, K representa demostraciones de contexto. Para la comparación clínica principal se toman de la propia cohorte; en el análisis de transferencia, proceden del simulador. La Figura 4.2 muestra la separación por paciente.

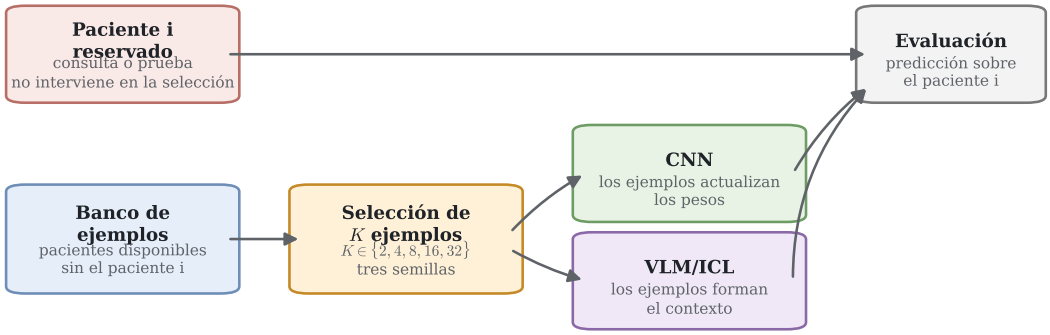


Figura 4.2.- Separación por paciente y selección de ejemplos para cada valor de K. El paciente reservado no interviene en la selección; los ejemplos actualizan los pesos de la CNN o forman el contexto del VLM.

Esta separación evita que registros de una misma persona aparezcan a la vez en entrenamiento y prueba, una fuente habitual de sesgo en el análisis de ECG. Sin este control, el modelo podría reconocer rasgos del paciente, del dispositivo o del renderizado en vez de patrones relacionados con la tarea.

4.4.- MÉTRICAS

La métrica principal es la *Balanced Accuracy* (BA), que asigna el mismo peso a la sensibilidad y a la especificidad aunque las clases estén desbalanceadas. Se calcula como

$$\mathrm{BA} = \frac{1}{2}\left(\frac{TP}{TP+FN} + \frac{TN}{TN+FP}\right).$$

También se informan F1, sensibilidad, especificidad, área bajo la curva ROC y precisión media. Las tablas principales presentan la media de las tres semillas y, cuando procede, su desviación estándar. Las matrices de confusión acumulan las predicciones de las tres ejecuciones.

Una sensibilidad alta acompañada de una especificidad baja puede resultar útil en un análisis exploratorio, porque permite recuperar más positivos. Sin embargo, no sería suficiente para un circuito asistencial si generase demasiadas alertas. Esta tensión orienta la lectura de las comparaciones posteriores.

El capítulo 6 desarrolla la CNN y el enfoque VLM/ICL dentro de este marco comparativo. Después, el capítulo 7 presenta los resultados cuantitativos obtenidos en el dominio sintético y en la cohorte del HUCA.

Capítulo 5. El simulador QRS/ST

5.1.- OBJETIVO DEL DOMINIO SINTÉTICO

Los datos sintéticos permiten estudiar la eficiencia con pocos ejemplos sin depender de una colección clínica extensa. En este trabajo, el simulador funciona como un entorno controlado. Cada latido se construye a partir de componentes interpretables, se somete a reglas explícitas y se renderiza como una imagen. Tanto la CNN como el modelo de visión y lenguaje reciben esa representación visual.

El objetivo no consiste en reproducir la fisiología cardíaca completa. Para ello habría que modelar las doce derivaciones, los cambios de frecuencia y la interacción entre ciclos. También serían necesarias la conducción auricular y ventricular, el ruido de adquisición, la variación anatómica y el efecto del dispositivo. El sistema implementado se limita a un latido aislado con apariencia de derivación precordial derecha. Esta simplificación hace posible parametrizar los tres hallazgos visuales de interés para el experimento.

El uso de datos sintéticos cumple cuatro funciones:

1. Generar etiquetas sin depender de anotación manual para cada imagen.
2. Separar la forma de una onda de factores externos como fabricante, hospital o estilo de documento.
3. Construir conjuntos de ejemplos con tamaños exactos y semillas conocidas.
4. Reservar una familia generadora compuesta para estudiar transferencia.

Esta capacidad de control tiene como contrapartida una brecha entre los dominios sintético y real. El simulador permite comprobar si los modelos aprenden una tarea definida mediante reglas, pero no anticipa el rendimiento en ECG clínicos. Los resultados se interpretan teniendo presente esta diferencia.

5.2.- REPRESENTACIÓN MATEMÁTICA

Cada latido se expresa como la suma de diez átomos gaussianos. En el átomo i, la amplitud a_i, el centro temporal μ_i y la anchura σ_i definen la función

$$g_i(t) = a_i \exp\left(-\frac{(t-\mu_i)^2}{2\sigma_i^2}\right). \tag{5.1}$$

La señal completa es

$$x(t) = \sum_{i=1}^{10} g_i(t). \tag{5.2}$$

El signo de a_i determina la dirección de la deflexión y su valor absoluto, la magnitud. El parámetro μ_i sitúa el componente en el eje temporal, mientras que σ_i controla su extensión. Al sumar los átomos se obtienen transiciones suaves y sin discontinuidades.

El uso de gaussianas parte de trabajos previos que representan las ondas electrocardiográficas mediante componentes paramétricos [19]. Este simulador es más sencillo que un modelo electrofisiológico dinámico, pero permite relacionar cada modificación con una región concreta de la señal.

Átomo	**Región principal**	**Función dentro del generador**
`P`	Onda P	Añade una deflexión auricular positiva anterior al QRS
`Q`	Inicio del QRS	Permite una pequeña deflexión negativa, aunque la configuración actual la mantiene anulada
`R`	QRS inicial	Produce el primer máximo positivo ventricular
`S`	QRS central	Forma la deflexión negativa posterior a R
`R_prime`	QRS terminal	Introduce un segundo máximo positivo y permite una forma RSR prima
`J_elev`	Punto J	Controla la transición entre el final del QRS y el segmento ST
`ST1`	ST inicial	Modela elevación temprana y la parte descendente de una forma cóncava
`ST2`	ST tardío	Controla la continuidad hacia la onda T
`T1`	Onda T principal	Define la polaridad y la magnitud principal de la repolarización
`T2`	Cola de la onda T	Suaviza y prolonga la repolarización

Tabla 5.1.- Átomos utilizados para construir un latido sintético

La Figura 5.1 muestra cómo se combinan los átomos de la Tabla 5.1.

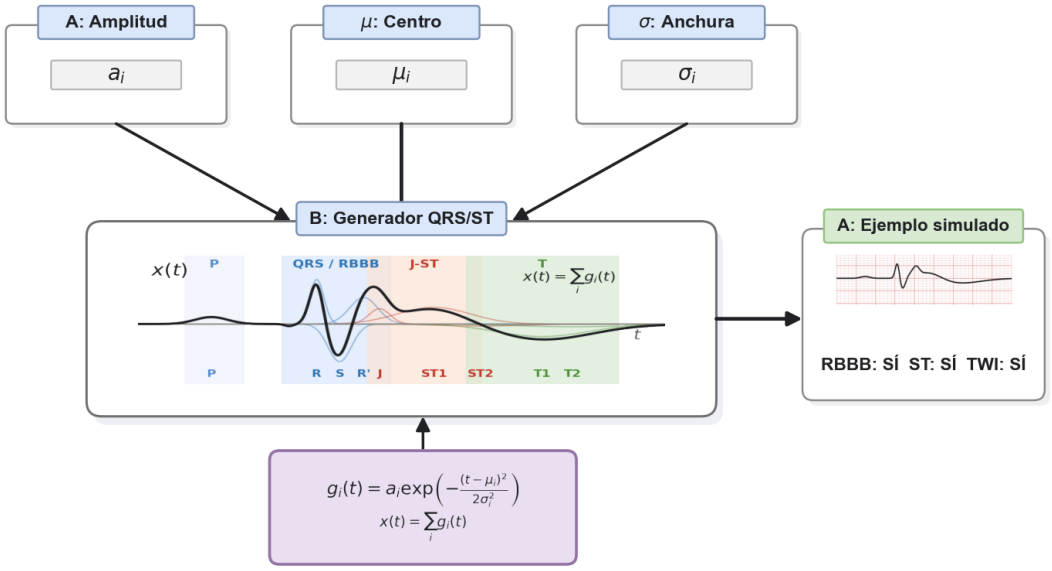


Figura 5.1.- Generador gaussiano de un latido sintético. Los parámetros de cada átomo fijan su amplitud, posición y anchura antes de sumar las regiones P, QRS, ST y T.

5.3.- MUESTREO TEMPORAL

La configuración final utiliza una frecuencia de 500 Hz y una duración de 900 ms. El número de muestras se calcula como

$$N = \text{round}\left(\frac{D}{1000} f_s\right), \tag{5.3}$$

donde D es la duración en milisegundos y f_s la frecuencia de muestreo. Con los valores finales se obtienen 450 muestras. El vector temporal es

$$t_n = \frac{1000n}{f_s}, \qquad n \in \{0, \ldots, N-1\}. \tag{5.4}$$

Los rangos de repolarización se definieron para una duración de referencia de 900 ms. Cuando cambia la duración del latido, los centros posteriores a 390 ms se adaptan mediante

$$\mu_i^{(D)} = 390 + \left(\mu_i^{(900)} - 390\right) \frac{D - 390}{900 - 390}. \tag{5.5}$$

Las anchuras de los componentes tardíos se escalan con el mismo factor y se impone un mínimo para evitar gaussianas degeneradas. Los componentes anteriores al punto de pivote permanecen fijos. Así, el QRS conserva su posición, mientras que ST y T se comprimen o expanden según la duración disponible.

5.4.- RANGOS DE PARÁMETROS

La generación comienza con una configuración común que asigna a cada átomo intervalos para a, μ y σ. A continuación se sustituyen los intervalos propios de la familia seleccionada. Aunque el muestreo dentro de cada rango es uniforme, la distribución de las señales aceptadas no lo es: las reglas morfológicas y los validadores descartan parte de las propuestas.

Estos rangos pertenecen al generador visual y no representan límites clínicos. Por ejemplo, el átomo `R_prime` mantiene una amplitud casi nula en la familia normal y admite valores mayores en RBBB. De forma análoga, `J_elev`, `ST1` y `ST2` permanecen cerca de cero en las señales normales y adoptan amplitudes positivas en la familia con elevación del ST.

Los rangos favorecen una morfología, mientras que los validadores deciden si la señal resultante satisface la definición de cada etiqueta. Mantener separadas ambas funciones evita que un cambio en la generación modifique de forma inadvertida el significado de las clases.

5.5.- FAMILIAS GENERADORAS

El simulador parte de cinco familias. Cada una selecciona rangos de muestreo y reglas de coherencia, pero no asigna directamente el vector objetivo.

5.5.1.- Familia normal

La familia `NORMAL` reduce la amplitud de R prima, mantiene las regiones J y ST próximas a la línea base y genera ondas T positivas. Además, rechaza cualquier señal que active alguno de los tres validadores de hallazgos. Esta comprobación evita que una combinación obtenida por azar dentro de los rangos normales supere uno de sus umbrales.

5.5.2.- Morfología RBBB

La familia `RBBB` favorece una segunda deflexión positiva después de S. El centro de R prima se sitúa al menos 24 ms después del centro de S. Dentro de los límites permitidos, su amplitud debe alcanzar como mínimo el 80 por ciento de la amplitud de R. También se le asigna una anchura mayor que a la primera R.

El propósito es obtener una forma RSR prima visible, no reproducir todos los criterios clínicos del bloqueo completo de rama derecha. Estos dependen, entre otros aspectos, de la duración global del QRS y de su distribución entre derivaciones [3]. Por este motivo, el texto interpreta la etiqueta como una morfología compatible.

5.5.3.- Elevación de ST

La familia `ST_ELEVATION` asigna amplitudes positivas al punto J y a los dos componentes del ST. La primera sección del segmento se ensancha para que no adopte la forma de un pico estrecho confundible con una deflexión del QRS. El validador también exige actividad ventricular positiva y negativa suficiente, lo que permite descartar señales planas desplazadas hacia valores altos.

5.5.4.- Inversión de T

La familia `T_WAVE_INVERSION` hace negativos los dos componentes de T y los separa de la región ST. Puede generar, además, una R prima moderada y una pequeña elevación de J, lo que permite coocurrencias con RBBB y elevación del ST. Para aceptar la señal, la deflexión negativa debe aparecer tarde, alcanzar una profundidad mínima y mantenerse durante un intervalo suficiente.

5.5.5.- Familia Brugada

La familia `BRUGADA` representa de forma esquemática una morfología coved o de tipo 1. Combina elevación de J, un ST inicial positivo, un descenso posterior y la inversión de T. La amplitud de R prima es menor que en la familia RBBB, aunque puede conservar una alteración terminal del QRS.

El nombre de la familia no forma parte del vector objetivo. Una señal aceptada por el validador interno de Brugada se evalúa después con los validadores independientes de RBBB, elevación del ST e inversión de T. Puede recibir, por tanto, una combinación parcial de hallazgos. La familia se utiliza así como prueba de composición, sin introducir una etiqueta clínica que el simulador no permite justificar.

Familia	Modificación dominante	Interpretación experimental
NORMAL	ST próximo a cero, T positiva y R prima mínima	Referencia sin hallazgos del conjunto
RBBB	Segundo pico positivo tardío y ancho	Componente terminal del QRS
ST elevado	Punto J y ST positivos	Componente de elevación posterior al QRS
Inversión de T	Repolarización tardía negativa	Componente de inversión de T
BRUGADA	J elevado, ST descendente y T negativa	Familia compuesta reservable para transferencia

Tabla 5.2.- Relación entre familias generadoras y rasgos favorecidos

5.6.- REGLAS DE COHERENCIA MORFOLÓGICA

El muestreo independiente de los átomos puede alterar el orden temporal de las ondas. Para evitarlo, antes de sumar las gaussianas se imponen varias relaciones. Q precede a R; S aparece después de R y tiene mayor anchura; J se sitúa después de S. Los dos componentes del ST se ordenan tras J, y T1 y T2 ocupan la región final.

Estas relaciones no convierten la señal en una representación fisiológica. Su función es mantener una geometría mínima que preserve la interpretación de los parámetros. Las reglas propias de cada familia añaden restricciones como la posición tardía de R prima o el signo negativo de T.

Los cambios en una regla pueden afectar a más de un componente. Desplazar T1, por ejemplo, modifica el resultado del validador de inversión y también puede alterar la media tardía del ST. Por ello, cualquier ajuste requiere volver a generar ejemplos y revisar tanto las frecuencias de las etiquetas como las tasas de aceptación.

5.7.- MUESTREO CON RECHAZO

La generación utiliza muestreo con rechazo. Para una familia c, el procedimiento consta de los siguientes pasos:

1. Combinar los rangos base con los rangos específicos de c.
2. Adaptar los componentes tardíos a la duración solicitada.

3. Muestrear los parámetros de los diez átomos.
4. Aplicar las reglas de orden y coherencia.
5. Sumar los átomos sobre el vector temporal.
6. Evaluar el validador correspondiente a c.
7. Aceptar la señal si supera las reglas o volver al paso de muestreo.

El generador admite un máximo de 400 intentos. Si ninguno produce una señal válida, devuelve un error junto con las últimas métricas calculadas. Los metadatos de cada muestra registran el número de intentos, lo que ayuda a detectar rangos poco compatibles con los validadores.

Sea q_c la probabilidad de aceptación de una propuesta de la familia c. El número esperado de intentos antes de una aceptación es aproximadamente

$$\mathbb{E}[A_c] = \frac{1}{q_c}. \tag{5.6}$$

Un número elevado de intentos no invalida por sí mismo las imágenes aceptadas, pero indica que gran parte del espacio paramétrico queda fuera de la definición de la etiqueta. Por ello, la tasa de aceptación forma parte de la revisión del generador.

5.8.- VALIDADORES Y SEMÁNTICA DE LAS ETIQUETAS

Los validadores analizan ventanas temporales de la señal completa. Las situadas después de 390 ms se adaptan mediante la ecuación 5.5. Las amplitudes se expresan en mV y las duraciones, en ms.

Validador	Condiciones necesarias
RBBB	Dos máximos positivos entre 240 y 470 ms, separación mínima de 28 ms, primer máximo superior a 0,12 mV, segundo máximo superior a 0,20 mV, mínimo intermedio inferior a $-0,05$ mV, segundo máximo posterior a 345 ms y anchura terminal superior a 38 ms por encima de 0,10 mV
Elevación de ST	Máximo del QRS superior a 0,28 mV, mínimo del QRS inferior a $-0,14$ mV, media de J superior a 0,09 mV y media del ST superior a 0,09 mV
Inversión de T	Máximo del QRS superior a 0,22 mV, máximo de R prima superior a 0,08 mV, media del ST superior a $-0,03$ mV, mínimo de T inferior a $-0,12$ mV, mínimo posterior al umbral temporal equivalente a 640 ms y más de 45 ms por debajo de $-0,05$ mV
Normal	Máximo del QRS superior a 0,22 mV, mínimo inferior a $-0,10$ mV, media de ST entre $-0,04$ y 0,05 mV, máximo de T superior a 0,12 mV, R prima inferior a 0,10 mV y rechazo de los tres hallazgos
Brugada	Máximo del QRS superior a 0,18 mV, mínimo inferior a $-0,16$ mV, media de J superior a 0,09 mV, media de ST superior a 0,08 mV, ST temprano al menos 0,03 mV por encima del ST tardío y mínimo de T inferior a $-0,08$ mV

Tabla 5.3.- Criterios de los validadores sintéticos

Los umbrales de la Tabla 5.3 separan morfologías dentro del simulador. No son criterios clínicos ni deben aplicarse a ECG reales, cuya interpretación requiere calibración, derivaciones identificadas, velocidad de papel conocida y contexto clínico. Los estándares revisados en el capítulo 2 solo orientan la forma general de las señales sintéticas.

Las tres etiquetas finales se calculan de forma independiente. Una vez aceptada la señal, se ejecutan los validadores de RBBB, elevación del ST y TWI para construir un vector binario. Las coocurrencias resultantes no tienen por qué coincidir con la familia de origen: la etiqueta describe la señal generada, no el mecanismo utilizado para proponerla.

5.9.- RENDERIZADO DE LAS SEÑALES

Cada latido se representa en un lienzo cuadrado de 896 por 896 píxeles y 130 puntos por pulgada. En el eje horizontal, la cuadrícula menor marca intervalos de 40 ms y la mayor, de 200 ms. En el eje vertical, las divisiones corresponden a 0,1 y 0,5 mV, respectivamente. La señal se dibuja en negro con un grosor de dos puntos y la cuadrícula, en dos tonos de rosa.

El renderizado conserva los títulos de los ejes y los valores numéricos. Aunque aportan información de escala, podrían actuar como atajos si los límites variasen entre muestras. Para evitarlo, todas las imágenes del experimento final comparten los mismos límites horizontales y verticales. También se revisó que ninguna familia presentase un encuadre, un margen o un patrón de marcas propio.

No se aplican reflejos horizontales, pues invertir el eje temporal alteraría el orden de las ondas, ni verticales, porque intercambiarían elevación y depresión. Las transformaciones admisibles deben conservar la semántica de la señal; entre ellas se encuentran pequeñas variaciones de grosor, contraste, desplazamiento y escala dentro de límites conocidos. La Figura 5.2 muestra una señal de cada familia.

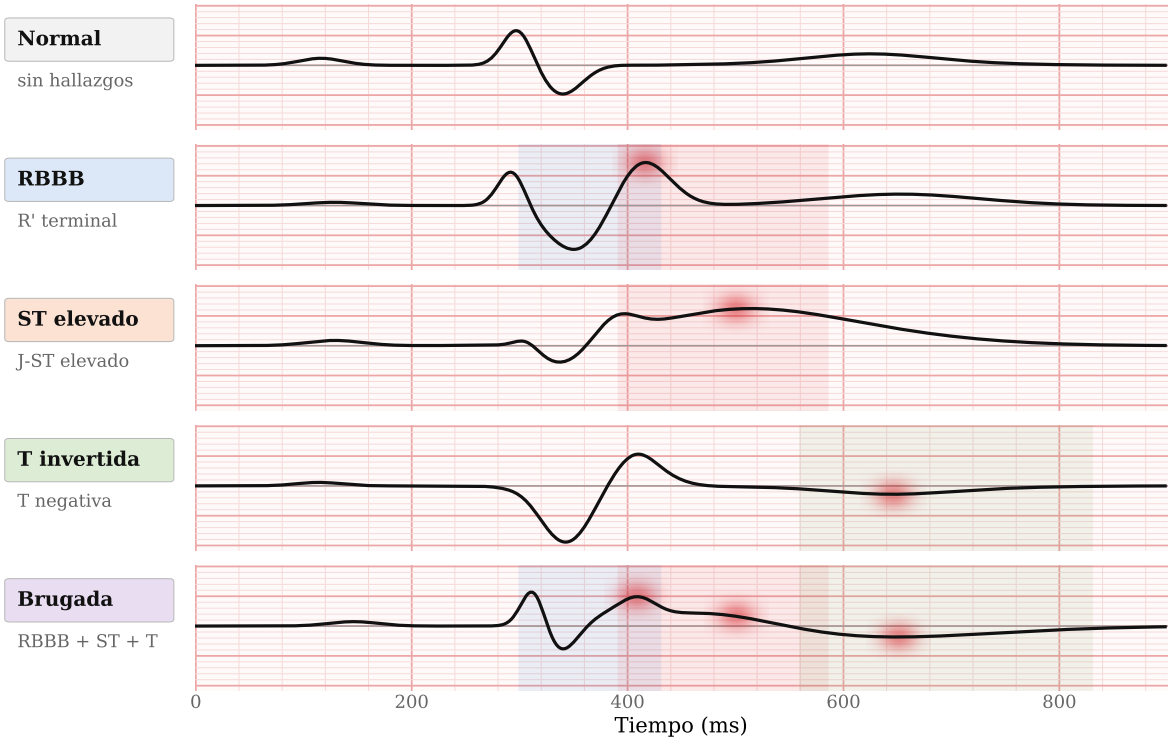


Figura 5.2.- Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador.

5.10.- CONSTRUCCIÓN DEL CONJUNTO DE DATOS

Para construir el conjunto sintético se asigna una semilla propia a cada muestra y se genera la señal a partir de una de las familias descritas. Tras la aceptación, las muestras se distribuyen entre entrenamiento, validación y prueba. Las imágenes y su manifiesto se almacenan conjuntamente.

El manifiesto relaciona cada muestra con su imagen, partición, familia generadora, semilla, subtipo cuando corresponde, número de intento, índices internos y etiquetas binarias. Otros ficheros recogen el esquema de etiquetas y las frecuencias por partición, familia y combinación de clases. El entrenamiento puede leer directamente los manifiestos CSV, sin depender de la organización de las carpetas, mientras que los ficheros JSON facilitan la revisión del proceso y la elaboración de resultados.

5.11.- COMPROBACIÓN DE INTEGRACIÓN

La configuración final consta de 100 pacientes sintéticos, cada uno con una imagen V1, sus pliegues LOOCV y los resúmenes de etiquetas. Veinte pacientes presentan los tres hallazgos; los 80 restantes son normales o contienen combinaciones parciales. Como cada configuración se repite con tres semillas, las matrices de confusión agregadas reúnen 300 predicciones.

Este conjunto constituye la base de la evaluación sintética. La prueba de integración abarca la generación de las señales, su aceptación mediante validadores, la partición por paciente y la escritura de los manifiestos. La coexistencia de varias combinaciones permite estudiar la evolución del rendimiento con K sin limitar la tarea a distinguir entre normalidad y un único patrón patológico.

La familia de origen y las etiquetas finales desempeñan funciones diferentes. La primera modifica los rangos de muestreo para favorecer una morfología, pero los validadores actúan después sobre la señal resultante. Así, una muestra generada desde la familia con elevación del ST puede activar también RBBB, y otra orientada a la inversión de T puede conservar una deflexión terminal asociada a otros hallazgos. La tarea queda definida por los rasgos detectados en la señal, no por el nombre de la familia inicial. La Figura 5.3 muestra las combinaciones obtenidas.

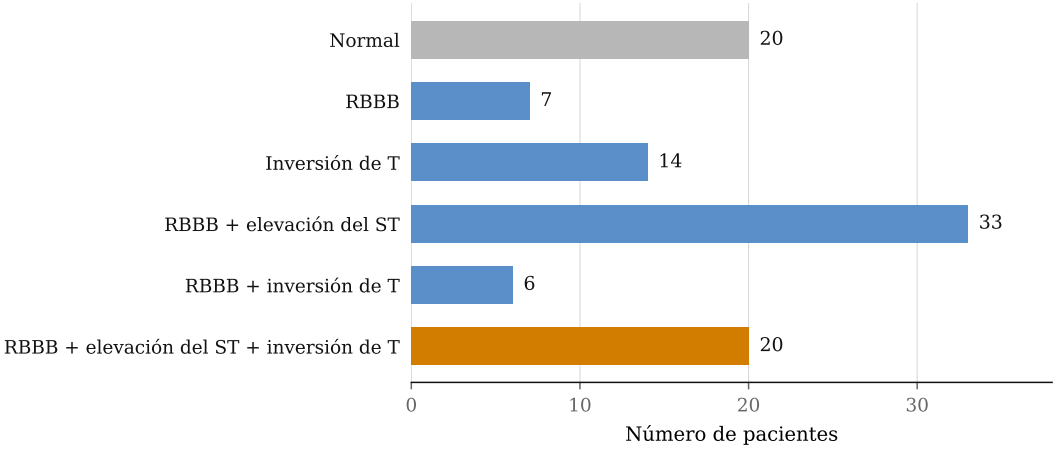


Figura 5.3.- Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV.

5.12.- RIESGOS DE ATAJOS VISUALES

Un resultado alto no implica necesariamente que el modelo haya aprendido la morfología de interés. También podría aprovechar límites automáticos de los ejes, diferencias de antialiasing, márgenes ligados a la amplitud, cambios en la densidad de la cuadrícula, nombres de

fichero o la propia estructura de carpetas.

Para reducir estos riesgos, las imágenes se leen desde el manifiesto sin proporcionar al modelo la familia de origen. Los límites visuales son constantes y los nombres de fichero solo contienen un contador. Como controles de sensibilidad se contemplan recortes de la zona del trazado y versiones sin el texto de los ejes. Una caída marcada al retirar elementos ajenos a la señal indicaría la necesidad de investigar posibles atajos antes de interpretar el rendimiento.

La atención espacial de la CNN se examina además mediante Grad-CAM [32]. Este análisis no permite establecer relaciones causales; sirve para observar si las activaciones se concentran en QRS, ST y T o en elementos periféricos de la imagen.

5.13.- LIMITACIONES DEL SIMULADOR

El simulador representa un latido aislado con una geometría semejante a la de una derivación precordial. No modela las doce derivaciones ni una transformación eléctrica común entre ellas. Tampoco incorpora variabilidad entre latidos, arritmias, intervalos dependientes de la frecuencia, ruido muscular, deriva de la línea base, interferencia de red, pérdida de electrodos o compresión de documentos.

La construcción mediante gaussianas produce curvas suaves y simplifica bordes que pueden ser más irregulares en un ECG real. A su vez, los validadores utilizan ventanas y umbrales diseñados exclusivamente para este dominio. Aplicarlos a una señal clínica como si fueran reglas diagnósticas carecería de justificación.

La familia Brugada simplifica una elevación del ST de morfología convexa asociada al patrón tipo 1. No representa la heterogeneidad del síndrome, la variación entre derivaciones ni su posible carácter intermitente. Se utiliza únicamente para estudiar la composición visual de los tres hallazgos.

Estas limitaciones delimitan el alcance del experimento. El dominio sintético permite comparar la eficiencia en el uso de ejemplos bajo condiciones controladas, pero no establece validez clínica. Esta última debe juzgarse a partir de la evaluación con la cohorte del HUCA y de una validación externa posterior.

Capítulo 6. Dos enfoques de modelado

Este capítulo describe dos formas de utilizar un conjunto reducido de imágenes etiquetadas. La primera entrena un modelo visual y actualiza sus pesos con los pacientes disponibles. La segunda incorpora esos ejemplos al contexto de un modelo de visión y lenguaje, que realiza la predicción sin modificar sus parámetros.

La comparación no se limita, por tanto, a dos arquitecturas. También enfrenta dos regímenes de uso de los datos. En la CNN, K es el número de pacientes de entrenamiento de cada pliegue; en el VLM, indica cuántas demostraciones preceden a la imagen de consulta. Se compara así el entrenamiento supervisado con la inferencia condicionada por contexto.

6.1.- ENTRADA Y UNIDAD DE ANÁLISIS

Todos los modelos reciben el ECG como imagen. La CNN redimensiona cada entrada a 224 por 224 píxeles y la procesa en formato RGB. En el VLM, la imagen forma parte de un mensaje multimodal que contiene instrucciones textuales y, cuando corresponde, demostraciones etiquetadas.

La evaluación utiliza exclusivamente V1 y produce una decisión por paciente. Como cada persona aporta una sola imagen, no se promedian ni se someten a voto predicciones de varias derivaciones. La unidad de análisis coincide de este modo con la unidad empleada para separar los datos.

6.2.- ENFOQUE SUPERVISADO CON CNN

6.2.1.- Qué aprende

La CNN transforma la imagen en probabilidades asociadas a los hallazgos de interés. Durante el entrenamiento, las etiquetas permiten calcular una pérdida con la que se actualizan los pesos. Al terminar este proceso, los parámetros quedan fijados y cada nueva imagen se evalúa mediante una inferencia directa.

Cuando los ejemplos son representativos, este enfoque puede adaptar sus rasgos visuales a la tarea y ofrece un coste reducido por predicción una vez entrenado. Estas propiedades lo convierten en una referencia útil para estudiar un posible despliegue local, aunque no bastan

por sí solas para justificar su uso clínico.

6.2.2.- Riesgos con pocos ejemplos

Con valores pequeños de K, la red puede ajustarse en exceso a los pacientes seleccionados en cada pliegue. Sustituir unos pocos ejemplos puede entonces desplazar la frontera de decisión. También existe el riesgo de que aprenda atajos ajenos a la morfología, como diferencias en la escala, el grosor del trazo, el recorte o la cuadrícula.

Por este motivo, la CNN se utiliza como referencia supervisada y no como solución clínica. Su función es medir el rendimiento de un entrenamiento visual convencional cuando la cantidad de datos es limitada.

6.3.- VLM CON ICL

6.3.1.- Qué cambia frente al entrenamiento

En el VLM, los ejemplos etiquetados se incluyen en el prompt como demostraciones y no modifican los pesos. El modelo recibe después la imagen objetivo y genera una respuesta en el formato especificado. Este aprendizaje en contexto ofrece una forma distinta de aprovechar pocos datos, pero no se asume que sustituya al entrenamiento supervisado.

La posibilidad resulta de interés en una enfermedad rara, donde reunir casos positivos confirmados es costoso. El experimento estudia si un modelo generalista puede orientar su decisión con pocas demostraciones. Para ello se utiliza Gemma 4, servido mediante vLLM en infraestructura universitaria bajo control propio.

6.3.2.- Tres condiciones de consulta

El enfoque multimodal se evalúa en tres condiciones. Zero-shot no incluye demostraciones locales. Para $K \geq 2$, el ICL estándar incorpora al menos un ejemplo de cada clase y completa el contexto de forma seudoaleatoria. El ICL balanceado intenta repartir las K demostraciones por igual entre positivos y negativos. La sección 6.6.5 detalla ambas estrategias.

La CNN recibe K pacientes para entrenar, mientras que el VLM emplea K pacientes para construir el contexto. En ambos casos se respeta la separación por paciente y la muestra reservada queda fuera de la selección.

6.4.- COMPARACIÓN ENTRE ENFOQUES

En la CNN, las imágenes de los K pacientes intervienen en la pérdida y modifican los pesos. Cuando se evalúa la transferencia al HUCA, estos pacientes proceden del simulador, ya que la cohorte clínica no contiene las etiquetas morfológicas requeridas por la cabeza multietiqueta. En el VLM, los K pacientes se convierten en demostraciones dentro del prompt. Los parámetros permanecen fijos, aunque la salida puede depender de la selección y del orden de los ejemplos, así como de la capacidad de la ventana de contexto.

La evaluación estudia cómo evoluciona cada régimen al aumentar el número de ejemplos. Primero se analiza el simulador, donde la etiqueta está definida por reglas, y después la cohorte del HUCA, cuya referencia clínica y variabilidad visual plantean una tarea diferente.

La sección 6.5 describe la CNN y su protocolo de entrenamiento. A continuación, la sección 6.6 presenta el VLM, las condiciones de consulta y las decisiones relacionadas con la privacidad. Los resultados cuantitativos se reservan para el capítulo 7.

6.5.- ENFOQUE SUPERVISADO CON CNN RESNET18

La CNN sirve como referencia supervisada. El objetivo no es comparar arquitecturas, sino estudiar un procedimiento convencional de aprendizaje a partir de imágenes etiquetadas. Los ejemplos actualizan los pesos y producen un modelo específico para la tarea.

6.5.1.- Arquitectura y entrada

El modelo es una ResNet18 preentrenada [31]. Su cabeza final se sustituye por tres salidas, correspondientes a RBBB, elevación del ST e inversión de T. Las imágenes se procesan en RGB con un tamaño de 224 por 224 píxeles. En el simulador, un paciente se considera positivo cuando concurren los tres hallazgos.

Esta formulación determina cómo se interpreta la evaluación real. La CNN no se ajusta directamente a la etiqueta `clinical_brugada`; estima los tres rasgos morfológicos y deriva una decisión positiva cuando aparecen de forma simultánea. La cohorte del HUCA actúa, por tanto, como conjunto de prueba clínica y no como fuente de entrenamiento morfológico. La Figura 6.1 resume el procedimiento.

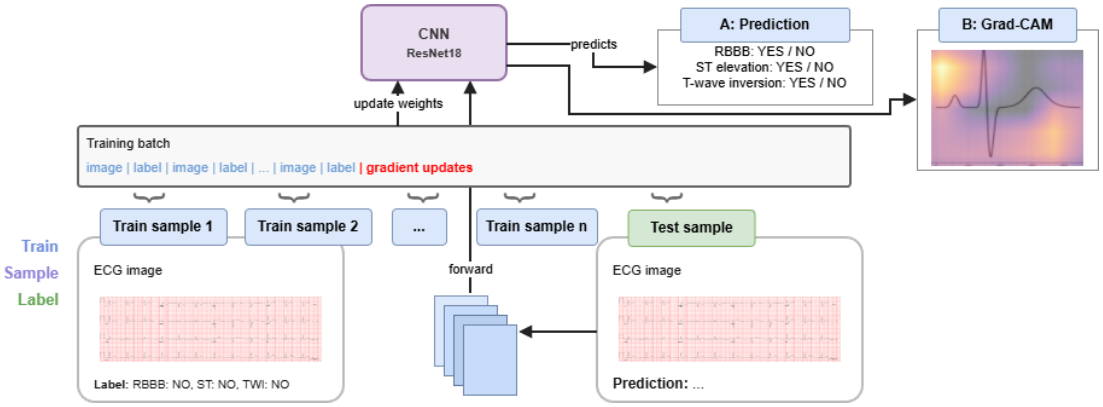


Figura 6.1.- Uso supervisado de los ejemplos etiquetados. Las muestras de entrenamiento actualizan ResNet18 y la muestra reservada produce una predicción binaria y su mapa Grad-CAM.

6.5.2.- Entrenamiento

El entrenamiento utiliza entropía cruzada binaria multietiqueta. La ponderación de la clase positiva se calcula automáticamente a partir de los ejemplos de cada pliegue. Se emplea AdamW [38], con una tasa de aprendizaje de 3×10^{-4}, lotes de 32 imágenes y un máximo de 20 épocas.

Propiedad	Valor
Arquitectura	ResNet18 con cabeza multietiqueta de tres salidas
Inicialización	Pesos preentrenados de ResNet18
Entrada	RGB, 224 por 224 píxeles
Pérdida	Entropía cruzada binaria multietiqueta con ponderación automática
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Épocas máximas	20
Tamaño de lote	32
Valores de K	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026
Umbral	Seleccionado por validación con *Balanced Accuracy* por paciente
Agregación	Sin agregación multiderivación; se usa únicamente V1 antes del umbral

Tabla 6.1.- Configuración CNN utilizada en los experimentos finales.

6.5.3.- Evaluación con la cohorte del HUCA

La cohorte del HUCA no contiene anotaciones independientes de RBBB, elevación del ST e inversión de T para cada imagen. Solo dispone de la referencia clínica binaria empleada en la campaña final. Con la arquitectura definida, no es posible entrenar la cabeza morfológica sobre esos datos sin inventar etiquetas que no están disponibles.

La evaluación real se plantea, en consecuencia, como una transferencia desde el simulador. Los K pacientes que actualizan los pesos proceden del conjunto sintético QRS/ST; la muestra de prueba pertenece al HUCA y se compara con la referencia clínica disponible. El protocolo evita crear anotaciones morfológicas artificiales para el dominio real, pero mide una transferencia sintético-real y no un entrenamiento clínico directo.

Un entrenamiento supervisado directo con el HUCA exigiría anotaciones morfológicas por imagen o un rediseño como clasificador binario de `clinical_brugada`. Esta segunda opción abordaría una tarea diferente, más próxima a la predicción de la referencia clínica que a la detección explícita de los tres rasgos visuales.

6.5.4.- Validación por paciente

La evaluación se organiza mediante validación leave-one-out por paciente. En el dominio sintético, cada pliegue reserva un paciente y selecciona los K casos de entrenamiento entre los restantes. En la transferencia al HUCA, la unidad reservada sigue siendo un paciente real, pero los K ejemplos de entrenamiento proceden del simulador. Ninguna imagen del paciente de prueba interviene en el ajuste.

Para cada pliegue se registran las probabilidades de V1, la predicción del paciente, el umbral seleccionado y los datos necesarios para calcular las matrices de confusión y las métricas. También se conservan paneles Grad-CAM para la inspección cualitativa.

6.5.5.- Selección de umbral

Cada una de las tres salidas produce un logit, que una función sigmoide transforma en probabilidad. El umbral se aplica por separado a RBBB, elevación del ST e inversión de T, no a una clase Brugada directa. Como el experimento utiliza únicamente V1, tampoco existe una agregación previa entre derivaciones.

Un hallazgo se considera presente cuando su probabilidad alcanza el umbral seleccionado. La decisión positiva se deriva después mediante la regla del experimento: RBBB, elevación del ST e inversión de T deben estar presentes de forma simultánea.

El umbral se selecciona dentro de cada pliegue utilizando solo los pacientes de validación. Entre los valores candidatos se conserva el que maximiza la *Balanced Accuracy* de la etiqueta

derivada a nivel de paciente. Si la validación no contiene ambas clases, se mantiene el valor 0,5. La etiqueta del paciente de prueba no interviene en esta elección.

6.5.6.- Adaptación de dominio

Además de la transferencia directa, se evaluaron cuatro variantes de adaptación de dominio no supervisada. El simulador QRS/ST se mantiene como fuente etiquetada, mientras que el HUCA actúa como dominio objetivo sin anotaciones morfológicas. Estos métodos intentan reducir la discrepancia entre las representaciones de las imágenes sintéticas y reales, sin convertir la cohorte clínica en un conjunto supervisado.

El preentrenamiento autosupervisado aplica SimCLR a imágenes del HUCA sin utilizar sus etiquetas [34]. El encoder recibe dos vistas aumentadas de una misma imagen, acerca entre sí sus representaciones y las separa de las correspondientes a otros elementos del lote. Los pesos obtenidos inicializan después la CNN entrenada con el simulador.

CORAL añade una pérdida que aproxima las covarianzas de las características de origen y destino [35]. MMD mide la discrepancia entre ambas distribuciones mediante kernels RBF y penaliza la separación entre sus medias embebidas [36]. DANN incorpora un clasificador de dominio y una capa de inversión de gradiente [33]. De este modo, el extractor busca rasgos útiles para la tarea pero menos informativos sobre el origen sintético o real de la imagen.

Método	Idea principal
SSL	Preentrenar el encoder con imágenes del HUCA sin etiquetas mediante aprendizaje contrastivo.
CORAL	Alinear covarianzas de características entre simulador y HUCA.
MMD	Reducir una distancia de distribución con kernels RBF.
DANN	Aprender características invariantes al dominio con inversión de gradiente.

Tabla 6.2.- Métodos de adaptación de dominio evaluados para la CNN.

6.5.7.- Grad-CAM

Grad-CAM se utiliza como diagnóstico cualitativo y no como una explicación clínica suficiente [32]. El mapa relaciona regiones de la imagen con el logit del modelo, pero no permite concluir que la red haya aprendido un criterio médico correcto. En este trabajo sirve para observar si las activaciones se concentran en zonas plausibles y para identificar decisiones erróneas pese a una localización visual razonable. La Figura 6.2 presenta un ejemplo.

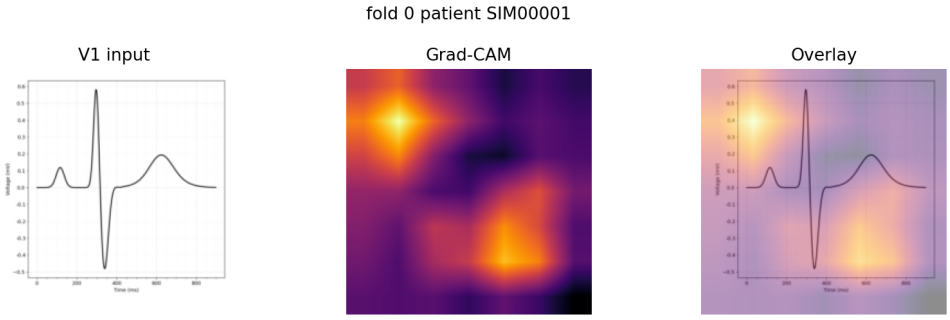


Figura 6.2.- Ejemplo Grad-CAM de la CNN para una única imagen V1 del conjunto sintético: entrada, mapa de activación y superposición.

6.5.8.- Qué se mide

La evaluación posterior aborda primero si la CNN aprende la regla visual del simulador con pocos ejemplos. Después examina si esa capacidad se transfiere a los ECG de la cohorte del HUCA y si la adaptación de dominio reduce la diferencia observada. Los resultados se presentan por separado para ambos dominios.

6.6.- VLM CON ICL

El segundo enfoque utiliza un modelo de visión y lenguaje con aprendizaje en contexto. El VLM no se entrena con los ejemplos seleccionados en cada pliegue: los recibe como demostraciones antes de la imagen objetivo cuando $K > 0$. El experimento estudia si ese contexto permite concretar la tarea sin actualizar los pesos.

6.6.1.- Motivación

El ajuste supervisado puede ser inestable cuando solo se dispone de unos pocos pacientes. El aprendizaje en contexto ofrece otra forma de utilizar sus etiquetas: no las convierte en gradientes, sino que las presenta como una guía explícita durante la inferencia.

No se presupone que esta estrategia supere a la CNN. Se compara el VLM tanto con la referencia supervisada como con su propia condición sin demostraciones para medir el efecto del contexto.

6.6.2.- Modelos médicos, modelos cerrados y privacidad

Existen modelos multimodales generalistas y otros adaptados al ámbito clínico. Algunos trabajos han estudiado modelos propietarios servidos por API para detectar anomalías

en ECG tratados como imagen mediante aprendizaje en contexto [28]. En esta memoria se adopta una configuración distinta para conservar el control sobre el modelo y el tratamiento de los datos.

Aunque las imágenes clínicas están seudonimizadas, siguen siendo datos sanitarios. Por este motivo se utilizan pesos abiertos en infraestructura universitaria bajo control propio. vLLM expone el modelo mediante un endpoint compatible con la API de OpenAI, sin enviar los trazados a un proveedor comercial. La configuración permite fijar la versión y los parámetros de inferencia.

6.6.3.- Modelo evaluado

El modelo evaluado es `google/gemma-4-E4B-it` [29]. Admite entradas de texto e imagen y permite configurar el presupuesto visual. La disponibilidad de sus pesos hace posible desplegar una versión fija en la infraestructura utilizada.

Gemma 4 no se selecciona por una superioridad demostrada en ECG, sino para caracterizar el comportamiento de un modelo generalista con pocos ejemplos. Los resultados no constituyen una validación del modelo para esta modalidad clínica.

6.6.4.- Construcción del prompt

La inferencia sigue el mismo orden en todos los pliegues. Primero se seleccionan los pacientes que actuarán como demostraciones, excluyendo al paciente de prueba. Después se construye un mensaje multimodal con la instrucción de sistema, las demostraciones y, al final, la imagen de consulta. La Figura 6.3 representa esta secuencia.

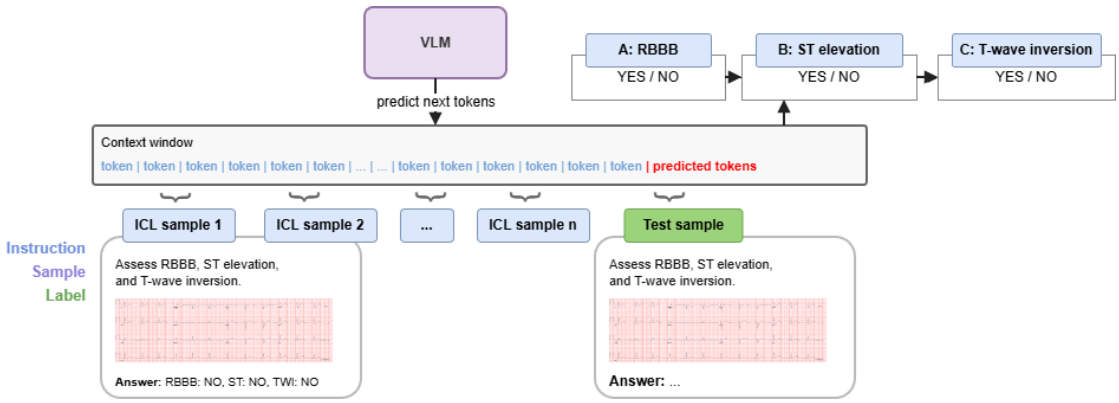


Figura 6.3.- Construcción del contexto VLM/ICL. Las demostraciones preceden a la imagen de consulta y la predicción se obtiene sin actualizar los pesos.

Cada demostración contiene una imagen de ECG y la respuesta correcta en formato JSON. La consulta se coloca después de todos los ejemplos. La salida del modelo debe ajustarse al esquema definido; si el formato no es válido, se registra como tal y no se reconstruye mediante

una interpretación manual.

No se exige una explicación libre, porque la evaluación compara decisiones binarias y no informes clínicos. El formato cerrado reduce la ambigüedad y evita convertir una respuesta plausible en una etiqueta mediante un juicio subjetivo.

6.6.5.- Condiciones de consulta

Se evalúan tres condiciones. En *zero-shot*, el modelo solo recibe las instrucciones y la imagen objetivo. La salida depende así de su conocimiento previo y de la descripción textual de la tarea, sin ejemplos locales.

En ICL estándar, para $K \geq 2$ se selecciona primero una demostración positiva y otra negativa. Las $K - 2$ posiciones restantes se completan de forma seudoaleatoria entre los pacientes disponibles. La condición estándar tiene, por tanto, una cobertura mínima de ambas clases y no equivale a una recuperación completamente aleatoria.

En ICL balanceado se intenta seleccionar $K/2$ demostraciones positivas y $K/2$ negativas. Si una clase no dispone de suficientes pacientes dentro del pliegue, las posiciones libres se completan con la otra. La comparación permite estudiar si una representación equitativa de las clases modifica la sensibilidad y la especificidad frente a la cobertura mínima del ICL estándar. Las semillas 42, 123 y 2026 fijan las selecciones de ambas condiciones.

6.6.6.- Origen del contexto

En el simulador, las demostraciones y la consulta pertenecen al mismo dominio morfológico. Para la cohorte del HUCA se analizan dos orígenes del contexto. La comparación principal utiliza pacientes de la propia cohorte como demostraciones y una imagen V1 clínica como consulta; ambos elementos comparten así dominio visual y referencia.

El análisis complementario utiliza demostraciones del simulador para consultar imágenes del HUCA. El modelo recibe entonces etiquetas morfológicas sintéticas y la evaluación se realiza contra la referencia clínica de la cohorte. Esta rama mide la transferencia sintético-real del contexto; no se interpreta como una solución clínica.

La CNN y el VLM se comparan a nivel de paciente y con las mismas métricas. La diferencia reside en el uso de K: la primera actualiza sus pesos, mientras que el segundo incorpora las imágenes al contexto de inferencia.

Capítulo 7. Resultados

7.1.- DOMINIO SINTÉTICO

El dominio sintético permite evaluar una regla morfológica conocida antes de analizar los ECG reales. Un caso se considera positivo solo cuando reúne los tres hallazgos: morfología compatible con RBBB, elevación del segmento ST e inversión de la onda T. Si falta cualquiera de ellos, la referencia es negativa. Esta tarea no mide utilidad clínica; comprueba si la CNN y el VLM identifican una combinación visual definida en una imagen de ECG.

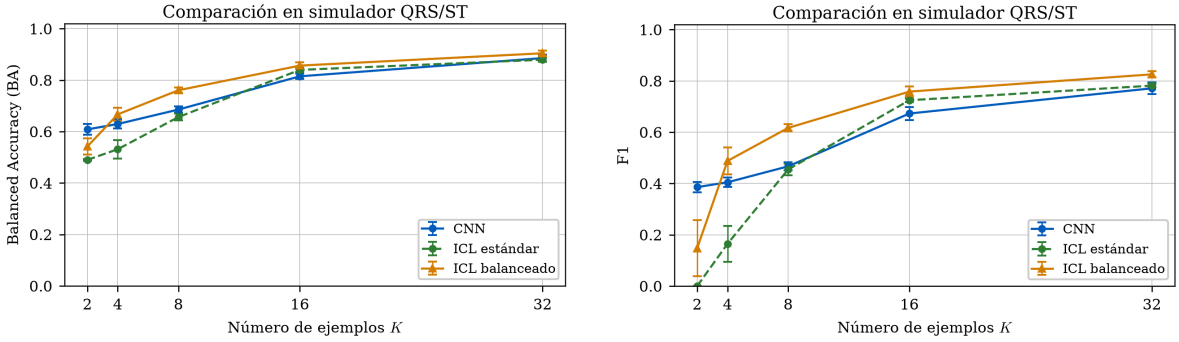
Cada uno de los 100 pacientes aporta una imagen V1. La evaluación LOOCV se repite con las semillas 42, 123 y 2026, de modo que las matrices agregadas contienen 300 predicciones sobre las mismas 100 imágenes.

La Tabla 7.1 reúne los puntos principales de la CNN y de Gemma 4. Los resultados de todos los valores de K se incluyen en el apéndice B.

Método	K	BA	F1	Sens.	Esp.
CNN ResNet18	32	$0,885 \pm 0,013$	0,771	0,867	0,904
Gemma 4 zero-shot	0	$0,500 \pm 0,000$	0,000	0,000	1,000
Gemma 4 ICL estándar	32	$0,879 \pm 0,008$	0,781	0,833	0,925
Gemma 4 ICL balanceado	32	$0,904 \pm 0,011$	0,825	0,867	0,942

Tabla 7.1.- Mejores resultados en el simulador QRS/ST. La BA se presenta como media y desviación estándar de tres semillas.

La Figura 7.1 muestra la evolución de la *Balanced Accuracy* (BA) y F1 con K.

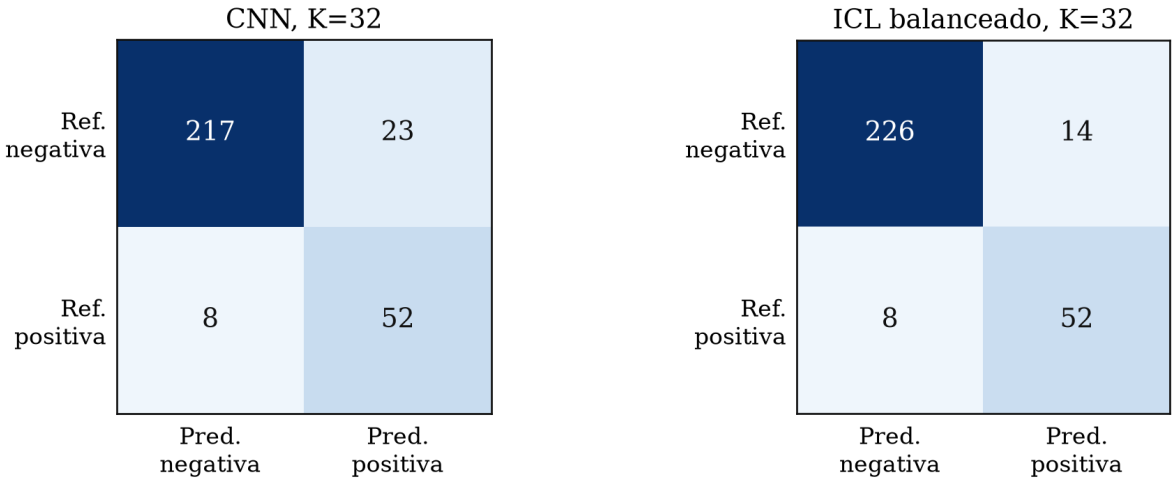


(a) Balanced Accuracy (BA). **(b)** F1.

Figura 7.1.- Rendimiento de CNN e ICL en el simulador según el número de ejemplos. Las barras representan la desviación estándar entre semillas.

La CNN mejora en todos los valores sucesivos de K. El incremento más acusado aparece al pasar de 8 a 16 pacientes. En $K = 32$ alcanza una BA de 0,885, F1 de 0,771, sensibilidad de 0,867 y especificidad de 0,904. La BA aumenta 0,071 respecto a $K = 16$, por lo que la curva no muestra saturación dentro del intervalo evaluado.

En zero-shot, Gemma 4 asigna todos los casos a la clase negativa y obtiene una BA de 0,500. Las demostraciones modifican este comportamiento: el ICL balanceado ya recupera algunos positivos con $K = 2$, mientras que el estándar comienza a hacerlo en $K = 4$. A partir de $K = 8$, ambas curvas mejoran de forma continuada. El valor numéricamente más alto corresponde al contexto balanceado con $K = 32$, con BA de 0,904 y F1 de 0,825. Frente al ICL estándar del mismo tamaño, la sensibilidad pasa de 0,833 a 0,867 y la especificidad de 0,925 a 0,942. La comparación es descriptiva, pues no se realizó un contraste inferencial. La Figura 7.2 muestra los errores agregados de los mejores puntos.



(a) CNN, $K = 32$.

(b) ICL balanceado, $K = 32$.

Figura 7.2.- Matrices de confusión agregadas en el simulador. Cada matriz suma las predicciones de tres semillas sobre los mismos 100 pacientes.

Los dos enfoques aprovechan el aumento de ejemplos en este dominio. La CNN ajusta un clasificador específico y el VLM pasa de una predicción monoclase en zero-shot al mayor valor observado, sin actualizar sus pesos. Esta diferencia numérica no implica superioridad general del ICL. Las imágenes sintéticas son homogéneas, las etiquetas proceden de reglas y no recogen la variabilidad de adquisición o de fenotipo de un ECG clínico. El resultado sirve como referencia controlada para interpretar la evaluación real.

7.2.- COHORTE DEL HUCA

La evaluación sobre la cohorte del HUCA introduce dos cambios respecto al simulador: las imágenes proceden de ECG clínicos y la referencia deja de ser una regla morfológica explícita. Para separar ambos efectos, el análisis distingue la transferencia desde el simulador del uso de demostraciones tomadas de la propia cohorte.

Primero se describe la cohorte del Hospital Universitario Central de Asturias (HUCA), incluida en el recurso Brugada-HUCA [39]. Después se estudian la CNN con adaptación de dominio y Gemma 4 con contexto sintético. La comparación principal utiliza, por último, demostraciones de la propia cohorte del HUCA.

7.2.1.- Cohorte y unidad experimental

La campaña final parte de 363 pacientes y excluye 46 registros cuyo patrón basal es distinto de cero. Quedan 317 pacientes: 116 con referencia positiva y 201 con referencia negativa.

Se genera una única imagen V1 por paciente y cada uno actúa como muestra de prueba en uno de los 317 pliegues LOOCV.

Grupo	Pacientes	Imágenes únicas
Referencia positiva	116	116
Referencia negativa	201	201
Total evaluado	317	317

Tabla 7.2.- Composición de la cohorte del HUCA utilizada en la evaluación.

El preprocesamiento selecciona V1, detecta un latido central y recorta una ventana que abarca 300 ms antes de R y 600 ms después. Cada imagen conserva la asociación con su paciente, su referencia clínica y el pliegue de evaluación. La Figura 7.3 distingue el número de pacientes, imágenes y predicciones agregadas.

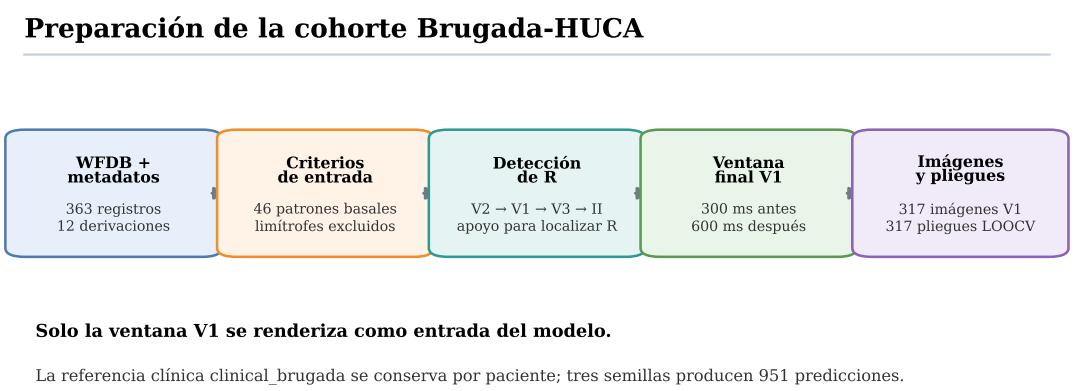


Figura 7.3.- Preparación de la imagen V1 y de los pliegues por paciente. Otras derivaciones pueden ayudar a localizar R, pero solo V1 se renderiza como entrada. Las 951 entradas de una matriz agregada corresponden a 317 pacientes evaluados con tres semillas, no a imágenes distintas.

La variable disponible no equivale a las tres etiquetas morfológicas del simulador. La tarea real utiliza la referencia binaria por paciente almacenada en `clinical_brugada`, por lo que las conclusiones se limitan a priorización para revisión especializada. Su distribución tampoco coincide con la documentación de Brugada-HUCA v1.0.0, que recoge 76 registros Brugada y 287 controles antes del procesamiento [39]. Como el paquete final no contiene el manifiesto intermedio que explica el cambio, las métricas se atribuyen al subconjunto procesado de la campaña. Esta carencia se mantiene como una limitación de reproducibilidad.

La CNN no se entrena directamente con la cohorte del HUCA porque su cabeza multietiqueta requiere anotaciones de RBBB, elevación del ST e inversión de T que no están dispo-

nibles. Su evaluación mide una transferencia desde la regla sintética. Gemma 4, en cambio, puede incorporar la referencia binaria mediante demostraciones sin modificar sus pesos. La Figura 7.4 sitúa ambas estrategias entre los dos dominios.

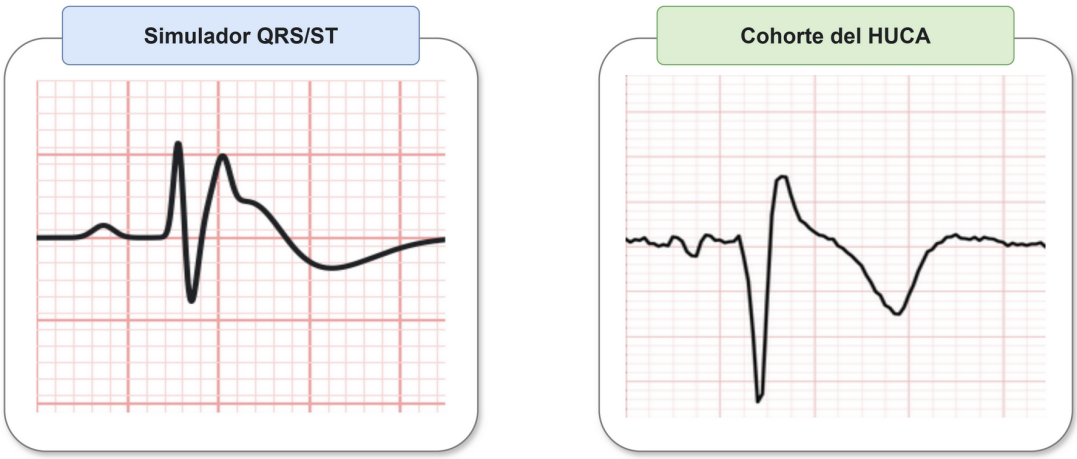


Figura 7.4.- Relación entre el dominio sintético, la cohorte del HUCA y las dos estrategias de adaptación evaluadas.

7.2.2.- Transferencia desde el simulador

Los dos análisis siguientes mantienen el simulador como única fuente de etiquetas morfológicas. En la CNN se añaden métodos de adaptación que utilizan imágenes del HUCA sin esas etiquetas. En Gemma 4 se conserva el modelo sin ajuste y se introducen demostraciones sintéticas antes de cada consulta del HUCA.

7.2.2.1.- CNN y adaptación de dominio

La CNN base obtiene su mejor resultado real en $K = 4$, con una BA de $0,551 \pm 0,034$. La curva no reproduce el crecimiento observado en el simulador: pasa de 0,531 en $K = 2$ a 0,551 en $K = 4$, pero desciende hasta 0,498 en $K = 32$. Aumentar los ejemplos sintéticos mejora el ajuste a la regla de origen, pero no se asocia aquí con una mayor concordancia con la referencia clínica.

La adaptación de dominio se evaluó en $K = 16$ y $K = 32$. MMD eleva la BA de 0,498 a 0,546 en $K = 32$, mientras que CORAL pasa de 0,520 a 0,545 en $K = 16$. Ninguno supera el 0,551 de la CNN base con $K = 4$, y las comparaciones carecen de contraste inferencial. Los métodos corrigen parte de la caída en configuraciones concretas, pero no eliminan la discrepancia entre la regla sintética y la referencia clínica.

Configuración	K	BA	F1	Sens.	Esp.
CNN base, mejor global	4	$0,551 \pm 0,034$	0,506	0,670	0,433
CORAL	16	$0,545 \pm 0,011$	0,501	0,670	0,421
MMD	32	$0,546 \pm 0,011$	0,502	0,678	0,413

Tabla 7.3.- Puntos principales de la CNN sobre la cohorte del HUCA. CORAL y MMD se comparan con sus bases del mismo valor de K.

7.2.2.2.- VLM con contexto sintético

En el análisis complementario, las demostraciones proceden del simulador y las consultas, de la cohorte del HUCA. El mejor punto corresponde al ICL balanceado con $K = 16$: BA de $0,514 \pm 0,008$, sensibilidad de 0,063 y especificidad de 0,965. El modelo predice casi siempre la clase negativa, por lo que el contexto sintético apenas modifica la decisión inicial. La Figura 7.5 reúne las dos pruebas de transferencia.

Al aumentar el contexto balanceado de $K = 16$ a $K = 32$, la BA pasa de 0,514 a 0,512 y la *Accuracy*, de 0,635 a 0,630. Al mismo tiempo, la sensibilidad sube de 0,063 a 0,072 y la especificidad baja de 0,965 a 0,952. La diferencia de BA es de solo 0,002 y queda por debajo de la desviación entre semillas de ambos puntos. Se interpreta como una meseta con otro equilibrio de errores, no como evidencia de un perjuicio causado por añadir demostraciones.

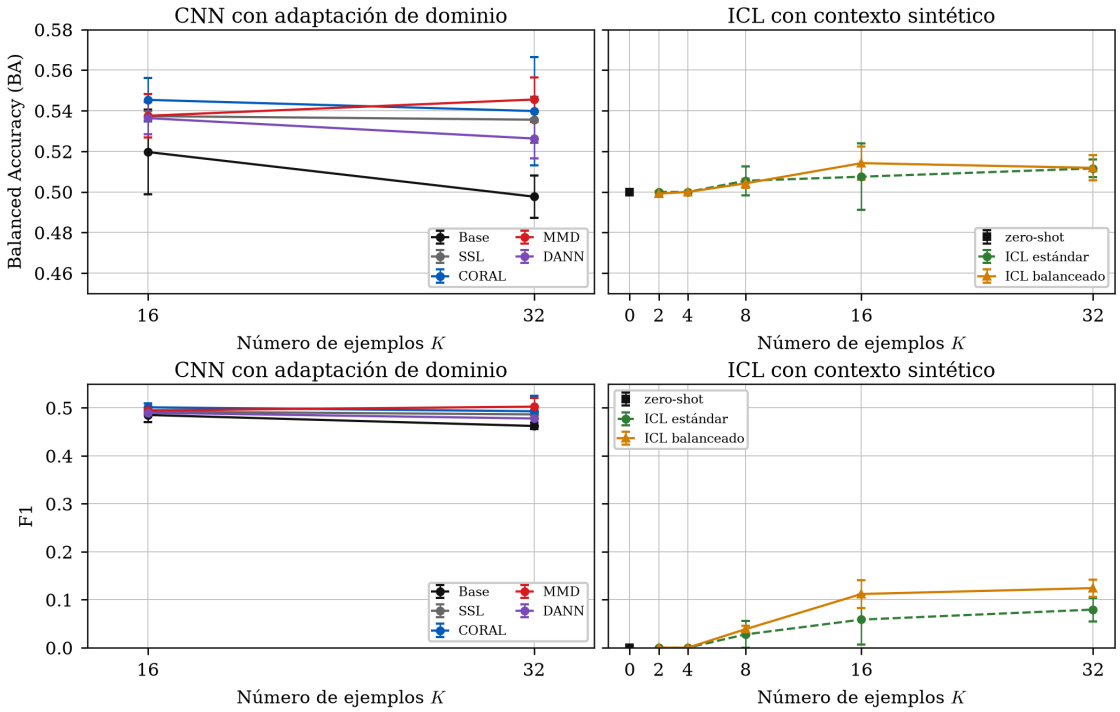


Figura 7.5.- Transferencia sintético-real. A la izquierda se comparan las variantes de adaptación de la CNN; a la derecha, Gemma 4 con demostraciones sintéticas.

7.2.3.- Contexto clínico y comparación principal

La comparación principal toma las demostraciones de la propia cohorte, siempre dentro de cada pliegue. En zero-shot, Gemma 4 no recupera ningún positivo y obtiene una BA de 0,499. Esta predicción prácticamente monoclase describe el comportamiento del modelo sin ejemplos locales; no permite concluir que el ECG carezca de información relevante.

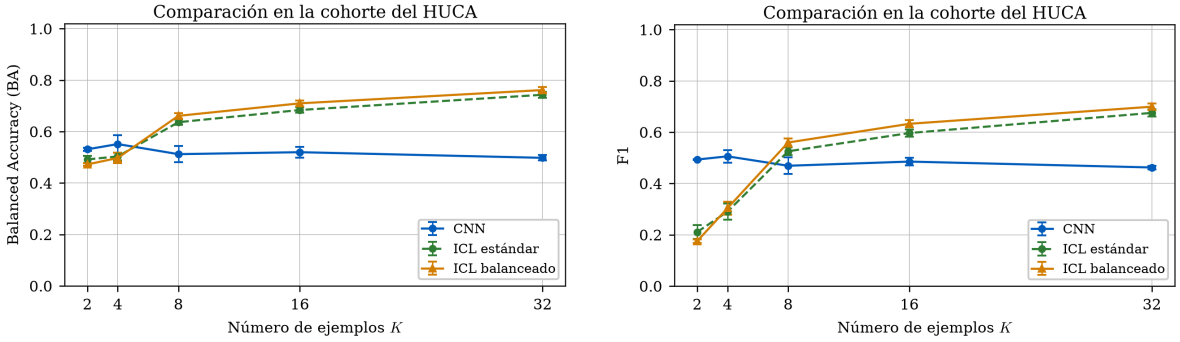
Las demostraciones reales cambian la distribución de las predicciones. Con $K = 2$ y $K = 4$, el ICL estándar obtiene una BA ligeramente mayor que el balanceado: 0,492 frente a 0,472 y 0,503 frente a 0,497, respectivamente. Este resultado no es contradictorio con el muestreo, porque la selección estándar ya contiene al menos un ejemplo de cada clase; el balance estricto controla la proporción, pero no la representatividad de cada demostración. Además, las diferencias son pequeñas y no se sometieron a un contraste inferencial.

A partir de $K = 8$, el contexto balanceado supera al estándar en los tres valores evaluados. Ambas variantes alcanzan su máximo en $K = 32$: $0,743 \pm 0,011$ para el ICL estándar y $0,761 \pm 0,011$ para el balanceado. Este último obtiene una sensibilidad de 0,741 y una especificidad de 0,781. La mejora frente al zero-shot aparece, por tanto, cuando el contexto contiene suficientes ejemplos locales, no por el mero hecho de incluir una demostración de cada clase.

Método	K	BA	F1	Sens.	Esp.
CNN ResNet18 base	4	$0,551 \pm 0,034$	0,506	0,670	0,433
Gemma 4 zero-shot	0	$0,499 \pm 0,001$	0,000	0,000	0,998
Gemma 4 ICL estándar	32	$0,743 \pm 0,011$	0,675	0,690	0,796
Gemma 4 ICL balanceado	32	$0,761 \pm 0,011$	0,699	0,741	0,781

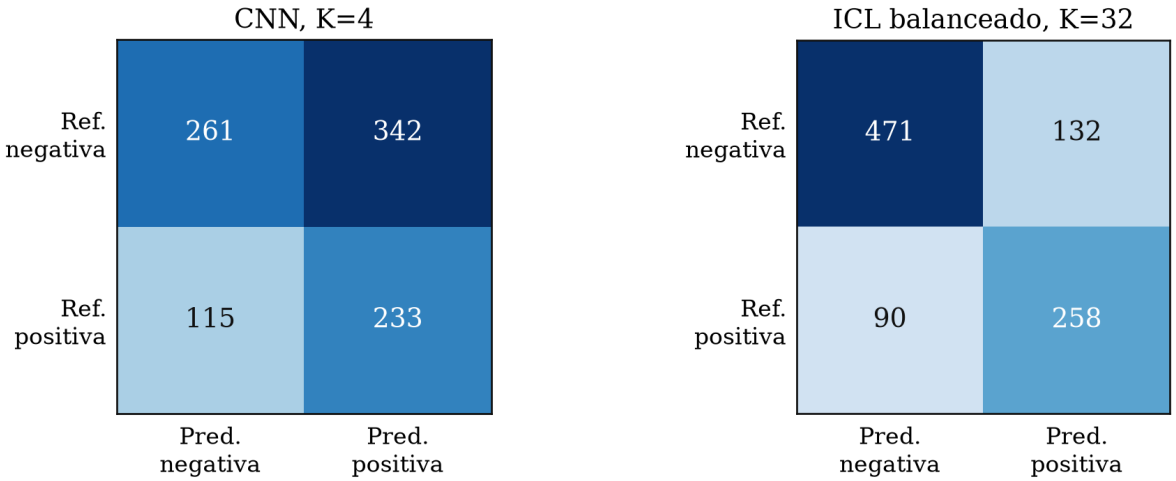
Tabla 7.4.- Mejores resultados sobre los ECG del HUCA. Las demostraciones de Gemma 4 proceden de la propia cohorte.

La Figura 7.6 muestra la evolución de la CNN y del VLM con K.



(a) Balanced Accuracy (BA). **(b)** F1.

Figura 7.6.- Comparación entre la CNN transferida desde el simulador y Gemma 4 con contexto clínico.



(a) CNN, $K = 4$. **(b)** ICL balanceado, $K = 32$.

Figura 7.7.- Matrices agregadas de los mejores puntos de la CNN y del VLM. Cada matriz suma 951 predicciones sobre 317 pacientes.

Las matrices de la Figura 7.7 muestran el cambio respecto al zero-shot. Con contexto clínico, Gemma 4 recupera más positivos sin clasificar como positivos a la mayoría de los controles. En su mejor punto supera numéricamente a la CNN transferida en BA, F1, sensibilidad y especificidad. El origen de las demostraciones resulta decisivo en este experimento: con ejemplos sintéticos, el mismo modelo permanece próximo a una decisión constante. El resultado muestra una adaptación local dentro de esta cohorte, pero no establece validez asistencial ni permite aislar qué propiedad concreta de las demostraciones causa la mejora. La Figura 7.8 detalla la sensibilidad y la especificidad.

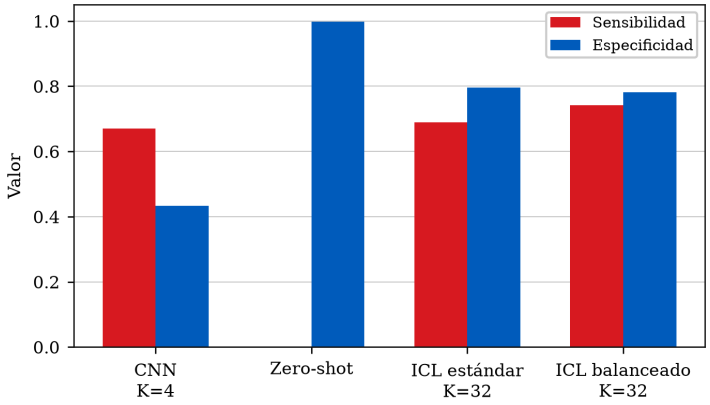
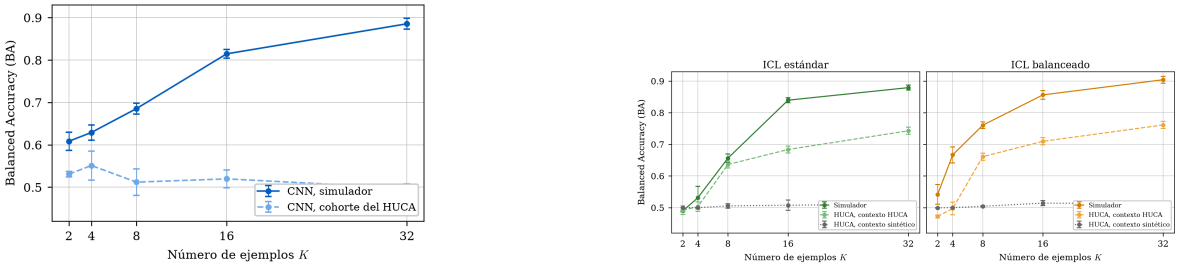


Figura 7.8.- Sensibilidad y especificidad de los mejores puntos sobre la cohorte del HUCA.

7.2.4.- Brecha sintético-real

La brecha entre dominios aparece en los dos enfoques. La CNN alcanza una BA de 0,885 en el simulador con $K = 32$, pero su mejor punto real es 0,551. En Gemma 4, el ICL balanceado llega a 0,904 en el simulador y a 0,761 cuando contexto y consulta son reales. Si las demostraciones son sintéticas y la consulta es real, el máximo se queda en 0,514. La Figura 7.9 resume estas diferencias.



(a) CNN base. **(b)** Gemma 4 según el origen del contexto.

Figura 7.9.- Brecha sintético-real medida mediante Balanced Accuracy (BA).

El simulador ofrece una tarea más separable para ambos enfoques, pero esa ventaja no se conserva al cambiar de imágenes y de referencia. La variabilidad de adquisición, las diferencias de escala, la heterogeneidad fenotípica y la información clínica ausente en una ventana V1 son explicaciones plausibles, no mecanismos demostrados por estos experimentos. Los resultados delimitan el simulador como banco de pruebas y señalan la necesidad de anotaciones morfológicas clínicas y evaluación multicéntrica.

La comparación permite localizar dónde se pierde rendimiento y cuánto se recupera con adaptación de dominio o con demostraciones locales. Con los datos disponibles, ambos modelos siguen siendo prototipos de investigación y no herramientas de diagnóstico o triaje autónomo.

Capítulo 8. Conclusiones generales

8.1.- CONCLUSIÓN PRINCIPAL

Este trabajo estudia cómo aprovechar un número reducido de pacientes etiquetados cuando el ECG está disponible como imagen. Se comparan dos regímenes: una CNN que actualiza sus pesos mediante entrenamiento y un VLM que incorpora demostraciones al contexto de inferencia. El significado de K cambia entre ambos, pero en los dos casos mide la cantidad de evidencia etiquetada que recibe el modelo.

El primer nivel de la evaluación es sintético. En el simulador QRS/ST, la ResNet18 mejora de forma progresiva hasta alcanzar una BA de $0,885 \pm 0,013$ con $K = 32$. Gemma 4 pasa de 0,500 en zero-shot a $0,904 \pm 0,011$ con contexto balanceado del mismo tamaño. Ambos modelos identifican la regla visual en un dominio homogéneo y con etiquetas definidas mediante validadores. Este resultado establece que la formulación es aprendible, pero no anticipa su comportamiento clínico.

El segundo nivel analiza la transferencia sintético-real. La CNN base obtiene un máximo de $0,551 \pm 0,034$ en el HUCA. MMD eleva el punto de $K = 32$ de 0,498 a 0,546, sin superar el máximo global. En Gemma 4, las demostraciones sintéticas alcanzan como máximo $0,514 \pm 0,008$, con sensibilidad de 0,063 y especificidad de 0,965. La pequeña bajada de BA en $K = 32$ queda dentro de la variación entre semillas y no aporta evidencia de un perjuicio por aumentar el contexto. En conjunto, la regla sintética no basta para predecir la referencia clínica real.

El tercer nivel utiliza demostraciones de la propia cohorte. Con $K = 2$ y $K = 4$, el ICL estándar supera ligeramente al balanceado; a partir de $K = 8$, la relación se invierte. En $K = 32$, el contexto balanceado alcanza una BA de $0,761 \pm 0,011$, con sensibilidad de 0,741 y especificidad de 0,781, frente a $0,743 \pm 0,011$ del estándar. El balance de clases no implica por sí solo un mejor resultado, pero con un contexto mayor ofrece el máximo observado en la cohorte. Sin validación externa ni contrastes inferenciales, esta mejora solo caracteriza el experimento local.

8.2.- APORTACIONES

La primera aportación es un protocolo documentado para estudiar ECG como imagen con pocos datos. Incluye generación sintética, preprocesamiento de V1, separación LOOCV

por paciente, tres semillas y métricas sensibles al desequilibrio. La ausencia del manifiesto clínico intermedio limita la reproducibilidad de la cohorte final, pero no la trazabilidad del procedimiento de evaluación una vez fijadas sus entradas.

La segunda aportación es separar el aprendizaje de la regla sintética, su transferencia a la cohorte del HUCA y el uso de contexto clínico local. Esta secuencia evita confundir el rendimiento del simulador con evidencia clínica y permite identificar en qué transición aparece la pérdida de rendimiento.

La tercera aportación es comparar el entrenamiento supervisado con el aprendizaje en contexto. La CNN utiliza K pacientes para ajustar sus pesos y requiere repetir el entrenamiento cuando cambia la muestra. El VLM mantiene sus parámetros y modifica el prompt. En la cohorte estudiada, esta segunda vía cambia la decisión cuando las demostraciones comparten dominio y referencia con la consulta.

La cuarta aportación es cuantificar la brecha sintético-real mediante dos análisis complementarios. Tanto la adaptación de dominio de la CNN como el contexto sintético del VLM muestran que los ejemplos generados no resuelven por sí solos la tarea clínica.

La quinta aportación es delimitar el papel del sistema. Se presenta un prototipo de investigación para priorizar la revisión, no un mecanismo diagnóstico. La identificación de Brugada requiere el ECG completo, el contexto clínico, valoración especializada y, cuando corresponda, pruebas adicionales.

8.3.- LIMITACIONES

La limitación principal reside en la cohorte del HUCA. Los 317 pacientes proceden de un único origen y la referencia clínica no incluye anotaciones independientes de RBBB, elevación del ST e inversión de T. La tarea combina así información morfológica y diagnóstica que una sola ventana V1 no puede representar por completo. Por la misma razón, la arquitectura actual no permite entrenar una CNN directamente con esa referencia sin redefinir la tarea.

La procedencia exacta de la referencia debe resolverse antes de reutilizar la cohorte procesada. Los archivos finales contienen 116 positivos y 201 negativos, mientras que Brugada-HUCA v1.0.0 documenta 76 registros Brugada y 287 controles antes del procesamiento [39]. Al faltar el manifiesto que relaciona ambas distribuciones, las métricas describen la campaña final y no una evaluación directa de la distribución pública.

La segunda limitación es la distancia entre el simulador y la práctica clínica. Sus imágenes son más homogéneas y las etiquetas responden a reglas explícitas. Ni las alineaciones probadas ni las demostraciones sintéticas eliminan esa diferencia. Además, las tres semillas se aplican sobre los mismos pacientes: su desviación estándar mide variabilidad experimental y no incertidumbre poblacional.

La tercera limitación afecta al VLM. Solo se evalúa Gemma 4, por lo que no puede establecerse una comparación entre modelos médicos y generalistas. El ICL también depende del prompt, del orden, de la selección de demostraciones y de la ventana de contexto. La literatura señala además la influencia de la información textual y de la recuperación de ejemplos [26, 27]. Los resultados no se generalizan, por tanto, a otros VLM o diseños de contexto.

No se ha realizado una evaluación prospectiva ni un análisis del impacto sobre el circuito clínico. Tampoco se estudian la calibración, el coste de los errores por subgrupo o los cambios en la carga de revisión. Las métricas disponibles son insuficientes para justificar un despliegue.

8.4.- TRABAJO FUTURO

La prioridad es obtener anotaciones morfológicas clínicas por derivación. Con ellas podría compararse la misma tarea en los dominios sintético y real, separar el error morfológico del asociado a la referencia clínica y entrenar una CNN real-real sin reutilizar etiquetas incompatibles.

También se necesita una validación externa con más casos positivos. Un modelo evaluado en un único centro puede aprovechar propiedades del equipo, del procesamiento o del renderizado. Cualquier evaluación orientada a un uso asistencial debería incorporar datos de otros hospitales, revisión experta de los errores, intervalos de incertidumbre, calibración y rendimiento por subgrupos definidos con antelación.

En el VLM conviene estudiar la recuperación y el orden de las demostraciones, así como modelos especializados en ECG. La comparación debería incorporar latencia y coste, además de BA. Una CNN ligera requiere entrenamiento local, pero abarata la inferencia; un VLM evita el ajuste de pesos a costa de más cómputo por consulta y de una construcción cuidadosa del contexto.

En conjunto, los experimentos muestran que una imagen de ECG contiene información aprovechable, especialmente cuando no se conserva la señal digital original. El zero-shot de Gemma 4 no resuelve la tarea clínica y colapsa hacia la clase negativa. Las demostraciones locales cambian ese comportamiento sin reentrenar el modelo, aunque el efecto depende del tamaño y de la composición del contexto. La contribución no es un diagnóstico automático, sino una caracterización inicial del ICL como mecanismo de adaptación local. Su uso permanece limitado a investigación y exige validación externa, trazabilidad y supervisión especializada.

Capítulo 9. Aspectos éticos y protección de datos

9.1.- ASPECTOS ÉTICOS

El estudio es retrospectivo y metodológico. Compara formas de aprender con pocas imágenes de ECG etiquetadas, sin automatizar decisiones asistenciales ni sustituir la valoración clínica. Sus predicciones solo se interpretan como señales experimentales de priorización; no constituyen un diagnóstico, un descarte de enfermedad o una recomendación terapéutica.

La principal precaución ética consiste en no extender los resultados más allá del diseño. La valoración del síndrome de Brugada requiere especialistas, contexto clínico y, en pacientes seleccionados, pruebas complementarias. Las métricas describen únicamente el comportamiento de los modelos con los datos y protocolos utilizados.

Esta distinción es especialmente importante para el VLM. El cambio de una predicción al introducir demostraciones no equivale a competencia clínica autónoma. La mejora frente al zero-shot caracteriza la adaptación al contexto dentro del experimento y no autoriza un uso sin revisión profesional.

La adaptación de dominio de la CNN exige la misma cautela. Las mejoras observadas al incorporar imágenes del HUCA sin etiquetas morfológicas no constituyen una validación clínica. Solo describen una reducción parcial de la diferencia entre las representaciones sintéticas y reales en algunas configuraciones.

También existe riesgo de sesgo de selección. La cohorte del HUCA procede de un único recurso y contiene 116 referencias positivas en el subconjunto procesado. La falta de análisis por subgrupos no implica que el rendimiento sea uniforme, sino que el tamaño disponible no permite estimarlo con precisión. Cualquier extensión clínica requeriría validación externa, evaluación prospectiva y supervisión profesional.

9.2.- PROTECCIÓN DE DATOS

El artículo 9 del Reglamento General de Protección de Datos considera los datos de salud una categoría especial [43]. Su tratamiento requiere una base jurídica adecuada, minimización, limitación de la finalidad, confidencialidad y medidas de seguridad proporcionales al riesgo. En investigación científica, el artículo 89 añade salvaguardias técnicas y organizati-

vas.

En España, la Ley Orgánica 3/2018 completa este marco e incorpora garantías para el tratamiento con fines de investigación, en particular cuando se emplean datos seudonimizados [44]. La Ley 14/2007 de Investigación biomédica añade principios de confidencialidad, supervisión ética y protección de las personas participantes [45].

Brugada HUCA se distribuye sin información identificativa y declara una anonimización mediante Safe Harbor [39]. Aun así, las imágenes derivadas de ECG se tratan con prudencia: se conservan solo los campos necesarios, se excluyen identificadores directos de los materiales de difusión y los datos permanecen en entornos protegidos. La incorporación de información adicional no anónima exigiría revisar la base jurídica y valorar una evaluación de impacto antes del tratamiento.

Apéndice A. Configuración experimental

Este apéndice recoge los parámetros principales de la configuración experimental. Se incluyen los valores necesarios para interpretar los resultados y comparar los enfoques CNN y VLM/ICL.

A.1.- CONJUNTO SINTÉTICO QRS/ST

Propiedad	Valor
Fuente	Simulador QRS/ST descrito en el capítulo 5
Pacientes	100
Imágenes únicas	100
Predicciones agregadas	300, correspondientes a tres semillas
Familias fuente	Cinco familias morfológicas descritas en el capítulo 5
Pacientes por familia	20
Derivaciones renderizadas	V1
Frecuencia de muestreo	500 Hz
Duración del latido	900 ms
Resolución de guardado	130 ppp
Positivos derivados	20
Negativos o incompletos	80
Valores de K	$K = \{2, 4, 8, 16, 32\}$
Semillas	42, 123 y 2026

Tabla A.1.- Configuración del conjunto sintético final.

La etiqueta positiva se obtiene cuando RBBB, elevación del ST e inversión de T están presentes de forma simultánea. La decisión por paciente utiliza únicamente la imagen V1 y aplica después el umbral seleccionado.

A.2.- COHORTE DEL HUCA

Propiedad	Valor
Fuente	Hospital Universitario Central de Asturias (HUCA), recurso Brugada HUCA 1.0.0
Pacientes brutos	363
Pacientes excluidos	46 por patrón basal limítrofe
Pacientes incluidos	317
Imágenes únicas incluidas	317
Predicciones agregadas	951, correspondientes a tres semillas
Referencias positivas	116
Referencias negativas	201
Derivaciones	V1
Ventana	300 ms antes de R y 600 ms después de R
Frecuencia de origen	100 Hz
Resolución de guardado	130 ppp
Separación	Leave-one-out por paciente

Tabla A.2.- Configuración de la cohorte procesada del HUCA.

La cohorte procesada del HUCA no incluye anotaciones independientes de los tres hallazgos morfológicos simulados. La evaluación emplea una referencia clínica por paciente. Esta variable, almacenada en `clinical_brugada`, procede de una revisión especializada.

A.3.- CONFIGURACIÓN CNN

Propiedad	Valor
Arquitectura	ResNet18
Pesos iniciales	Inicialización estándar de ResNet18
Entrada	RGB, 224 por 224
Salida	Tres hallazgos morfológicos
Pérdida	Entropía cruzada binaria multietiqueta
Optimizador	AdamW
Tasa de aprendizaje	3×10^{-4}
Lote	32
Épocas máximas	20
Estrategia de umbral	Selección en validación mediante Balanced Accuracy
Métrica principal	Balanced Accuracy por paciente
Grad-CAM	Límite de 12 paneles por ejecución sintética y 6 por ejecución sobre el HUCA

Tabla A.3.- Hiperparámetros de la CNN final.

A.4.- CONFIGURACIÓN DE ADAPTACIÓN DE DOMINIO

Propiedad	Valor
Origen etiquetado	Conjunto sintético QRS/ST
Destino no etiquetado	Cohorte del HUCA
Métodos	SSL, CORAL, MMD y DANN [34, 35, 36, 33]
Valores de K	$K = 16$ y $K = 32$
Semillas	42, 123 y 2026
Peso de adaptación	0,1
Escalas MMD	0,5, 1,0, 2,0 y 4,0
SSL	SimCLR durante 3 épocas
Política de destino	Transductiva compartida, sin etiquetas destino en la pérdida supervisada

Tabla A.4.- Configuración de los experimentos de adaptación de dominio.

A.5.- CONFIGURACIÓN VLM/ICL

El enfoque VLM/ICL usa los mismos pacientes reservados, valores de K y métricas por paciente que la CNN. La evaluación final corresponde a Gemma 4, servido mediante vLLM en infraestructura universitaria, con temperatura 0 y salida estructurada.

Elemento	Valor
Modelo informado	`google/gemma-4-E4B-it`
Servicio	vLLM en infraestructura universitaria
Entrada	Imagen ECG y demostraciones imagen-etiqueta
Valores de K	$K = \{0, 2, 4, 8, 16, 32\}$
Condiciones informadas	Zero-shot, ICL estándar e ICL balanceado
Contextos sobre la cohorte del HUCA	Demostraciones de la propia cohorte o del simulador
Salida morfológica	RBBB, elevación del ST e inversión de T
Salida clínica	Caso Brugada confirmado frente a normal
Métrica principal	Balanced Accuracy por paciente

Tabla A.5.- Configuración resumida del enfoque VLM/ICL.

La sección 6.6 describe este enfoque y el capítulo de resultados desarrolla su comparación con la CNN.

Apéndice B. Resultados completos

Este apéndice reúne las tablas agregadas utilizadas en el capítulo 7. Todas las cifras son medias de tres semillas. La incertidumbre indicada junto a la Balanced Accuracy (BA) corresponde a la desviación estándar entre ejecuciones. Las matrices acumulan predicciones sobre los mismos pacientes y no aumentan el tamaño de la muestra.

B.1.- CNN

Dominio	K	Acc.	BA	F1	Prec.	Sens.	Esp.
Sintético	2	0,593	$0,608 \pm 0,021$	0,386	0,279	0,633	0,583
Sintético	4	0,627	$0,629 \pm 0,018$	0,404	0,297	0,633	0,625
Sintético	8	0,687	$0,685 \pm 0,013$	0,467	0,355	0,683	0,688
Sintético	16	0,853	$0,815 \pm 0,011$	0,673	0,611	0,750	0,879
Sintético	32	0,897	$0,885 \pm 0,013$	0,771	0,695	0,867	0,904
HUCA	2	0,492	$0,531 \pm 0,006$	0,493	0,389	0,675	0,386
HUCA	4	0,519	$0,551 \pm 0,034$	0,506	0,407	0,670	0,433
HUCA	8	0,481	$0,512 \pm 0,032$	0,469	0,376	0,629	0,395
HUCA	16	0,479	$0,520 \pm 0,021$	0,485	0,381	0,670	0,370
HUCA	32	0,462	$0,498 \pm 0,010$	0,462	0,364	0,632	0,363

Tabla B.1.- Resultados completos de la CNN en los dominios sintético y real.

B.2.- ADAPTACIÓN DE DOMINIO DE LA CNN

Método	K	Acc.	BA	F1	Prec.	Sens.	Esp.
Base	16	0,479	$0,520 \pm 0,021$	0,485	0,381	0,670	0,370
SSL	16	0,506	$0,537 \pm 0,003$	0,492	0,395	0,655	0,420
CORAL	16	0,512	$0,545 \pm 0,011$	0,501	0,401	0,670	0,421
MMD	16	0,504	$0,538 \pm 0,011$	0,495	0,395	0,664	0,411
DANN	16	0,507	$0,536 \pm 0,008$	0,490	0,394	0,647	0,426
Base	32	0,462	$0,498 \pm 0,010$	0,462	0,364	0,632	0,363
SSL	32	0,509	$0,536 \pm 0,011$	0,486	0,394	0,635	0,436
CORAL	32	0,509	$0,540 \pm 0,027$	0,493	0,396	0,655	0,425
MMD	32	0,510	$0,546 \pm 0,011$	0,502	0,400	0,678	0,413
DANN	32	0,499	$0,526 \pm 0,010$	0,478	0,387	0,626	0,426

Tabla B.2.- Resultados completos de adaptación no supervisada sobre la cohorte del HUCA.

B.3.- VLM CON APRENDIZAJE EN CONTEXTO

B.3.1.- Dominio sintético

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	$0,500 \pm 0,000$	0,000	0,000	1,000
Estándar	2	$0,490 \pm 0,003$	0,000	0,000	0,979
Estándar	4	$0,531 \pm 0,036$	0,164	0,100	0,963
Estándar	8	$0,656 \pm 0,014$	0,454	0,417	0,896
Estándar	16	$0,840 \pm 0,008$	0,724	0,767	0,913
Estándar	32	$0,879 \pm 0,008$	0,781	0,833	0,925
Balanceado	2	$0,542 \pm 0,031$	0,148	0,083	1,000
Balanceado	4	$0,667 \pm 0,025$	0,488	0,367	0,967
Balanceado	8	$0,760 \pm 0,011$	0,617	0,617	0,904
Balanceado	16	$0,856 \pm 0,014$	0,758	0,783	0,929
Balanceado	32	$0,904 \pm 0,011$	0,825	0,867	0,942

Tabla B.3.- Resultados de Gemma 4 en el simulador QRS/ST.

B.3.2.- Cohorte del HUCA con contexto clínico

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	$0,499 \pm 0,001$	0,000	0,000	0,998
Estándar	2	$0,492 \pm 0,014$	0,211	0,152	0,831
Estándar	4	$0,503 \pm 0,015$	0,290	0,239	0,768
Estándar	8	$0,636 \pm 0,011$	0,525	0,491	0,781
Estándar	16	$0,684 \pm 0,011$	0,596	0,586	0,781
Estándar	32	$0,743 \pm 0,011$	0,675	0,690	0,796
Balanceado	2	$0,472 \pm 0,005$	0,175	0,126	0,818
Balanceado	4	$0,497 \pm 0,020$	0,304	0,261	0,733
Balanceado	8	$0,661 \pm 0,011$	0,560	0,526	0,796
Balanceado	16	$0,710 \pm 0,011$	0,632	0,638	0,781
Balanceado	32	$0,761 \pm 0,011$	0,699	0,741	0,781

Tabla B.4.- Resultados de Gemma 4 sobre la cohorte del HUCA con demostraciones de la propia cohorte.

B.3.3.- Cohorte del HUCA con contexto sintético

Condición	K	BA	F1	Sens.	Esp.
Zero-shot	0	$0,500 \pm 0,000$	0,000	0,000	1,000
Estándar	2	$0,500 \pm 0,000$	0,000	0,000	1,000
Estándar	4	$0,500 \pm 0,000$	0,000	0,000	1,000
Estándar	8	$0,506 \pm 0,007$	0,028	0,014	0,997
Estándar	16	$0,508 \pm 0,016$	0,059	0,032	0,983
Estándar	32	$0,512 \pm 0,004$	0,079	0,043	0,980
Balanceado	2	$0,499 \pm 0,001$	0,000	0,000	0,998
Balanceado	4	$0,500 \pm 0,000$	0,000	0,000	1,000
Balanceado	8	$0,504 \pm 0,002$	0,039	0,020	0,988
Balanceado	16	$0,514 \pm 0,008$	0,112	0,063	0,965
Balanceado	32	$0,512 \pm 0,006$	0,124	0,072	0,952

Tabla B.5.- Resultados de Gemma 4 sobre la cohorte del HUCA con demostraciones sintéticas.

Apéndice C. Prompts y respuestas estructuradas

C.1.- CRITERIO DE CONSERVACIÓN

Los prompts forman parte del protocolo experimental. En un modelo de visión y lenguaje, cambios pequeños en instrucciones, orden o formato pueden modificar la respuesta. Por esa razón se conserva el contenido de los prompts y el esquema de salida exigido.

C.2.- SISTEMA PARA TAREA MORFOLÓGICA

```
You are evaluating single-beat right precordial ECG images from lead V1.
Use only the visible morphology in the ECG image. Treat each finding as an
independent visual attribute of the beat, not as a final diagnosis.

Return only the requested JSON. Do not include prose, markdown, caveats, a
diagnosis, or a clinical recommendation.
```

C.3.- TAREA MORFOLÓGICA

```
Analyze this single-beat right precordial ECG image from lead {lead}.

Inspect the beat from left to right:
  - identify the QRS complex, including any second positive terminal deflection
  - use the flat PR/TP segment around the beat as the visual baseline when visible
  - inspect the J point and ST segment immediately after the QRS
  - inspect the T wave that follows the ST segment

Evaluate these morphology findings independently:

RBBB:
  - true when the QRS has a right-precordial terminal conduction pattern such as
    RSR', rSr', rsR', or a clear late positive R' after the initial QRS deflection
  - also true when the terminal part of the QRS looks delayed or widened in a way
```

```
    compatible with right bundle branch block morphology
  - false when there is no clear terminal R' or delayed terminal QRS morphology

ST_ELEVATION:
  - true when the J point or ST segment after the QRS remains above the visual
    baseline
  - coved/convex elevation and saddleback elevation count when visually present
  - false when the ST segment returns to baseline or is not visibly elevated

T_WAVE_INVERSION:
  - true when the T wave after the ST segment is predominantly negative, below
    the visual baseline
  - false when the T wave is upright, flat without a clear negative component, or
    not visible enough to judge as inverted

Return only valid JSON with boolean values for exactly these keys:

{
  "RBBB": true,
  "ST_ELEVATION": true,
  "T_WAVE_INVERSION": true
}
```

C.4.- SISTEMA PARA TAREA CLÍNICA

```
You are evaluating a single lead V1 right precordial ECG beat image from one
patient.

Use only the visible morphology in the image and the in-context examples. The
label is a research reference for suspected Brugada triage. It must not be used
as an autonomous diagnosis.

Return only the requested JSON. Do not include prose, markdown, caveats, a
diagnosis, or a clinical recommendation.
```

C.5.- TAREA CLÍNICA DIRECTA

```
Analyze this single right precordial ECG beat image from lead {lead} from one
    patient.

```

```
Decide whether the patient is compatible with the Brugada-positive research
reference used in this study.

Look for right-precordial Brugada-type visual evidence in V1:
  - J-point or ST elevation immediately after the QRS
  - a coved or convex descending ST segment, especially when followed by a
    predominantly negative T wave
  - a saddleback ST shape can be supportive but is less specific by itself
  - terminal right-precordial QRS features such as rSr' or RSR' can support the
    visual pattern, but should not be the only reason for a positive label

Return false when the beat is visually closer to a normal V1 morphology, when ST
elevation is absent, or when the image does not show enough Brugada-type
evidence. Use the support examples, when present, to calibrate the study label.

Return only valid JSON with exactly this key:

{
  "clinical_brugada": true
}
```

C.6.- CONSTRUCCIÓN DEL CONTEXTO

En zero-shot no se añaden demostraciones. El modelo recibe el mensaje de sistema, la tarea y la imagen objetivo. En ICL estándar, cada demostración contiene una imagen V1 y la respuesta JSON correcta. Cuando $K \geq 2$, se incluye primero una muestra de cada clase y el resto se selecciona de forma seudoaleatoria mediante la semilla de la ejecución. En ICL balanceado, se intenta asignar $K/2$ pacientes positivos y $K/2$ negativos; si una clase no dispone de casos suficientes, las posiciones libres se completan con la otra. Ninguna de las dos condiciones incluye al paciente reservado para test.

Las respuestas se validan de forma estricta. Una salida con claves ausentes, claves adicionales, texto libre o tipos incorrectos se registra como fallo de formato. En la evaluación final, la tasa de JSON inválido fue 0, por lo que las diferencias de rendimiento proceden de las decisiones del modelo y no de errores sintácticos.

Bibliografía

[1] Zeppenfeld, K. y colaboradores. 2022 ESC Guidelines for the management of patients with ventricular arrhythmias and the prevention of sudden cardiac death. *European Heart Journal*, 43(40), 3997–4126, 2022. https://doi.org/10.1093/eurheartj/ehac262.

[2] Kligfield, P., Gettes, L. S., Bailey, J. J. y colaboradores. Recommendations for the standardization and interpretation of the electrocardiogram. Part I. The electrocardiogram and its technology. *Circulation*, 115(10), 1306–1324, 2007. https://doi.org/10.1161/CIRCULATIONAHA.106.180200.

[3] Surawicz, B., Childers, R., Deal, B. J., Gettes, L. S. y colaboradores. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part III. Intraventricular conduction disturbances. *Circulation*, 119(10), e235–e240, 2009. https://doi.org/10.1161/CIRCULATIONAHA.108.191095.

[4] Rautaharju, P. M., Surawicz, B. y Gettes, L. S. AHA, ACCF and HRS recommendations for the standardization and interpretation of the electrocardiogram. Part IV. The ST segment, T and U waves, and the QT interval. *Circulation*, 119(10), e241–e250, 2009. https://doi.org/10.1161/CIRCULATIONAHA.108.191096.

[5] OpenStax. Anatomy and Physiology 2e. Figure 19.23, ECG Tracing. Rice University, 2022. https://openstax.org/books/anatomy-and-physiology-2e/pages/19-2-cardiac-muscle-and-electrical-activity.

[6] Sieira, J. y Brugada, P. The definition of the Brugada syndrome. *European Heart Journal*, 38(40), 3029–3034, 2017. https://doi.org/10.1093/eurheartj/ehx490.

[7] Wilde, A. A. M., Semsarian, C., Marquez, M. F. y colaboradores. Use, misuse, and pitfalls of the drug challenge test in the diagnosis of the Brugada syndrome. *European Heart Journal*, 44(27), 2427–2439, 2023. https://doi.org/10.1093/eurheartj/ehad295.

[8] BrugadaDrugs.org Advisory Board. Diagnostic drugs for Brugada syndrome. BrugadaDrugs.org. https://www.brugadadrugs.org/druglist_diagnostic/.

[9] CardioNetworks y ECGpedia. Brugada syndrome type1 example4. Wikimedia Commons, licencia CC BY-SA 3.0. https://commons.wikimedia.org/wiki/File:Brugada_syndrome_type1_example4_(CardioNetworks_ECGpedia).png.

[10] Napolitano, C. y Priori, S. G. Brugada syndrome. *Orphanet Journal of Rare Diseases*, 1, 35, 2006. https://doi.org/10.1186/1750-1172-1-35.

[11] Corrado, D., Pelliccia, A., Heidbuchel, H. y colaboradores. Recommendations for interpretation of 12 lead electrocardiogram in the athlete. *European Heart Journal*, 31(2), 243–259, 2010. https://doi.org/10.1093/eurheartj/ehp473.

[12] Ribeiro, A. H. y colaboradores. Automatic diagnosis of the 12 lead ECG using a deep neural network. *Nature Communications*, 11, 1760, 2020. https://doi.org/10.1038/s41467-020-15432-4.

[13] Wagner, P., Strodthoff, N., Bousseljot, R. D. y colaboradores. PTB XL, a large publicly available electrocardiography dataset. *Scientific Data*, 7, 154, 2020. https://doi.org/10.1038/s41597-020-0495-6.

[14] Gow, B., Pollard, T., Nathanson, L. A. y colaboradores. MIMIC IV ECG. Diagnostic Electrocardiogram Matched Subset. Version 1.0. PhysioNet, 2023. https://doi.org/10.13026/4nqg-sb35.

[15] Gliner, V., Keidar, N., Makarov, V. y colaboradores. Automatic classification of healthy and disease conditions from images or digital standard 12 lead electrocardiograms. *Scientific Reports*, 10, 16331, 2020. https://doi.org/10.1038/s41598-020-73060-w.

[16] Sangha, V. y colaboradores. Automated multilabel diagnosis on electrocardiographic images and signals. *Nature Communications*, 13, 1583, 2022. https://doi.org/10.1038/s41467-022-29153-3.

[17] Wu, H., Patel, K. H. K., Li, X. y colaboradores. A fully automated paper ECG digitisation algorithm using deep learning. *Scientific Reports*, 12, 20963, 2022. https://doi.org/10.1038/s41598-022-25284-1.

[18] Gliner, V., Makarov, V., Avetisyan, A. I., Schuster, A. y Yaniv, Y. Using domain adaptation for classification of healthy and disease conditions from mobile captured images of standard 12 lead electrocardiograms. *Scientific Reports*, 13, 14023, 2023. https://doi.org/10.1038/s41598-023-40693-6.

[19] Sayadi, O., Shamsollahi, M. B. y Clifford, G. D. Synthetic ECG generation and Bayesian filtering using a Gaussian wave based dynamical model. *Physiological Measurement*, 31(10), 1309–1329, 2010. https://doi.org/10.1088/0967-3334/31/10/002.

[20] Gillette, K. y colaboradores. MedalCare XL. 16 900 healthy and pathological synthetic 12 lead ECGs from electrophysiological simulations. *Scientific Data*, 10, 531, 2023. https://doi.org/10.1038/s41597-023-02416-4.

[21] Lopez Alcaraz, J. M. y Strodthoff, N. Diffusion based conditional ECG generation with structured state space models. arXiv:2301.08227, 2023. https://doi.org/10.48550/arXiv.2301.08227.

[22] Liu, R., Bai, Y., Yue, X. y Zhang, P. Teaching multimodal language models to comprehend 12 lead electrocardiographic images. *npj Digital Medicine*, 9, 349, 2026. https://doi.org/10.1038/s41746-026-02551-3.

[23] Zhang, D., Lan, X., Geng, S. y colaboradores. MEETI. A multimodal ECG dataset from MIMIC IV ECG with signals, images, features and interpretations. *Scientific Data*, 13, 527, 2026. https://doi.org/10.1038/s41597-026-06796-1.

[24] Dong, Q., Li, L., Dai, D., Zheng, C. y colaboradores. A survey on in-context learning. *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing*, 1107–1128, 2024. https://aclanthology.org/2024.emnlp-main.64/.

[25] Alayrac, J. B., Donahue, J., Luc, P. y colaboradores. Flamingo. A visual language model for few shot learning. *Advances in Neural Information Processing Systems*, 35, 23716–23736, 2022. https://arxiv.org/abs/2204.14198.

[26] Chen, S., Han, Z., He, B., Liu, J., Buckley, M., Qin, Y., Torr, P., Tresp, V. y Gu, J. Can multimodal large language models truly perform multimodal in context learning. *IEEE/CVF Winter Conference on Applications of Computer Vision*, 6000–6010, 2025. https://doi.org/10.1109/WACV61041.2025.00585.

[27] Qin, L., Chen, Q., Fei, H., Chen, Z., Li, M. y Che, W. What factors affect multimodal in context learning. An in depth exploration. *Advances in Neural Information Processing Systems*, 37, 2024. https://arxiv.org/abs/2410.20482.

[28] Camba, S., Otero, A., García, D., Sánchez, L. y Costa, N. Can In-Context Learning Enable Large Vision Language Models to Detect ECG Abnormalities? En *Artificial Intelligence in Biomedicine. CIABiomed 2025*, Lecture Notes in Computer Science, vol. 16148, 200–213. Springer, Cham, 2026. https://doi.org/10.1007/978-3-032-10661-2_16.

[29] Google DeepMind. Gemma 4 model card. Google AI for Developers. https://ai.google.dev/gemma/docs/core/model_card_4.

[30] Google Health AI Developer Foundations. MedGemma 1.5 model card. Google for Developers. https://developers.google.com/health-ai-developer-foundations/medgemma/model-card.

[31] He, K., Zhang, X., Ren, S. y Sun, J. Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, 770–778, 2016. https://doi.org/10.1109/CVPR.2016.90.

[32] Selvaraju, R. R. y colaboradores. Grad-CAM: Visual explanations from deep networks via gradient-based localization. *Proceedings of the IEEE International Conference on Computer Vision*, 618–626, 2017. https://doi.org/10.1109/ICCV.2017.74.

[33] Ganin, Y. y colaboradores. Domain adversarial training of neural networks. *Journal of Machine Learning Research*, 17(59), 1–35, 2016. https://jmlr.org/papers/v17/15-239.html.

[34] Chen, T., Kornblith, S., Norouzi, M. y Hinton, G. A simple framework for contrastive learning of visual representations. *Proceedings of the 37th International Conference on Machine Learning*, PMLR 119, 1597–1607, 2020. https://proceedings.mlr.press/v119/chen20j.html.

[35] Sun, B. y Saenko, K. Deep CORAL. Correlation alignment for deep domain adaptation. En *European Conference on Computer Vision Workshops*, 443–450, 2016. https://arxiv.org/abs/1607.01719.

[36] Long, M., Cao, Y., Wang, J. y Jordan, M. I. Learning transferable features with deep adaptation networks. *Proceedings of the 32nd International Conference on Machine Learning*, PMLR 37, 97–105, 2015. https://proceedings.mlr.press/v37/long15.html.

[37] Tsoumakas, G. y Katakis, I. Multi label classification. An overview. *International Journal of Data Warehousing and Mining*, 3(3), 1–13, 2007. https://doi.org/10.4018/jdwm.2007070101.

[38] Loshchilov, I. y Hutter, F. Decoupled weight decay regularization. *International Conference on Learning Representations*, 2019. https://arxiv.org/abs/1711.05101.

[39] Costa Cortez, N. y García Iglesias, D. Brugada-HUCA. 12-Lead ECG Recordings for the Study of Brugada Syndrome. Version 1.0.0. PhysioNet, 2026. https://doi.org/10.13026/0m2w-dy83.

[40] Bossuyt, P. M., Reitsma, J. B., Bruns, D. E. y colaboradores. STARD 2015: an updated list of essential items for reporting diagnostic accuracy studies. *BMJ*, 351, h5527, 2015. https://doi.org/10.1136/bmj.h5527.

[41] Sounderajah, V., Guni, A., Liu, X., STARD-AI Steering Committee y colaboradores. The STARD-AI reporting guideline for diagnostic accuracy studies using artificial intelligence. *Nature Medicine*, 31(10), 3283–3289, 2025. https://doi.org/10.1038/s41591-025-03953-8.

[42] Collins, G. S., Moons, K. G. M., Dhiman, P. y colaboradores. TRIPOD+AI statement. Updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378, 2024. https://doi.org/10.1136/bmj-2023-078378.

[43] Unión Europea. Reglamento 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales. *Diario Oficial de la Unión Europea*. https://eur-lex.europa.eu/eli/reg/2016/679/oj/spa.

[44] España. Ley Orgánica 3/2018 de Protección de Datos Personales y garantía de los derechos digitales. *Boletín Oficial del Estado*. https://www.boe.es/buscar/act.php?id=BOE-A-2018-16673.

[45] España. Ley 14/2007 de Investigación biomédica. *Boletín Oficial del Estado*. https://www.boe.es/buscar/act.php?id=BOE-A-2007-12945.

Índice de figuras

2.1. Representación clínica de un ECG real de doce derivaciones renderizado desde un registro de PTB-XL/PhysioNet [13]. 6
2.2. Componentes morfológicos de un latido ECG: onda P, complejo QRS, onda T, segmentos PR y ST, e intervalos PR y QT. Fuente: OpenStax [5]. 7
2.3. Ejemplos clínicos de morfología Brugada. La imagen izquierda procede de ECGpedia, CC BY-SA 3.0 [9]. La imagen derecha procede de Napolitano y Priori, CC BY 2.0 [10]. 9
2.4. Representación esquemática de rasgos morfológicos asociados al patrón tipo 1 de Brugada. 10

3.1. Esquema general del aprendizaje en contexto: varias demostraciones se concatenan con una consulta y el modelo congelado produce la respuesta sin actualizar parámetros. Fuente: Dong y colaboradores [24]. 22

4.1. Resumen del diseño experimental común: entrada de ECG como imagen, uso supervisado de ejemplos en la CNN, uso contextual de ejemplos en el VLM/ICL y evaluación con métricas compartidas. 26
4.2. Separación por paciente y selección de ejemplos para cada valor de K. El paciente reservado no interviene en la selección; los ejemplos actualizan los pesos de la CNN o forman el contexto del VLM. 28

5.1. Generador gaussiano de un latido sintético. Los parámetros de cada átomo fijan su amplitud, posición y anchura antes de sumar las regiones P, QRS, ST y T. 31
5.2. Ejemplos sintéticos por familia generadora utilizados para validar visualmente el simulador. 37
5.3. Distribución de combinaciones de etiquetas derivadas en el conjunto sintético LOOCV. 38

6.1. Uso supervisado de los ejemplos etiquetados. Las muestras de entrenamiento actualizan ResNet18 y la muestra reservada produce una predicción binaria y su mapa Grad-CAM. 43
6.2. Ejemplo Grad-CAM de la CNN para una única imagen V1 del conjunto sintético: entrada, mapa de activación y superposición. 46

6.3. Construcción del contexto VLM/ICL. Las demostraciones preceden a la imagen de consulta y la predicción se obtiene sin actualizar los pesos. 47

7.1. Rendimiento de CNN e ICL en el simulador según el número de ejemplos. Las barras representan la desviación estándar entre semillas. 50
7.2. Matrices de confusión agregadas en el simulador. Cada matriz suma las predicciones de tres semillas sobre los mismos 100 pacientes. 51
7.3. Preparación de la imagen V1 y de los pliegues por paciente. Otras derivaciones pueden ayudar a localizar R, pero solo V1 se renderiza como entrada. Las 951 entradas de una matriz agregada corresponden a 317 pacientes evaluados con tres semillas, no a imágenes distintas. 52
7.4. Relación entre el dominio sintético, la cohorte del HUCA y las dos estrategias de adaptación evaluadas. 53
7.5. Transferencia sintético-real. A la izquierda se comparan las variantes de adaptación de la CNN; a la derecha, Gemma 4 con demostraciones sintéticas. . . 54
7.6. Comparación entre la CNN transferida desde el simulador y Gemma 4 con contexto clínico. 56
7.7. Matrices agregadas de los mejores puntos de la CNN y del VLM. Cada matriz suma 951 predicciones sobre 317 pacientes. 56
7.8. Sensibilidad y especificidad de los mejores puntos sobre la cohorte del HUCA. 57
7.9. Brecha sintético-real medida mediante Balanced Accuracy (BA). 57

Índice de tablas

1. Siglas y abreviaturas utilizadas en la memoria. III

4.1. Conjuntos utilizados en los experimentos finales. Cada paciente aporta una imagen; las matrices de confusión acumulan las predicciones obtenidas con las tres semillas. 27

5.1. Átomos utilizados para construir un latido sintético 30
5.2. Relación entre familias generadoras y rasgos favorecidos 34
5.3. Criterios de los validadores sintéticos 35

6.1. Configuración CNN utilizada en los experimentos finales. 43
6.2. Métodos de adaptación de dominio evaluados para la CNN. 45

7.1. Mejores resultados en el simulador QRS/ST. La BA se presenta como media y desviación estándar de tres semillas. 49
7.2. Composición de la cohorte del HUCA utilizada en la evaluación. 52
7.3. Puntos principales de la CNN sobre la cohorte del HUCA. CORAL y MMD se comparan con sus bases del mismo valor de K. 54
7.4. Mejores resultados sobre los ECG del HUCA. Las demostraciones de Gemma 4 proceden de la propia cohorte. 55

A.1. Configuración del conjunto sintético final. 63
A.2. Configuración de la cohorte procesada del HUCA. 64
A.3. Hiperparámetros de la CNN final. 65
A.4. Configuración de los experimentos de adaptación de dominio. 65
A.5. Configuración resumida del enfoque VLM/ICL. 66

B.1. Resultados completos de la CNN en los dominios sintético y real. 67
B.2. Resultados completos de adaptación no supervisada sobre la cohorte del HUCA. 68
B.3. Resultados de Gemma 4 en el simulador QRS/ST. 68
B.4. Resultados de Gemma 4 sobre la cohorte del HUCA con demostraciones de la propia cohorte. 69
B.5. Resultados de Gemma 4 sobre la cohorte del HUCA con demostraciones sintéticas. 69